Monte Carlo, Entegraller, MCMC

Fizik, biyoloji ve ozellikle makina ogrenimi problemlerinde bazen cok boyutlu bir fonksiyon uzerinden entegral almak gerekebiliyor. En basit ornek, mesela bir dagilimin baska bir fonksiyon ile carpiminin beklentisini (expectation) hesaplamak gerektiginde, ki bu

$$E(f) = \int p(x)f(x)dx$$

entegralidir, $x \in \mathbb{R}^n$, $p(x)$ dagilim fonksiyonu, $f(x)$ herhangi bir baska fonksiyon olmak uzere, o zaman tum x degerlerini goz onune alarak (ayriksal baglamda ya teker teker gecerek, ya da analitik olarak) entegral hesabini yapmak gerekecekti.

Fakat $p(x)$ bir dagilim olduguna gore, ve bizim gectigimiz her x icin bir olasilik degeri varsa, bu isi tersine cevirerek, $p(x)$'teki olasiliklara gore belli (az) sayida x urettirirsek, ve sadece bu x'leri entegral hesabinda kullanirsak yaklasiksal acidan gercek entegral hesabina yaklasmis oluruz.

Bu mantikli degil mi? Dusunursek, mesela 10 degeri 0.4 olasiliginda ise, 5 degeri 0.1 olasiliginda ise, hem sayi, hem olasiligi ile carpmak yerine "daha fazla 10 degeri uretmek" ve bu degerleri f'e gecmek, toplamak, sonra bolmek, vs. yaklasiksal olarak ayni kapiya cikar. Yani

$$E_N = \frac{1}{N}\sum_{1=1}^{N} f(x^{(i)})$$

ustteki entegralin yaklasiksal temsilidir, $x^{(i)}$ $p(x)$ olasiligina gore uretilen sayilari temsil ediyor. Ustteki baglantinin teorik olarak ispati da var, bu ispati burada vermeyecegiz.

Iste Monte Carlo entegral hesabinin artasinda yatan numara budur.

MCMC

Demek ki Monte Carlo entegralinin islemesi icin $p(x)$'den ornekleme yapmak gerekiyor. Simdi ikinci numaraya gelelim.

Bazen ne yazik ki $p(x)$'den ornekleme yapmak kolay olmuyor. Bu durumlar icin $p(x)$ yerine onu yaklasiksal olarak temsil eden bir $\pi(x)$'i elde etmekle ugrasiliyor. Bu $\pi(x)$ ise bir Markov Zincirinin (Markov Chain -yine MC harfleri!-) duragan dagilimi olarak hayal ediliyor.

Markov Zinciri teorisinde bir gecis matrisi, yan Markov Zincirinin kendisi verilir, ve duragan dagilimin hesaplanmasi istenir. MCMC problemlerinde ise, yani Monte Carlo entegrali icin Markov Zinciri kullanildigi durumlarda elimizde bir $\pi(x)$ dagilimi vardir ve bir Markov Zinciri olusturmamiz gerekir. Nihai dagilimi biliriz, ve bu dagilima "giden" gecisleri uretiriz. Bu gecisleri oyle ayarlayabiliriz ki uretilen rasgele sayilar hedef dagilimindan geliyormus gibi olur.

Gecisleri uretmek icin literaturde bir cok teknik vardir. Onemsel Ornekleme (Impor-

tance Sampling), Ornekleme ve Oneme Gore Tekrar Ornekleme (Sampling Importance Resampling), Metropolis-Hastings, Gibbs Orneklemesi gibi teknikleri vardir, ve detaylari degisik olsa da hepsi de MCMC kategorisine girer, ve yapmaya calistiklari $\pi(x)$'e giderken bir sekilde bir gecisleri, zinciri ortaya cikartmak ve bu gecisleri entegral hesabinda kullanmaktir.

Ustteki tekniklerden en yaygin kullanilani Metropolis-Hastings algoritmasidir.

Not: Bu alandaki makalelerde bir dagilimin "belli bir carpimsal sabite kadar" bilindigi (known up to a multiplicative constant) soylenir. Bu soz aslinda su anlama gelir. Mesela ayriksal bir dagilimimiz var, ama bu dagilimin kendisini, su halini biliyoruz

```
[ 4.3  2.   8.4  8.7  1.8]
```

Bu bir dagilim degil, cunku ogelerin toplami 1 degil. Onu bir dagilim haline cevirmek icin, tum ogeleri toplamak ve bu vektordeki tum sayilari bu toplam ile bolmek gerekir. Toplam 25.2, bolersek

```
[ 0.17063492  0.07936508  0.33333333  0.3452381   0.07142857]
```

Ilk vektor "belli bir carpimsal sabite kadar" bilinen dagilim, carpimsal sabit 25.2. Esas dagilim ikinci vektor.

Peki niye bu sozu soyleyenler toplami hesaplayip gercek dagilimi hesaplamiyorlar? Sebep performans. Bazen ayriksal dagilim o kadar yuksek boyutlu, fazla oge iceren bir halde oluyor ki, performans acisindan bu basit toplam hesabini yapmak bile cok pahali oluyor. Iste MCMC metotlarinin bir guzel tarafi daha burada, dagilimin kendisi olmasa bile belli bir carpimsal sabite kadar bilinen versiyonlari ile gayet rahat bir sekilde isliyorlar.

Kaynaklar

Algorithmic Machine Learning, Stephen Marsland