Regresyon, Ridge, Lasso, Capraz Saglama, Regularize Etmek

Konumuz regresyon cesitleri, ve ornek veri olarak diyabet hastaligi olan kisilerden alinmis bazi temel verilerle hastaligin bir sene sonraki ilerleme miktari kullanilacak. Regresyon sayesinde temel veriler ile hastaligin ilerlemesi arasinda bir baglanti bulunabilir, bu sayede hem veri aciklanir / daha iyi anlasilir (hangi degisken onemlidir, hangisi degildir), hem de baska bir hastanin temel verilerini kullanarak o hastanin diyabetinin bir sene sonra ne olacagini tahmin etmek mumkun olur. Kullanilan temel veriler kisinin yasi, cinsiyeti, vucut kutle endeksi (body mass index) ortalama tansiyonu ve alti kere alinmis kan serum olcumleridir.

```
from pandas import *
diabetes = read_csv("diabetes.csv",sep=';')
diabetes_y = diabetes['response']
diabetes_x = diabetes.drop("response",axis=1)
diabetes_x_train = diabetes_x[:-20]
diabetes_x_test  = diabetes_x[-20:]
diabetes_y_train = diabetes_y[:-20]
diabetes_y_test  = diabetes_y[-20:]
```

Ilk once basit regresyonu hatirlayalim (ordinary least regression). Bu teknigi daha once pek cok yonden gorduk. *Lineer Cebir*, *Cok Degiskenli Calculus* ders notlarinda, ve bizim *Uygulamali Matematik* yazilarinin hepsinde bu teknigin turetilmesi mevcut. Formul

$$\hat{w} = (X^T X)^{-1} X^T y$$

Numerik olarak hemen bu hesabi yapabiliriz. Bir hatirlatma: veri setine y ekseninin nerede kesildiginin bulunabilmesi icin suni bir ekstra 'intercept' adli kolon ekleyecegiz, bu kolon iki boyutta $y = ax + c$ formulundeki c'nin bulunabilmesi icindir. Pandas ile bu ekstra kolonu eklemek cok basit, ismen mevcut olmayan kolon erisildigi anda o kolon hemen yoktan yaratilir.

```
import numpy.linalg as la
x_tmp = diabetes_x_train.copy()
x_tmp['intercept'] = 1
xTx = np.dot(x_tmp.T,x_tmp )
ws = np.dot(la.inv(xTx),np.dot(x_tmp.T,diabetes_y_train))
print ws
```

```
[  3.03499452e-01  -2.37639315e+02   5.10530605e+02   3.27736981e+02
  -8.14131711e+02   4.92814589e+02   1.02848453e+02   1.84606489e+02
   7.43519617e+02   7.60951724e+01   1.52764307e+02]
```

Ayni hesabi bir de `scikit-learn` paketini kullanarak yapalim. Bu paketin `LinearRegression` cagrisi intercept isini otomatik olarak hallediyor, eger intercept olmasin isteseydik, `fit_intercept=False` diyecektik.

```
from sklearn import linear_model, cross_validation
lin = linear_model.LinearRegression()
```

```
lin.fit(diabetes_x_train, diabetes_y_train)
print lin.coef_
print "score", lin.score(diabetes_x_test, diabetes_y_test),
```

```
[  3.03499452e-01  -2.37639315e+02   5.10530605e+02   3.27736981e+02
  -8.14131711e+02   4.92814589e+02   1.02848453e+02   1.84606489e+02
   7.43519617e+02   7.60951724e+01]
score 0.585075302278
```

Sonuclar birbirine oldukca yakin. Simdi diger tekniklere gelelim.

Sırt Regresyonu (Ridge Regression)

Klasik regresyon ile

$$\hat{w} = \arg\min_{w} ||y - Xw||^2$$

problemini cozdugumuzu biliyoruz, ki $||\cdot||^2$ Oklit normunun karesini temsil ediyor. Fakat bazi durumlarda X^TX'in tekil (singular) olmasi mumkun ki boyle bir durumda $(X^TX)^{-1}$'in tersini almamiz mumkun olmazdi. Tekillik ne zaman ortaya cikar? Eger elimizde veri noktasindan daha fazla boyut var ise mesela... Diyelim ki veri olarak 10 tane kolon var, ama sadece 9 tane veri satiri. Sirt Regregyonunun cikis noktasi budur.

Fakat ek olarak bu teknik kestirme hesaplarimiza (estimation) bir meyil / yanlilik (bias) eklemek icin de kullanilabilir ve bu meyil tahminlerin / kestirme hesaplarin iyilesmesine faydali olabilir.

Meyili nasil ekleriz? Diyelim ki bizim tanimlayacagimiz bir λ ile tum ws'lerin toplamina bir ust sinir tanimlayabiliriz. Boylelikle regresyonun bulacagi katsayilarin cok fazla buyumesine bir "ceza" getirmis olacagiz, ve bu cezayi iceren regresyon hesabi o cezadan kacinmak icin mecburen bulacagi katsayilari ufak tutacak, hatta bazilarini sifira indirebilecek. Bu azaltmaya istatistikte kuculme (shrinkage) ismi veriliyor.

Sirt regresyonu icin bu kucultme soyle

$$\hat{w}_{sirt} = \arg\min_{w}(||y - Xw||^2 + \lambda||w||^2)$$

Goruldugu uzere w'nin buyuklugunu, bir λ katsayisi uzerinden minimizasyon problemine dahil ettik, boylece diger parametreler ile buyukluk te minimize edilecek. Ustteki tanim siniri tanimlanmamis (unconstrained) bir optimizasyon problemidir. Sinirli olarak

$$\min_{w} ||y - Xw||^2$$

$$\textit{Su kosula gore (subject to)} \; ||w||^2 \leqslant \tau$$

ki λ Lagrange carpanidir. Aslinda simdiye kadar ustteki cevrimin tersini gorduk cogunlukla (yani sinirli problemden sinirsiza gitmeyi), bu gidis tarzini gormek te iyi oldu.

Neyse bastaki sinirsiz problemi cozmek icin ifadenin gradyanini alalim,

$$\nabla\big(||y - Xw||^2 + \lambda||w||^2\big)$$

$$\nabla\big((y - Xw)^T(y - Xw) + \lambda w^T w\big)$$

$$\nabla\big((y^T - w^T X^T)(y - Xw) + \lambda w^T w\big)$$

$$\nabla(y^T y - y^T Xw - w^T X^T y + w^T X^T Xw + \lambda w^T w)$$

$$-y^T X - X^T y + 2X^T Xw + 2\lambda w$$

$$-2X^T y + 2X^T Xw + 2\lambda w$$

$$2X^T Xw + 2\lambda w - 2X^T y$$

$$2(X^T X + \lambda I)w - 2X^T y$$

Minimizasyon icin ustteki ifadeyi sifira esitleyebiliriz

$$2(X^T X + \lambda I)w - 2X^T y = 0$$

O zaman

$$(X^T X + \lambda I)w = X^T y$$

$$\hat{w} = (X^T X + \lambda I)^{-1} X^T y$$

Bu son ifade en az kareler (least squares) yani normal regresyon cozum formulune cok benziyor, sadece ek olarak bir λI toplama islemi var. Demek ki sirt regresyonunu kullanmak icin zaten yaptigimiz hesaba, zaten bizim kendimizin karar verdigi bir λ uzerinden λI eklersek, geri kalan tum islemler ayni olacak.

Kontrol edelim

```
lam = 0.2
wridge = np.dot(la.inv(xTx+lam*np.eye(xTx.shape[0])),\
                np.dot(x_tmp.T,diabetes_y_train))
print wridge
```

```
[  16.70807829 -179.42288145  447.64999897  285.41866481  -51.7991733
  -75.09876191 -192.46341288  123.61066573  387.91385823  105.53294479
  152.7637018 ]
```

Simdi `scikit-learn` ile ayni hesabi yapalim

```
ridge = linear_model.Ridge(alpha=0.2)
ridge.fit(diabetes_x_train, diabetes_y_train)
print ridge.score(diabetes_x_test, diabetes_y_test), ridge.coef_
```

```
0.553680030106 [  16.69330211 -179.414259    447.63706059  285.40960442  -51.79094255
  -75.08327488 -192.45037659  123.60400024  387.91106403  105.55514774]
```

Bir yontem daha var, bu yonteme Lasso ismi veriliyor. Lasso'ya gore cezalandirma

$$\sum_{k=1}^{n} w_k^2 \leqslant \lambda$$

uzerinden olur. Bu yontemin tum detaylarina simdilik inmeyecegiz.

Ornek olarak bir λ ile onun buldugu katsayilara bakalim.

```
lasso = linear_model.Lasso(alpha=0.3)
lasso.fit(diabetes_x_train, diabetes_y_train)
print lasso.coef_
```

```
[   0.          -0.          497.3407568   199.17441037   -0.          -0.
 -118.89291549    0.          430.93795945    0.        ]
```

Lasso bazi katsayilari sifira indirdi! Bu katsayilarin agirlik verdigi degiskenleri, eger Lasso'ya inanirsak, modelden tamamen atmak mumkundur.

Bu arada Sirt ve Lasso yontemlerinin metotlarina "regularize etmek (regularization)" ismi de veriliyor.

k-Katlamali Capraz Saglama (k-fold Cross-Validation)

Bir yapay ogrenim algoritmasini kullanmadan once veriyi iki parcaya ayirmak ise yarar; bu parcalar tipik olarak egitim verisi (training set) digeri ise test verisi (validation set) olarak isimlendirilir. Isimlerden belli olacagi uzere, algoritma egitim seti uzerinde egitilir; ve basarisi test verisi uzerinden rapor edilir. Bir bakima modelin olusturulmasi bir set uzerindendir, sonra "al simdi hic gormedigin bir veri seti, bakalim ne yapacaksin" sorusunun cevabi, saglamasi bu sekilde yapilir.

k-Katlamali Capraz Saglama bu iki parcali egitim / test kavramini bir adim oteye tasir. Ufak bir k seceriz, ki bu genellikle 5 ila 10 arasinda bir sayi olur, ve tum verimizi rasgele bir sekilde ama k tane ve esit buyuklukte olacak sekilde parcalara ayiririz. Bu parcalara "katlar (folds)" ismi verilir bazen (ki isim buradan geliyor).

Sonra teker teker her parcayi test verisi yapariz ve geri kalan tum parcalari egitim verisi olarak kullaniriz. Bu islemi tum parcalar icin tekrarlariz.

Bu yaklasim niye faydalidir? Cunku veriyi rasgele sekillerde bolup, pek cok yonden egitim / test icin kullaninca verinin herhangi bir sekilde bizi yonlendirmesi / aldatmasi daha az mumkun hale gelir.

Ve iste bu ozelligi, ek olarak, capraz saglamayi "model secmek" icin vazgecilmez bir arac haline getirir.

Model secmek nedir? Model secimi ustteki baglamda optimal bir λ bulmaktir mesela, yani her modeli temsil eden bir λ var ise, en iyi λ'yi bulmak, en iyi modeli bulmak anlamina geliyor, capraz saglama bunu sagliyor. Capraz saglama icin `scikit-learn`'un sagladigi fonksiyonlar vardir, once katlari tanimlariz, sonra bu degistirilmis regresyon fonksiyonlarina katlama usulunu geceriz.

```
k_fold = cross_validation.KFold(n=420, n_folds=7)
```

Katlari ustteki gibi tanimladik. 420 tane veri noktasini 7 kata bol dedik. Simdi bu katlari kullanalim,

```
ridge_cv = linear_model.RidgeCV(cv=k_fold)
ridge_cv.fit(np.array(diabetes_x), np.array(diabetes_y))
print ridge_cv.alpha_
```

```
0.1
```

Ustteki sonuc $\lambda = 0.1$'i gosteriyor. Bu λ daha optimalmis demek ki. Lasso icin benzer sekilde

```
lasso_cv = linear_model.LassoCV(cv=k_fold)
print lasso_cv.fit(diabetes_x, diabetes_y)
```

```
LassoCV(alphas=None, copy_X=True,
    cv=sklearn.cross_validation.KFold(n=420, n_folds=7), eps=0.001,
    fit_intercept=True, max_iter=1000, n_alphas=100, normalize=False,
    precompute=auto, tol=0.0001, verbose=False)
```

```
print lasso_cv.alpha_
```

```
0.00283958719118
```

```
print lasso_cv.score(diabetes_x_test, diabetes_y_test)
```

```
0.597090337358
```

Simdi veri setinin bir kismi uzerinde teker teker hangi algoritmanin daha basarili oldugunu gorelim.

```
def predict(row):
    j = row; i = row-1
```

```
    new_data = diabetes_x[i:j]
    print diabetes_y[i:j], "lasso",lasso_cv.predict(new_data), \
                "ridge",ridge_cv.predict(new_data), \
                  "linear",lin.predict(new_data)

predict(-2) # sondan ikinci veri satiri
predict(-3)
predict(-4)
predict(-5)
predict(-8)
```

```
439    132
Name: response, dtype: int64 lasso [ 122.2361344] ridge [ 127.1821212] linear [ 123.5
438    104
Name: response, dtype: int64 lasso [ 101.85154189] ridge [ 108.89678818] linear [ 102
437    178
Name: response, dtype: int64 lasso [ 192.95670241] ridge [ 189.58095011] linear [ 194
436    48
Name: response, dtype: int64 lasso [ 52.8903924] ridge [ 57.66611598] linear [ 52.5445
433    72
Name: response, dtype: int64 lasso [ 60.42852107] ridge [ 66.3661042] linear [ 61.198
```

Ustteki sonuclara gore gercek degeri 132 olan 439. satirda lasso 122.2, sirt (ridge) 127.1, basit regresyon ise 123.5 bulmus. O veri noktasi icin sirt yontemi daha basarili cikti.

Sonuclara bakinca bazen sirt, bazen normal regresyon basarili cikiyor. Hangi yontem kazanmis o zaman? Bir o, o bir bu ondeyse, hangi yontemi kullanacagimizi nasil bilecegiz?

Aslinda her seferinde tek bir metotu kullanmak gerekmiyor. Bu metotlari bir takim (ensemble) halinde isletebiliriz. Her test noktasini, her seferinde tum metotlara sorariz, gelen sonuclarin mesela.. ortalamasini aliriz. Bu sekilde tek basina isleyen tum metotlardan tutarli olarak her seferinde daha iyi sonuca ulasacak bir sonuc elde edebiliriz. Zaten Kaggle gibi yarismalarda cogunlukla birinciligi kazanan metotlar bu turden takim yontemlerini kullanan metotlar, mesela Netflix yarismasini kNN ve SVD metotlarini takim halinde isleten bir grup kazandi.

Kaynaklar

`www.lx.it.pt/~mtf/Figueiredo_Linear_Regression.pdf`

`www.cs.nyu.edu/~mohri/mls/lecture_8.pdf`

Harrington, P., *Machine Learning in Action*

Shalizi, C., Data Analysis from an Elementary Point of View