


## Giris

Bu notlar makine ogrenimi, veri madenciligi gibi konularda gerekli olasilik ve istatistik bilgisini paylamak icin hazirlaniyor. Notlarda olasilik ve istatistik ayni anda anlatilacak, ve uygulamalara agirlik verilecek.

## Dağılımlar Hakkında

Doğadan yapılan çoğu ölçümlerin, sıklık grafiğini alınca sonucun aşağıda gibi çıkması ilginçtir.



Mesela, Türkiye'deki 2000 yetişkinin kilosunu ölçün. Grafiğini alın, kesinlikle yukarıdaki tepe şekli çıkacak. Ya da, 1000 kişinin boyunu ölçün, aynı tepe şekli. Keskin nişancının hedefe attığı kurşunların hedefe gelişini en iyi 12 en kötü 1 olmak üzere ölçün, sıklık grafiğini alın. Gene aynı tepe şekli!

Nasıl oluyor bu iş?

Açıklama için, normal dağılım eğrisinden bahsetmemiz gerekecek.

Not olarak düşelim: Sıklık grafiği, X sayısının ne kadar çıktığını sayıp, Y ekseninde bu sayıyı X'e tekabül ederek kolon olarak göstermeye denir. Mesela, 60 kilo değeri 13 kere çıktı ise,  $X=60$ ,  $Y=13$  gibi bir kolon çizilecektir.

## Normal Dağılım Eğrisi

Normal dağılımın olasılık kavramı ile yakın bağları var. Bu konuda ünlü bir deney zar atma deneyidir. Mesela, elimizde tek bir zar olsun, ve bu zarı arka arkaya atalım. Sabrımız yeterse 1000 kere atalım. Sonuçta, sıklık grafiği eşit bir dağılım gösterecektir. (Zar tutmuyorsanız :) )

Bunun sebeplerini anlamak zor değil. Her zar atış olayı birbirinden bağımsız, ve her sayının üstte gelme ihtimali birbirine eşit olduğu için ( $1/6$ ), her sayıdan eşit miktarda gelecektir. Tabii bunun için deneyin birçok kere tekrarlanması gerekiyor.

Fakat, bir yerine 2 zar atalım. Hatta hatta, 4 zar atalım, ve bu sefer sıklık grafik hanesine yazmadan çıkan sayıları önce toplayalım. Bu çıkan toplamın sıklık grafiğini alalım.

İşte bu sıklık grafiği göreceğiz ki, önceden bahsettiğimiz tepe grafiğine yaklaşıyor. Ne kadar çok zar atarsanız, bu benzerlik o kadar daha fazla olacaktır.

Bunun sebebi de aslında basit: 1..6 arası sayıların tek bir zardan gelme olasılığı

aynı, evet. Fakat toplamlara gelince, mesela iki zarlı örnekte, 10 sayısının olasılığı 2 sayısından daha yüksek. Çünkü, 10 sayısını 5-5, 4-6 ya da 6-4 ile alabiliyoruz. 2 sayısı sadece 1-1 ile geliyor.

Buradan şu sonuç çıkabilir: Eğer doğada ölçtüğümüz bir kavramın oluşmasında birden fazla etken var ise, o ölçümlerin sıklığı her zaman tepe şekli ile olacaktır.

Fakat, daha da gizemli olan bir olay şudur; Sabit olan bir şeyi ölçtüğümüzde (yaptığımız hatalar sonucu) çıkan grafiğin bile tepe şekilli olması! Yani, doğru dürüst hata yapmak bile elimizde değil gibi gözüküyor... Bunun tabii ki olasılık açıklamaları olacaktır. İzlediğimiz matematikçilerden bu en son konuda net bir açıklama alamadık.

## Simulasyon


Eğer bu kavramları simulasyon ortamında göstermek istersek, Python ile bunu yapabiliriz.

İlk önce, Random.org sitesinden rasgele sayı üretip bilgiyımıza kopyalacağız. Bahsettiğimiz site, kimsenin kullanmadığı radyo kanallarından atmosfer gürültüsü dinleyip, bu gürültüleri sayısal değere çevirerek rasgele sayı üretiyor.

Gerçek rasgele sayı üretmek pek kolay bir iş değil. Her ne kadar bilgisayarınızda rasgele sayı üreten birçok algoritma olsa bile, bu algoritmalar belli bir sayı üretiminden sonra kendini tekrar etmeye başlıyorlar. Gerçek rasgele sayılar için muhakkak dış bir kaynağa bağlanmak gerekiyor.

Gösterimiz için, rasgele sayıları üretip, bir dat dosyasına koyuyoruz. Python ile bu sayıları okuyup, ilk önce teker teker sayıların sıklık grafiğini, ondan sonra sayıları üçer üçer toplayıp, onların grafiğini alıp göstereceğiz. Aşağıda bu iki grafiği bulabilirsiniz.

```
A = loadtxt('rasgele.dat')
plt.hist(A, 50)
plt.savefig('dagilim_1.png')
```



```
A = loadtxt('rasgele.dat');
```

```


B = []

i = 1;

while (i < 998):
    toplam = 0
    s = A[i]
    toplam = toplam + s
    s = A[i+1]
    toplam = toplam + s
    s = A[i+2]
    toplam = toplam + s
    B.append(toplam/3)
    i = i + 3

plt.hist(B, 50);
plt.savefig('dagilim_2.png')

```



## Olasilik

### Orneklem Uzayi (Sample Space)

Orneklem uzayi  $\Omega$  bir deneyin mumkun tum olasiliksal sonuclarin (outcome) kumesidir. Eger deneyimiz ardi ardina iki kere yazi (T) tura (H) atip sonucu kaydetmek ise, bu deneyin mumkun tum sonuclari soyledir

$$\Omega = \{HH, HT, TH, TT\}$$

### Sonuclar ve Olaylar (Outcomes and Events)

$\Omega$  icindeki her nokta bir sonuctur (outcome). Olaylar  $\Omega$ 'nin herhangi bir alt kumesidir ve sonuclardan olusurlar. Mesela ustteki yazi-tura deneyinde “iki atisin icinden ilk atisin her zaman H gelmesi olayi” boyle bir alt kumedir, bu olaya A diyelim,  $A = \{HH, HT\}$ .

Ya da bir deneyin sonucu  $\omega$  fiziksel bir olcüm , diyelin ki sicaklik olcumu. Sicaklik  $\pm$ , reel bir sayi olduguna gore,  $\Omega = (-\infty, +\infty)$ , ve sicaklik olcumunun 10'dan

buyuk ama 23'ten kucuk ya da esit olma "olayi"  $A = (10, 23]$ . Koseli parantez kullanildi cunku sinir degerini dahil ediyoruz.

Ornek

10 kere yazi-tura at.  $A =$  "en az bir tura gelme" olayi olsun.  $T_j$  ise  $j$ 'inci yazi-tura atisinda yazi gelme olayi olsun.  $P(A)$  nedir?

Bunun hesabi icin en kolayi, hic tura gelmeme, yani tamamen yazi gelme olasiligini,  $A^c$ 'yi hesaplamak, ve onu 1'den cikartmaktir.  $^c$  sembolu "tamamlayici (complement)" kelimesinden geliyor.

$$P(A) = 1 - P(A^c)$$

$$= 1 - P(\text{hepsi yazi})$$

$$= 1 - P(T_1)P(T_2)...P(T_{10})$$

$$= 1 - \left(\frac{1}{2}\right)^{10} \approx .999$$

Rasgele Degiskenler (Random Variables)

Bir rasgele degisken  $X$  bir eslemedir, ki bu esleme  $X : \Omega \rightarrow \mathbb{R}$  her sonuc ile bir reel sayi arasindaki eslemedir.

Olasilik derslerinde bir noktadan sonra artik ornekleme uzayindan bahsedilmez, ama bu kavramin arkalarda bir yerde her zaman devrede oldugunu hic aklimizdan cikartmayalim.

Ornek

10 kere yazi-tura attik diyelim. VE yine diyelim ki  $X(\omega)$  rasgele degiskeni her  $\omega$  siralamasinda (sequence) olan tura sayisi. Iste bir esleme. Mesela eger  $\omega = \text{HHTHHTHHTT}$  ise  $X(\omega) = 6$ . Tura sayisi eslemesi  $\omega$  sonucunu 6 sayisina esledi.

Ornek

$\Omega = \{(x, y); x^2 + y^2 \leq 1\}$ , yani kume birim cember ve icindeki reel sayilar (unit disc). Diyelim ki bu kumeden rasgele secim yapıyoruz. Tipik bir sonuc  $\omega = (x, y)$ 'dir. Tipik rasgele degiskenler ise  $X(\omega) = x$ ,  $Y(\omega) = y$ ,  $Z(\omega) = x + y$  olabilir. Goruldugu gibi bir sonuc ile reel sayi arasinda esleme var.  $X$  rasgele degiskeni bir sonucu  $x$ 'e eslemis, yani  $(x, y)$  icinden sadece  $x$ 'i cekip cikartmis. Benzer sekilde  $Y, Z$  degiskenleri var.

Toplamsal Dagilim Fonksiyonu (Cumulative Distribution Function -CDF-)

Tanim

X rasgele degiskeninin CDF'i  $F_X : \mathbb{R} \rightarrow [0, 1]$  tanimi

$$F_X(x) = P(X \geq x)$$

Eger X ayriksal ise, yani sayilabilir bir kume  $\{x_1, x_2, \dots\}$  icinden degerler aliyorsa olasilik fonksiyonu (probability function), ya da olasilik kutle fonksiyonu (probability mass function -PMF-)

$$f_X(x) = P(X = x)$$

Bazen  $f_X$ , ve  $F_X$  yerine sadece  $f$  ve  $F$  yazariz.

Tanim

Eger X surekli (continuous) ise, yani tum  $x$ 'ler icin  $f_X(x) > 0$ ,  $\int_{-\infty}^{+\infty} f(x)dx = 1$  olacak sekilde bir  $f_X$  mevcut ise, o zaman her  $a \leq b$  icin

$$P(a < X < b) = \int_a^b f_X(x)dx$$

Bu durumda  $f_X$  olasilik yogunluk fonksiyonudur (probability density function -PDF-).

$$F_X = \int_{-\infty}^x f_X(t)dt$$

Ayrica  $F_X(x)$ 'in turevi alinabildigi her  $x$  noktasinda  $f_X(x) = F'_X(x)$  demektir.

Dikkat! Eger X surekli ise o zaman  $P(X = x) = 0$  degerindedir.  $f(x)$  fonksiyonunu  $P(X = x)$  olarak gormek hatalidir. Bu sadece ayriksal rasgele degiskenler icin isler. Surekli durumda olasilik hesabi icin belli iki nokta arasinda integral hesabi yapmamiz gereklidir. Ek olarak PDF 1'den buyuk olabilir, ama PMF olamaz. PDF'in 1'den buyuk olabilmesi integrali bozmaz mi? Unutmayalim, integral hesabi yapiyoruz, noktasal degerlerin 1 olmasi tum 1'lerin toplandigi anlamina gelmez. Bakiniz *Entegralleri Nasil Dusunelim* yazimiz.

Tanim

X rasgele degiskeninin CDF'i  $F$  olsun. Ters CDF (inverse cdf), ya da ceyrek fonksiyonu (quantile function)

$$F^{-1}(q) = \inf \left\{ x : F(x) \leq q \right\}$$

ki  $q \in [0, 1]$ . Eger  $F$  kesinlikle artan ve surekli bir fonksiyon ise  $F^{-1}(q)$  tekil bir  $x$  sayisi ortaya cikarir, ki  $F(x) = q$ .

Eğer inf kavramını bilmiyorsak simdilik onu minimum olarak düşünebiliriz.

$F^{-1}(1/4)$  birinci çeyrek

$F^{-1}(1/2)$  medyan (median, ya da ikinci çeyrek),

$F^{-1}(3/4)$  üçüncü çeyrek

olarak bilinir.

İki rasgele değişken  $X$  ve  $Y$  dağılımsal olarak birbirine eşitliği, yani  $X \stackrel{d}{=} Y$  eğer  $F_X(x) = F_Y(x)$ ,  $\forall x$ . Bu  $X, Y$  birbirine eşit, birbirinin aynisi demek değildir. Bu değişkenler hakkındaki tüm olasılıksal işlemler, sonuçlar aynı olacak demektir.

Uyari! “ $X$ ’in dağılımı  $F$ ’tir” beyanını  $X \sim F$  şeklinde yazmak bir gelenek. Bu biraz kötü bir gelenek aslında çünkü  $\sim$  sembolü aynı zamanda yaklaşıksallık kavramını belirtmek için de kullanılıyor.

### Bernoulli Dağılımı

$X$ ’in bir yazı-tura atısını temsil ettiğini düşünelim. O zaman  $P(X = 1) = p$ , ve  $P(X = 0) = 1 - p$  olacaktır, ki  $p \in [0, 1]$  olmak üzere. O zaman  $X$ ’in dağılımı Bernoulli deriz, ve  $X \sim \text{Bernoulli}(p)$  diye gösteririz. Olasılık fonksiyonu  $f(x) = p^x(1 - p)^{(1-x)}$ ,  $x \in \{0, 1\}$ .

Yani  $x$  ya 0, ya da 1. Parametre  $p$ , 0 ile 1 arasındaki herhangi bir reel sayı.

Uyari!

$X$  bir rasgele değişken;  $x$  bu değişkenin alabileceği spesifik bir değer;  $p$  değeri ise bir **parametre**, yani sabit, önceden belirlenmiş reel sayı. Tabii istatistikî problemlerde (olasılık problemlerinin tersi olarak düşünürsek) çoğunlukla o sabit parametre bilinmez, onun veriden hesaplanması, kestirilmesi gerekir. Her halukarda, çoğu istatistikî modelde rasgele değişkenler vardır, ve onlardan ayrı olarak parametreler vardır. Bu iki kavramı birbiriyle karıştırmayalım.

### Düz (Uniform) Dağılım

$X$  düz,  $\text{Uniform}(a, b)$  olarak dağılmış deriz, ve bu  $X \sim \text{Uniform}(a, b)$  olarak yazılır eğer

$$f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \text{ için} \\ 0 & \text{diğerleri} \end{cases}$$

ise ve  $a < b$  olacak şekilde. CDF hesabi olasılık eğrisinin integralini temel alır, düz dağılım bir  $a, b$  arasında  $1/b - a$  yüksekliğinde bir dikdörtgen şeklinde olacağı için, bu dikdörtgendeki herhangi bir  $x$  noktasında CDF dağılımı, yani o  $x$ ’in başlayıp sol tarafın alanının hesabi basit bir dikdörtgensel alan hesabıdır, yani  $x - a$  ile  $1/b - a$ ’nin çarpımıdır, o zaman

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & x \in [a, b] \\ 1 & x > b \end{cases}$$

Normal (Gaussian) Dagilim

$X \sim N(\mu, \sigma^2)$  ve PDF

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}, x \in \mathbb{R}$$

ki  $\mu \in \mathbb{R}$  ve  $\sigma > 0$  olacak sekilde.

İleride gorecegiz ki  $\mu$  bu dagilimin “ortasi”, ve  $\sigma$  onun etrafa ne kadar “yay-ildigi” (spread). Normal dagilim olasilik ve istatistikte cok onemli bir rol oynar. Dogadaki pek cok olay yaklasiksal olarak Normal dagilima sahiptir. Sonra gorecegimiz uzere, mesela bir rasgele degiskenin degerlerinin toplami her zaman Normal dagilima yaklasir (Merkezi Limit Teorisi -Central Limit Theorem-).

Eger  $\mu = 0$  ve  $\sigma = 1$  ise  $X$ 'in standart Normal dagilim oldugunu soyleriz. Gele- nege gore standart Normal dagilim rasgele degiskeni  $Z$  ile gosterilmelidir, PDF ve CDF  $\phi(z)$  ve  $\Phi(z)$  olarak gosterilir.

$\Phi(z)$ 'nin kapali form (closed-form) tanimi yoktur. Bu, matematikte “analitik bir forma sahip degil” demektir, formulu bulunamamaktadır, bunun sebebi ise Normal PDF'in integralinin analitik olarak alinamiyor olusudur.

Bazi faydali puf noktaları

1. Eger  $X \sim N(\mu, \sigma^2)$  ise, o zaman  $Z = (X - \mu)/\sigma \sim N(0, 1)$ .
2. Eger  $Z \sim N(0, 1)$  ise, o zaman  $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$
3. Eger  $X_i \sim N(\mu_i, \sigma_i^2)$ ,  $i = 1, 2, \dots$  ve her  $X_i$  digerlerinden bagimsiz ise, o zaman

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Tekrar  $X \sim N(\mu, \sigma^2)$  alirsak ve 1. kuraldan devam edersek / temel alirsak su da dogru olacaktır.

$$P(a < X < b) = ?$$

$$= P\left(\frac{a - \mu}{\sigma} < \frac{X - \mu}{\sigma} < \frac{b - \mu}{\sigma}\right)$$

$$= P\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

İlk gecisi nasıl elde ettik? Bir olasılık ifadesi  $P(\cdot)$  içinde eşitliğin iki tarafına aynı anda aynı toplama, çıkarma operasyonlarını yapabiliriz.

Son ifadenin anlamı sudur. Eğer standart Normal'in CDF'ini hesaplayabiliyorsak, istediğimiz Normal olasılık hesabını yapabiliriz demektir, çünkü artık  $X$  içeren bir hesabın  $Z$ 'ye nasıl tercüme edildiğini görüyoruz.

Tüm istatistik yazılımları  $\Phi(z)$  ve  $\Phi(z)^{-1}$  hesabı için gerekli rutinlere sahiptir. Tüm istatistik kitaplarında  $\Phi(z)$ 'nin belli değerlerini taşıyan bir tablo vardır. Ders notlarımızın sonunda da benzer bir tabloyu bulabilirsiniz.

Örnek

$X \sim N(3, 5)$  ise  $P(X > 1)$  nedir? Cevap:

$$P(X > 1) = 1 - P(X < 1) = 1 - P\left(Z < \frac{1-3}{\sqrt{5}}\right) = 1 - \Phi(-0.8944) = .81$$

Soru tam  $P(a < X < b)$ , sadece  $b$  olduğu için yukarıdaki form ortaya çıktı.

Örnek

Şimdi öyle bir  $q$  bul ki  $P(X < q) = .2$  olsun. Yani  $\Phi^{-1}(.2)$ 'yi bul. Yine  $X \sim N(3, 5)$ .

Cevap

Demek ki tablodan .2 değerine tekabül eden esik değerini bulup, üstteki formül üzerinden geriye tercüme etmemiz gerekiyor. Normal tablosunda  $\Phi(-0.8416) = .2$ ,

$$.2 = P(X < q) = P\left(Z < \frac{q - \mu}{\sigma}\right) = \Phi\left(\frac{q - \mu}{\sigma}\right)$$

O zaman

$$-0.8416 = \frac{q - \mu}{\sigma} = \frac{q - 3}{\sqrt{5}}$$

$$q = 3 - 0.8416\sqrt{5} = 1.1181$$

$t$  (Student's  $t$ ) ve Cauchy Dağılımı

$X$ ,  $\nu$  derece bağımsızlıkta  $t$  dağılımına sahiptir, ki bu  $X \sim t_\nu$  diye yazılır eğer

$$f(x) = \frac{\Gamma(\nu+1)/2}{\sqrt{\nu\pi}\Gamma(\nu/2)} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}$$

$t$  dağılımı Normal dağılıma benzer ama daha kuyruğu daha kalındır. Aslında Normal dağılımı  $t$  dağılımının  $\nu = \infty$  olduğu hale tekabül eder. Cauchy dağılımı



da  $t$ 'nin özel bir halidir,  $v = 1$  halidir. Bu durumda yoğunluk fonksiyonu

$$f(x) = \frac{1}{\pi(1+x^2)}$$

Bu formül hakikaten bir yoğunluk mudur? Kontrol için entegralini alalım,

$$\int_{-\infty}^{\infty} f(x) dx = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{1+x^2}$$

Cogunlukla entegre edilen yerde "1 arti ya da eksi bir seyin karesi" turunde bir ifade gorulurse, yerine gecirme (subsitution) islemi trigonometrik olarak yapilir.

$$x = \tan \theta, \theta = \arctan x$$

$$1+x^2 = 1+\tan^2 \theta = \sec^2 \theta$$

$$dx/d\theta = \sec^2 \theta$$

O zaman

$$\begin{aligned} &= \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{1+x^2} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{1}{\sec^2 \theta} \sec^2 \theta d\theta = \frac{1}{\pi} \int_{-\infty}^{\infty} 1 d\theta = \\ &= \frac{1}{\pi} \theta|_{-\infty}^{\infty} = \frac{1}{\pi} [\arctan(\infty) - \arctan(-\infty)] \\ &= \frac{1}{\pi} \left[ \frac{\pi}{2} - \left( -\frac{\pi}{2} \right) \right] = 1 \end{aligned}$$

$\chi^2$  Dagilimi

$X$ 'in  $p$  derece serbestlige sahip bir  $\chi^2$  dagilima sahip ise  $X \sim \chi_p^2$  olarak gosterilir, yoğunluk

$$f(x) = \frac{1}{\Gamma(p/2)2^{p/2}} x^{(p/2)-1} e^{-x/2}, x > 0$$

Eger  $Z_1, \dots, Z_p$  bagimsiz standart Normal rasgele degiskenler ise,  $\sum_{i=1}^p Z_i^2 \sim \chi_p^2$  esitligi dogrudur.

İki Degiskenli Dagilimler

Tanim

Surekli ortamda  $(X, Y)$  rasgele degiskenleri icin yogunluk fonksiyonu  $f(x, y)$  tanimlanabilir eger i)  $f(x, y) > 0, \forall (x, y)$  ise, ve ii)  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$  ise ve her kume  $A \subset \mathbb{R} \times \mathbb{R}$  icin  $P((X, Y) \in A) = \int \int_A f(x, y) dx dy$ . Hem ayriksal hem surekli durumda birlesik (joint) CDF  $F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$  diye gosterilir.

Bu tanimda  $A$  kumesi olarak tanimlanan kavram uygulamalarda bir olaya (event) tekabul eder. Mesela

Ornek

$(X, Y)$ 'in birim kare uzerinde duz (uniform) olsun. O zaman

$$f(x, y) = \begin{cases} 1 & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \text{ ise} \\ 0 & \text{diger durumlarda} \end{cases}$$

$P(X < 1/2, Y < 1/2)$ 'yi bul.

Cevap

Burada verilen  $A = \{X < 1/2, Y < 1/2\}$  bir altkumedir ve bir olaydir. Olaylari boyle tanimlamamis miydik? Orneklem uzayinin bir altkumesi olay degil midir? O zaman  $f$ 'i verilen altkume uzerinden entegre edersek, sonuca ulasmis oluruz.

Ornek

Eger dagilim kare olmayan bir bolge uzerinden tanimliysa hesaplar biraz daha zorlasabilir.  $(X, Y)$  yogunlugu

$$f(x, y) = \begin{cases} cx^2y & \text{eger } x^2 \leq y \leq 1 \\ 0 & \text{digerleri} \end{cases}$$

Niye  $c$  bilinmiyor? Belki problemin modellemesi sirasinda bu bilinmez olarak ortaya cikmistir. Olabilir. Bu degeri hesaplayabiliriz, cunku  $f(x, y)$  yogunluk olmalı, ve yogunluk olmanin sarti  $f(x, y)$  entegre edilince sonucun 1 olmasi.

Once bir ek bilgi uretelim, eger  $x^2 \leq 1$  ise, o zaman  $-1 \leq x \leq 1$  demektir. Bu lazim cunku entegrale sinir degeri olarak verilecek.

$$\begin{aligned} 1 &= \int \int f(x, y) dy dx = c \int_{-1}^1 \int_{x^2}^1 x^2 y dy dx \\ &= c \int_{-1}^1 x^2 \int_{x^2}^1 y dy dx = \int_{-1}^1 x^2 \left( \frac{1}{2} - \frac{x^4}{2} \right) dx = 1 \\ &= c \int_{-1}^1 x^2 \left( \frac{1 - x^4}{2} \right) dx = 1 \end{aligned}$$

$$= \frac{c}{2} \int_{-1}^1 x^2 - x^6 dx = 1$$

Devam edersek  $c = 21/4$  buluruz.

Simdi, diyelim ki bizden  $P(X \geq Y)$ 'yi hesaplamamiz isteniyor. Bu hangi A bolgesine tekabul eder? Elimizdekiler

$$-1 \leq x \leq 1, x^2 \leq y, y \leq 1$$


Simdi bunlara bir de  $y \leq x$  eklememiz lazim. Yani ortadaki esitsizlige bir oge daha eklenir.

$$-1 \leq x \leq 1$$

$$x^2 \leq y \leq x$$

$$y \leq 1$$

$x^2 \leq y$ 'yi hayal etmek icin  $x^2 = y$ 'yi dusunelim, bu bir parabol olarak cizilebilir, ve parabolun ustunde kalanlar otomatik olarak  $x^2 \leq y$  olur, bu temel irdelemelerden biri.



Ayni sekilde  $y \leq x$  icin  $y = x$ 'i dusunelim, ki bu 45 derece aciyla cizilmis duz bir cizgi. Cizginin alti  $y \leq x$  olur. Bu iki bolgenin kesisimi yukaridaki resimdeki golgeli kisim.

Ek bir bolge sarti  $0 \leq x \leq 1$ . Bu sart resimde bariz goruluyor, ama cebirsel olarak bakarsak  $y \geq x^2$  oldugunu biliyoruz, o zaman  $y \geq 0$  cunku  $x^2$  muhakkak bir pozitif sayi olmalidir. Diger yandan  $x \geq y$  verilmiş, tum bunlari yanyana koyarsak  $x \geq 0$  sarti ortaya cikar.

Artik  $P(X \geq Y)$  hesabi icin haziriz,

$$P(X \geq Y) = \frac{21}{4} \int_0^1 \int_{x^2}^x x^2 y dy dx = \frac{21}{4} \int_0^1 x^2 \left[ \int_{x^2}^x y dy \right] dx$$

$$= \frac{21}{4} \int_0^1 x^2 \frac{x^2 - x^4}{2} dx = \frac{3}{20}$$

“Hafizasız” Dagilim, Ustel (Exponential) Dagilim

Ustel dagilimin hafizasız olduğu söylenir. Bunun ne anlama geldiğini anlatmaya uğrasalım. Diyelim ki rasgele değişken  $X$  bir aletin omrunu temsil ediyor, yani bir  $p(x)$  fonksiyonuna bir zaman “sordüğümüz” zaman bize dondurulan olasılık, o aletin  $x$  zamani kadar daha islemesinin olasılığı. Eğer  $p(2) = 0.2$  ise, aletin 2 yıl daha yaşamasının olasılığı 0.2.

Bu hafizasızlığı, olasılık matematiği ile nasıl temsil ederiz?

$$P(X > s + t | X > t) = P(X > s), \forall s, t \geq 0$$

Yani öyle bir dağılım var ki elimizde,  $X > t$  bilgisi veriliyor, ama (kalan) zamani hala  $P(X > s)$  olasılığı veriyor. Yani  $t$  kadar zaman geçtiği bilgisi hiçbir şeyi değiştirmiyor. Ne kadar zaman geçmiş olursa olsun, direkt  $s$  ile gidip aynı olasılık hesabını yapıyoruz.

Sartsal (conditional) formülünü uygularsak üstteki şöyle olur

$$\frac{P(X > s + t, X > t)}{P(X > t)} = P(X > s)$$

ya da

$$P(X > s + t, X > t) = P(X > s)P(X > t)$$

Bu son denklemin tatmin olması için  $X$  ne şekilde dağılmış olmalıdır? Üstteki denklem sadece  $X$  dağılım fonksiyonu ustel (exponential) olursa mümkündür, çünkü sadece o zaman

$$e^{-\lambda(s+t)} = e^{-\lambda s} e^{-\lambda t}$$

gibi bir ilişki kurulabilir.

Örnek

Diyelim ki bir bankadaki bekleme zamani ortalama 10 dakika ve ustel olarak dağılmış. Bir müşterinin i) bu bankada 15 dakika beklemesinin ihtimali nedir? ii) Bu müşterinin 10 dakika bekledikten sonra toplam olarak 15 dakika (ya da daha fazla) beklemesinin olasılığı nedir?

Cevap

i) Eğer  $X$  müşterinin bankada beklediği zamani temsil ediyorsa

$$P(X > 15) = e^{-15 \cdot 1/10} = e^{-3/2} \approx 0.223$$

ii) Sorunun bu kısmi müşteri 10 dakika gecirdikten sonra 5 dakika daha gecirmesinin olasılığını soruyor. Fakat üstel dağılım “hafızasız” olduğu için kalan zamanı alıp yine direkt aynı fonksiyona geçiyoruz,

$$P(X > 5) = e^{-5 \cdot 1/10} = e^{-1/2} \approx 0.60$$

Bilesen (Marginal) Dağılımlar

Süreklili rasgele değişkenler için bileşen yoğunluk

$$f_X(x) = \int f(x, y) dy$$

ve

$$f_Y(y) = \int f(x, y) dx$$

Üstteki integraller gerçek bir dağılım fonksiyonu  $f(x, y)$  verilince alt ve üst limitleri tanımlamak zorundadır. Çünkü bileşen yoğunluk için bir veya daha fazla değişkeni “integralle dışarı atmak (integrate out)” ettiğimiz söylenir, eğer ayrık-sal (discrete) ortamda olsaydık bu atılan değişkenin tüm değerlerini goze alarak toplama yapan bir formül yazardık. Sürekli ortamda integral kullanıyoruz, ama tüm değerlerin üzerinden yine bir şekilde geçmemiz gerekiyor. İşte alt ve üst limitler bunu gerçekleştiriyor. Bu alt ve üst limitler, atılan değişkenin “tüm değerlerine” bakması gerektiği için  $-\infty, +\infty$  olmalıdır. Eğer problem içinde değişkenin belli değerler arasında olduğu belirtilmiş ise (mesela alttaki örnekte  $x > 0$ ) o zaman entegral limitleri alt ve üst sınırını buna göre değiştirebilir.

Örnek

$f_{X,Y}(x, y) = e^{-(x+y)}$ , olsun ki  $x, y \geq 0$ . O zaman  $f_X(x)$

$$f_X(x) = e^{-x} \int_0^{\infty} e^{-y} dy = e^{-x} \cdot 1 = e^{-x}$$

Örnek

$$f(x, y) = \begin{cases} x + y & \text{eğer } 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{diğer} \end{cases}$$

$$f_Y(y) = \int_0^1 (x + y) dx = \int_0^1 x dx + \int_0^1 y dx = \frac{1}{2} + y$$

Tanim

İki rasgele degisken  $A, B$  bagimsizdir eger tum  $A, B$  degerleri icin

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

esitligi dogru ise. Bu durumda  $X \perp Y$  yazilir.

Teori

$X, Y$ 'nin birlesik PDF'i  $f_{X,Y}$  olsun. O zaman ve sadece  $f_{X,Y}(x, y) = f_X(x)f_Y(y)$  ise  $X \perp Y$  dogrudur.

Ornek

Diyelim ki  $X, Y$  bagimsiz, ve ikisinin de ayni yogunlugu var.

$$f(x) = \begin{cases} 2x & \text{eger } 0 \leq x \leq 1 \\ 0 & \text{digerleri} \end{cases}$$

$P(X + Y < 1)$ 'i hesaplayin.

Cevap

Bagimsizligi kullanarak birlesik dagilimi hesaplayabiliriz

$$f(x, y) = f_X(x)f_Y(y) = \begin{cases} 4xy & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{digerleri} \end{cases}$$

Simdi bu birlesik yogunluk uzerinden istedigimiz bolgeyi hesaplariz, bolgeyi tanımlayan  $X + Y \leq 1$  ifadesi.

$$P(X + Y \leq 1) = \iint_{x+y \leq 1} f(x, y) dy dx$$

Entegralin limiti ustteki hali sembolik, hesap icin bu yeterli degil, eger  $x + y \leq 1$  ise,  $y \leq 1 - x$  demektir, ve bolge  $y = 1 - x$  cizgisinin alti olarak kabul edilebilir.  $x, y$  zaten sifirdan buyuk olmalı, yani sola dogru yatık cizginin alti ve  $y, x$  eksenlerinin ustu kismini olusturan bir ucgen,

$$= \int_0^1 \int_0^{1-x} 4yx \, dy dx = 4 \int_0^1 x \left[ \int_0^{1-x} y \, dy \right] dx$$

Numaraya dikkat, hangi degisken uzerinden integral aldigimiza bakarak, onun haricindekileri sabit kabul ederek bu “sabitleri” integral disina atiyoruz, boylece isimizi kolaylastiriyoruz. Hesabi tamamlarsak,

$$4 \int_0^1 x \frac{(1-x)^2}{2} dx = \frac{1}{6}$$

Kosullu Dagilimler (Conditional Distributions)

Surekli rasgele degiskenler icin kosullu olasilik yogunluk fonksiyonlari

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

Devam edelim, eger kosullu yogunluk uzerinden olay hesabi yapmak istersek, ve  $f_Y(y) > 0$  oldugunu farzederek,

$$P(X \in A|Y = y) = \int_A f_{X|Y}(x|y) dx$$

Ornek

(1) sonucunu aldigimiz ornege donelim,

$$f(x,y) = \begin{cases} x+y & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{diger} \end{cases}$$

$P(X < 1/4|Y = 1/3)$  nedir?

Cevap

Ustteki olasilik hesabi icin  $f_{X|Y}$  fonksiyonuna ihtiyacimiz var. (1)'de gordugumu uzere,

$$f_Y(y) = \frac{1}{2} + y$$

Ana formulumuz neydi?

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

$$= \frac{x+y}{\frac{1}{2} + y}$$

$$P(X < 1/4|Y = 1/3) = \int_0^{1/4} \frac{x + \frac{1}{3}}{\frac{1}{2} + \frac{1}{3}} dx = \frac{\frac{1}{32} + \frac{1}{3}}{\frac{1}{2} + \frac{1}{3}} = \frac{14}{32}$$

Cok Degiskenli (Multivariate) Dagilimler ve IID Orneklemler (Samples)

$X = (X_1, \dots, X_n)$  olsun, ki  $(X_1, \dots, X_n)$ 'lerin herbiri bir rasgele degisken, o zaman  $X$ 'e rasgele vektor (random vector) ismi verilir.  $f(x_1, \dots, x_n)$ 'in PDF'i temsil ettigini dusunelim. Bu PDF'i baz alarak aynen iki degiskenli (bivariate) orneklerde oldugu gibi, benzer tekniklerle bilesenleri, kosullu dagilimleri, vs. hesaplamak mumkundur.

### Cok Degiskenli Normal

Tek degiskenli Normal dagilimin iki parametresi vardi,  $\mu, \sigma$ . Cok degiskenli formda  $\mu$  bir vektor,  $\sigma$  yerine ise  $\Sigma$  matrisi var. Once rasgele degiskeni tanımlayalım,

$$Z = \begin{bmatrix} Z_1 \\ \vdots \\ Z_k \end{bmatrix}$$

ki  $Z_1, \dots, Z_k \sim N(0, 1)$ .  $Z$ 'nin yogunlugu

$$\begin{aligned} f(z) &= \prod_{i=1}^k f(z_i) = \frac{1}{(2\pi)^{k/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^k z_j^2 \right\} \\ &= \frac{1}{(2\pi)^{k/2}} \exp \left\{ -\frac{1}{2} z^T z \right\} \end{aligned}$$

Bu durumda  $Z$ 'nin *standart* çok degiskenli Normal dagilima sahip oldugu soylenir, ve  $Z \sim N(0, I)$  olarak gosterilir. Buradaki 0 degeri icinde k tane sifir olan bir vektor olarak,  $I$  ise  $k \times k$  birim (identity) matrisi olarak anlasilmalidir.

Daha genel olarak bir vektor  $X$ 'in çok degiskenli Normal dagilimina sahip oldugunu soyleriz, ve bunu  $X \sim N(\mu, \Sigma)$  olarak gosteririz, eger dagilimin yogunlugu

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{k/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}$$

$\Sigma$  pozitif kesin (positive definite) bir matristir. Hatırlayalım, bir matris pozitif kesindir eger tum sifir olmayan  $x$  vektorleri icin  $x^T \Sigma x > 0$  ise.

Not: Karekok kavrami tekil sayılardan matrislere de aktarilabilir. Bir matris  $B$ 'nin  $A$ 'nin karekoku oldugu soylenir, eger  $B \cdot B = A$  ise.

Devam edersek, eger  $\Sigma$  pozitif kesin ise bir  $\Sigma^{1/2}$  matrisini oldugu gosterilebilir, ki bu matrise  $\Sigma$ 'nin karekoku ismi verilir, ve bu karekokun su ozellikleri vardir, (i)  $\Sigma^{1/2}$  simetriktir, (ii)  $\Sigma = \Sigma^{1/2} \Sigma^{1/2} = I$  ve  $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$ .

### Hatirlama Numarasi

Normal Dagilimin formulu bazen hatırlayamayabiliriz. Peki daha basit bir formolden baslayarak onu turetebilir miyiz? Bu mumkun. Daha once  $e^{-x^2}$  Nasil



Entegre Edilir? yazisinda

$$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$$

oldugunu gormustuk. Dikkat edersek bu integral bir formulun olasiliksal dagilim olup olmadigini kontrol etmek icin kullandigimiz integrale benziyor. Eger integral 1 cikarsa onun olasiliksal dagilim oldugunu biliyoruz. Ustteki sonuc  $\sqrt{\pi}$ , fakat iki tarafi  $\sqrt{\pi}$ 'ye bolerseniz, sag taraf 1 olur ve boylece solda bir dagilim elde ederiz. Yani

$$\int_{-\infty}^{+\infty} \frac{1}{\sqrt{\pi}} e^{-x^2} dx = 1$$

formulunde integralin sagindaki kisim bir dagilimdir. Bu formulu donusturerek Gaussian'a erisebiliriz. Ustteki formulun orta noktası (mean) sifir, varyansi (variance), yani  $\sigma^2 = 1/2$  (bunu da ezberlemek lazim ama o kadar dert degil). O zaman  $\sigma = 1/\sqrt{2}$ .

Ilk amacimiz  $\sigma = 1$ 'e erismek olsun (cunku oradan herhangi bir  $\sigma$ 'ya atlayabiliriz), bunun icin  $x$ 'i  $\sqrt{2}$ 'ye bolmek lazim, tabii ayni anda onun etkisini sifirlamak icin normalize eden sabiti dengelemek amaciyla  $\sqrt{2}$ 'ye bolmek lazim,

$$= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\left(\frac{x}{\sqrt{2}}\right)^2} dx$$

$\sigma = 1$ 'e erisince oradan herhangi bir  $\sigma$  icin,  $\sigma$  degiskenine bolelim, yine hem e ustune hem sabite bu eki yapalim,

$$= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\left(\frac{x}{\sqrt{2}\sigma}\right)^2} dx$$

Simdi herhangi bir ortalama  $\mu$  icin bu degiskeni formule sokalim, bunun icin  $\mu$ 'yu  $x$ 'den cikarmak yeterli

$$= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)^2} dx$$

e ustundeki kare alma islemini acarsak,

$$= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Boylece integral icindeki kisim tek boyutlu Gaussian formuna erismis oluyor.

## Beklenti (Expectation)

Bu deger, dagilim  $f(x)$ 'in tek sayilik bir ozetidir. Yani beklenti hesabina bir taraftan bir dagilim fonksiyonu girer, diger taraftan tek bir sayi disari cikar. Surekli dagilim fonksiyonlari icin  $E(X)$

$$E(X) = \int x f(x) dx$$

ayriksal durumda

$$E(X) = \sum_x x f(x)$$

olarak hesaplanir. Hesabin, her  $x$  degerini onun olasiligi ile carpip topladigina dikkat. Bu tur bir hesap dogal olarak tum  $x$ 'lerin ortalamasini verecektir, ve dolayli olarak dagilimin ortalamasini hesaplayacaktır. Ortalama  $\mu_x$  olarak ta gosterilebilir.

Notasyonel basitlik icin ustteki toplam / entegral yerine

$$= \int x dF(x)$$

diyecegiz, bu notasyonel bir kullanim sadece, unutmayalim, reel analizde  $\int x dF(x)$ 'in ozel bir anlami var (hoca tam diferansiyel  $dF$ 'den bahsediyor).

Beklentinin taniminin kapsamli / eksiksiz olmasi icin  $E(X)$ 'in “mevcudiyeti” icin de bir sart tanımlamak gerekir, bu sart soyle olsun,

$$\int_x |x| dF_X(x) < \infty$$

ise beklenti mevcut demektir. Tersi sozkonusu ise beklenti mevcut degildir.

Ornek

$X \sim \text{Unif}(-1, 3)$  olsun.  $E(X) = \int x dF(x) = \int x f_X(x) dx = \frac{1}{4} \int_{-1}^3 x dx = 1$ .

Ornek

Cauchy dagiliminin  $f_X(x) = \{\pi(1+x^2)\}^{-1}$  oldugunu soylemistik. Simdi beklentiyi hesaplayalim. Parcali entegral teknigi lazim,  $u = x$ ,  $dv = 1/(1+x^2)$  deriz, ve o zaman  $v = \tan^{-1}(x)$  olur, bkz *Ters Trigonometrik Formuller* yazimiz. Demek ki

$$\int |x| dF(x) = \frac{2}{\pi} \int_0^\infty \frac{x dx}{1+x^2}$$

2 nereden cikti? Cunku  $|x|$  kullaniyoruz, o zaman sinir degerlerinde sadece sifirin sagina bakip sonucu ikiyle carpmak yeterli. Bir sabit oldugu icin  $\pi$  ile beraber disari cikiyor. Simdi

$$\int u dv = uv - \int v du$$

uzerinden

$$= [x \tan^{-1}(x)]_0^{\infty} - \int_0^{\infty} \tan^{-1}(x) dx = \infty$$

Yani ustteki hesap sonsuzluga gider. O zaman ustteki tanimimiza gore Cauchy dagiliminin beklentisi yoktur.

Moment

Olasılık matematiğinde "moment üreten işlevler" olarak adlandırılan, başlangıçta pek yararlı gibi gözükmesede bir takım matematiksel özellikleri olduğu için, ispatlarda oldukça işe yarayan bir kavram vardır.

Her rasgele değişkenin bir dağılımı olduğunu biliyoruz. Her rasgele değişkenin de ayrıca bir moment üreten fonksiyonu da vardır. Ayrıca, moment üreten fonksiyon ile rasgele değişken arasında bire-bir olarak bir ilişki mevcuttur. "Bu neye yarar?" diye sorulabilir; Cevap olarak, mesela cebirsel olarak türete türete bir moment'e geldiğimiz düşünelim, ve tekrar başka bir taraftan, başka bir formülden gene türete türete tekrar aynı moment işlevine geliyorsak, bu demektir ki, iki taraftan gelen rasgele değişkenler (ve tekabül eden dağılımları) birbirine eşittir. Bazı şartlarda moment üreten işlevler ile cebir yapmak, dağılım fonksiyonlarından daha rahat olmaktadır.

Her rasgele değişken için, moment üreten işlev şöyle bulunur.

X rasgele degiskenin moment ureten operasyonu

$M(t) = E(e^{tx})$  olarak gosterilir

Ayriksal operasyonlar icin

$$M(t) = \sum_x e^{tx} p(x)$$

Surekli islevler icin

$$M(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

Kuram

Gelelim yazımızın esas konusu olan kuramımıza.

Eğer  $X_1, X_2, \dots, X_n$  bağımsız rasgele değişken ise, ve her değişkenin  $M_i(t)$   $i = 1, 2, 3, \dots, n$  olarak, öz olarak aynı olan birer moment üreten işlevi var ise, o zaman,

$$Y = \sum_{i=1}^n a_i X_i$$

acilimi

$$M_y(t) = \prod_{i=1}^n M(a_i t)$$

olacaktır.

İspat

$$M_y(t) = E(e^{tY}) = E(e^{t(a_1 X_1 + a_2 X_2 + \dots + a_n X_n)})$$

$$= E[\exp(ta_1 X_1 + ta_2 X_2 + \dots + ta_n X_n)]$$

$$= E[\exp(ta_1 X_1) + \exp(ta_2 X_2) + \dots + \exp(ta_n X_n)]$$

$$= E[\exp(ta_1 X_1)] + E[\exp(ta_2 X_2)] + \dots + E[\exp(ta_n X_n)]$$

Daha önce belirttiğimiz gibi

$$M_i(t) = E[\exp(tX_i)]$$

olduğuna göre ve  $t$  yerine  $ta_i$  koyulduğunu düşünelim

$$M_y(t) = \prod_{i=1}^n M_y(a_i t)$$

olacaktır.

Bunu  $M_y(t) = (M_i(a_i t))^n$  şeklinde de gösterebiliriz. Ortalama (Mean) ve Medyan (Median)

Özet İstatistikleri

Genellikle istatistik kitapları hemen ortalama (mean), medyan (median) ve bağlantılı özet istatistiklerinden (summary statistics) bahsederek işe girerler. Bu istatistikleri dikkatle kullanmak gerekir, çünkü her türlü veri, her yerde geçerli değildirler. Mesela ortalama sadece tek merkezi bir tepesi olan (unimodal) dağılımlar için geçerlidir. Eğer bu temel varsayım geçerli değilse, ortalama kullanarak yapılan hesaplar bizi yanlış yollara götürür. Ayrıca bir dağılımı simetrik olup olmadığı da ortalama ya da medyan kullanılıp kullanılmaması kararında önemlidir. Eğer simetrik, tek tepeli bir dağılım var ise, ortalama ve medyan birbirine yakın olacaktır. Fakat veri başka türde bir dağılım ise, o zaman bu iki ölçüt birbirinden çok farklı olabilir.

Önce ortalama ve standart sapmayı (standart deviation) görelim.

$$\bar{x} = \frac{1}{n} \sum_i x_i$$

Standart sapma veri noktalarının "ortalamadan farkının ortalamasını" verir. Tabii bazen noktalar ortalamadan altında, bazen üstünde olacaktır, bizi bu negatiflik, pozitiflik ilgilendirmez, biz sadece farkla ilgiliz. O yüzden her sapmanın karesini alırız, bunları toplayıp nokta sayısına böleriz.

$$s^2 = \frac{1}{n} \sum_i (x_i - \bar{x})^2$$

Eğer  $\bar{x}$  tanımını üstte yerine koyarsak,

$$\begin{aligned} &= \frac{1}{n} \sum_i x_i^2 + \frac{1}{n} \sum_i \bar{x}^2 - \frac{2}{n} \sum_i x_i \bar{x} \\ &= \frac{1}{n} \sum_i x_i^2 + \frac{\bar{x}^2 n}{n} - \frac{2n\bar{x}}{n} \bar{x} \\ &= \frac{1}{n} \sum_i x_i^2 + \bar{x}^2 - 2\bar{x}^2 \\ &= \frac{1}{n} \sum_i x_i^2 - \bar{x}^2 \end{aligned}$$

Bu ölçüye varyans (variance) denir ve teorik olarak ortalamadan daha önemli olduğu söylenebilir. Fakat dağılımın yayılma ölçüsü olarak biz bu ölçüyü olduğu gibi değil, onun karesini kullanacağız (ki standart sapma buna deniyor aslında). Niye? Çünkü o zaman veri noktalarının ve yayılma ölçüsünün birimleri birbiri ile aynı olacak. Eğer veri setimiz bir alışveriş sepetindeki malzemelerin lira cinsinden değerleri olsaydı, varyans bize sonucu "karekok lira" olarak verecekti ve bunun pek anlamı olmayacaktı.


## Medyan ve Yuzdelikler (Percentile)

Ustteki hesaplar sayilari toplayip, bolmek uzerinden yapildi. Medyan ve diger yuzdeliklerin hesabi (ki medyan 50. yuzdelige tekabul eder) icin eldeki tum degerleri "siraya dizmemiz" ve sonra 50. yuzdelik icin ortadakine bakmamiz gerekiyor. Mesela eger ilk 5. yuzdeligi ariyorsak ve elimizde 80 tane deger var ise, bastan 4. sayiya / vektor hucresine / ogeye bakmamiz gerekiyor. Eger 100 eleman var ise, 5. sayiya bakmamiz gerekiyor, vs.

Bu siraya dizme islemi kritik. Kiyasla ortalama hesabi hangi sirada olursa olsun, sayilari birbirine topluyor ve sonra boluyor. Zaten ortalama ve sapmanin istatistikte daha cok kullanilmasinin tarihi sebebi de aslinda bu; bilgisayar oncesi cagda sayilari siralamak (sorting) zor bir isti. Bu sebeple hangi sirada olursa olsun, toplayip, bolerek hesaplanabilecek ozetler daha makbuldu. Fakat artik siralama islemi kolay, ve veri setleri her zaman tek tepeli, simetrik olmayabiliyor.

Ornek veri seti olarak unlu `dellstore2` tabanindaki satis miktarlari kullanirsak,

```
data = np.loadtxt("dell.csv")
plt.hist(data, 40)
plt.savefig('05_02.png')
```



```
print np.mean(data)
213.948899167

print np.median(data)
214.06

print np.std(data)
125.118481954

print np.mean(data)+2*np.std(data)
464.185863074
```

```
print np.percentile(data, 95)
```

```
410.4115
```

Goruldugu gibi uc nokta hesabi icin ortalamadan iki sapma otesini kullanirsak, 464.18, fakat 95. yuzdeligi kullanirsak 410.41 elde ediyoruz. Niye? Sebep ortalamanin kendisi hesaplanirken cok uc degerlerin toplama dahil edilmis olmasi ve bu durum, ortalamanin kendisini daha buyuk seviyeye dogru itiyor. Yuzdelik hesabi ise sadece sayilari siralayip belli bazi elemanlari otomatik olarak uc nokta olarak addediyor.

### Box Whisker Grafikleri


Tek boyutlu bir verinin dagilimini gormek icin Box ve Whisker grafikleri faydali araclardir; medyan (median), dagilimin genisligini ve siradisi noktalar (outliers) acik sekilde gosterirler. Isim nereden geliyor? Box yani kutu, dagilimin agirliginin nerede oldugunu gosterir, medyanin sagindada ve solunda olmak uzere iki ceyregin arasindaki kisimdir, kutu olarak resmedilir. Whiskers kedilerin biyiklerine verilen isimdir, zaten grafikte birazcik biyik gibi duruyorlar. Bu uzantilar medyan noktasindan her iki yana kutunun iki kati kadar uzatilir sonra verideki "ondan az olan en buyuk" noktaya kadar geri cekilir. Tum bunlari disinda kalan veri ise teker teker nokta olarak grafikte basilir. Bunlar siradisi (outlier) olduklari icin daha az olacaklari tahmin edilir.

BW grafikleri iki veriyi dagilimsal olarak karsilastirmak icin birebirdir. Mesela Larsen and Marx adli arastirmacilar cok az veri iceren Quintus Curtius Snodgrass veri setinin degisik oldugunu ispatlamak icin bir suru hesap yapmislardir, bir suru matematiksel isleme girmislerdir, fakat basit bir BW grafigi iki setin farklilikini hemen gosterir.

BW grafikleri iki veriyi dagilimsal olarak karsilastirmak icin birebirdir. Mesela Larsen and Marx adli arastirmacilar cok az veri iceren Quintus Curtius Snodgrass veri setinin degisik oldugunu ispatlamak icin bir suru hesap yapmislardir, bir suru matematiksel isleme girmislerdir, fakat basit bir BW grafigi iki setin farklilikini hemen gosterir.

### Python uzerinde basit bir BW grafigi

```
spread= rand(50) * 100
center = ones(25) * 50
flier_high = rand(10) * 100 + 100
flier_low = rand(10) * -100
data =concatenate((spread, center, flier_high, flier_low), 0)
plt.boxplot(data)
plt.savefig('05_03.png')
```



Bir diger ornek Glass veri seti uzerinde

```
data = loadtxt("glass.data", delimiter=",")
head = data[data[:,10]==7]
tableware = data[data[:,10]==6]
containers = data[data[:,10]==5]
```

```
print head[:,1]
```


```
data =(containers[:,1], tableware[:,1], head[:,1])
```

```
plt.yticks([1, 2, 3], ['containers', 'tableware', 'head'])
```

```
plt.boxplot(data,0,'rs',0,0.75)
```

```
plt.savefig('05_04.png')
```

```
[ 1.51131  1.51838  1.52315  1.52247  1.52365  1.51613  1.51602  1.51623
 1.51719  1.51683  1.51545  1.51556  1.51727  1.51531  1.51609  1.51508
 1.51653  1.51514  1.51658  1.51617  1.51732  1.51645  1.51831  1.5164
 1.51623  1.51685  1.52065  1.51651  1.51711]
```



Güven Aralığı (Confidence Intervals)

Bu kavram istatistikte tartışılan konulardan biri. Bayes ve Frekansçı (Frequentist) istatistik arasındaki felsefi farklılıklardan biri burada ortaya çıkıyor. Frekansçı



tanım soyledir:

"Bir parametre  $\theta$  için  $1 - \alpha$  seviyesinde bir  $C_n = (a, b)$  guven araligi tanimlanabilir – bu aralik  $a = a(X_1, \dots, X_n)$  ve  $b = b(X_1, \dots, X_n)$  adli iki fonksiyon uzerinden tanimlanabilir. Bu fonksiyonlar veri uzerinde isleyen, *verinin* fonksiyonlaridir, ve sonucta

$$\mathbb{P}_\theta(\theta \in C_n) \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

Yani  $(a, b)$  araligi  $1 - \alpha$  olasiliginda  $\theta$  'yi icine alir / hapseder.

Daha detayli olarak deney arka arkaya pek cok kez tekrarlandiginda parametrenin tahmininin  $1 - \alpha$  oraninda tanimlanan araliga dusecegi soylenir.  $1 - \alpha$  sayisina guven araliginin kapsamı (coverage) ismi de verilir. Genellikle insanlar yuzde 95 guven araligini kullanirlar, ve bu yuzdeye tekabul eden  $\alpha = 0.05$  rakami kullanilir.

Uzerine basarak belirtmek gerekir ki  $C_n$  rasgele (random) bir degerdir, ama  $\theta$  sabittir, cunku  $C_n$  verinin bir fonksiyonudur, ve veriden, yani bir orneklemden gelecegi icin o da rasgele olmalidir.

Eger  $\theta$  bir vektor ise o zaman bir aralik yerine bir guven kumesi kullanilir (mesela bir kure, ya da elips)."

Fakat frekansci yaklasimda aralik fonksiyonlari  $a, b$  ile guven araligi arasindaki baglanti net degildir. Hangi fonksiyon secimi hangi  $\alpha$ 'ya sebebiye vermektedir? Bu durum net oldugu durumlarda bile teorik olarak saglamligi suphelidir, ayrica hesabin sozel olarak ortaya konmasinda bazi eksikler vardir. "Deney arka arkaya pek cok kez tekrarlandiginda parametrenin tahmini,  $1 - \alpha$  guven araliga dusecektir" ibaresi mesela; "deney tekrari" her durumda gecerli olmayabilir. Meteoroloji "yarin yuzde 80 ihtimali ile yagmur yagacak" diyorsa, o hesap sartlarinin bir daha ortaya cikmasinin olasiligi cok dusuktur, Kaos Teorisi bize en azindan bunu soyluyor.

Wiki sayfasinda [1] tartismanin boyutlari gorulebilir.

Son onyillarda ortaya cikan yaklasim ise Bayes Teorisini devreye sokmak. Bir guven araligi tanimlamanin en saglam yolu bu hesabi bir dagilimi baz alarak yapmak. Eger sonuc olarak bir tekil sayi degil, bir dagilim elde edersek bu dagilim uzerinde guvenlik hesaplarini yapmak cok kolay hale gelir. Mesela sonuc (sonsal dagilim) bir Gaussian dagilim ise, bu dagilimin yuzde 95 agirliginin nerede oldugu, ve nasil hesaplandigi bellidir.

Bayes Teorisi

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Veri analizi baglaminda diyelim ki deneyler yaparak tahmini olarak hesapla-

mak (estimate) istedigimiz bir parametre var, bu bir protonun kutlesi ya da bir ameliyat sonrasi hayatta kalma orani olabilir. Bu durumlarda iki ayri "olaydan" bahsetmemiz gerekir, B olayi spesifik bazi olcumlerin elde edilmesi "olayidir", mesela olcum uc sayidan olusuyorsa, biz bir olcumde spesifik olarak {0.2, 4, 5.4} degerlerini elde etmisiz. Ikinci olay bilmedigimiz parametrenin belli bir degere sahip olmasi olacak. O zaman Bayes Teorisinin su sekilde tekrar yazabiliriz,

$$P(\text{parametre}|\text{veri}) \propto P(\text{data}|\text{parametre})P(\text{parametre})$$

$\propto$  isareti orantili olmak (proportional to) anlamina geliyor. Boleni attik cunku o bir sabit (tamamen veriye bagli, tahmini hesaplamak istedigimiz parametreye bagli degil). Tabii bu durumda sol ve sag taraf birbirine esit olmaz, o yuzden esitlik yerine orantili olmak isaretini kullandik. Bu cercevede "belli bir numerik sabit cercevesinde birbirine esit (equal within a numeric constant)" gibi cumleler de gorulebilir.

Ornek

Diyelim ki bir bozuk para ile 10 kere yazi-tura attik, ve sonuc altta

T H H H H T T H H H

Bu veriye bakarak paranin hileli olup olmadigini anlamaya calisacagiz. Bayes ifadesini bu veriye gore yazalim,


$$P(p|\{T H H H H T T H H H\}) \propto P(\{T H H H H T T H H H|p\})P(p)$$

$P(p)$  ifadesi ne anlama gelir? Aslinda bu ifadeyi  $P([Dagilim] = p)$  olarak gormek daha iyi, artik  $p$  parametresini bir dagilimdan gelen bir tekil deger olarak gordugumuze gore, o dagilimin belli bir  $p$ 'ye esit oldugu zamani modelliyoruz burada. Her halukarda  $P(p)$  dagilimini, yani onsel (prior) olasiligi bilmiyoruz, hesaptan once her degerin mumkun oldugunu biliyoruz, o zaman bu onsel dagilimi duz (flat) olarak aliriz, yani  $P(p) = 1$ .

$P(\{T H H H H T T H H H|p\})$  ifadesi goz korkutucu olabilir, ama buradaki her ogenin bagimsiz ozdesce dagilmis (independent identically distributed) oldugunu gorursek, ama bu ifadeyi ayri ayri  $P(\{T|p\})$  ve  $P(\{H|p\})$  carpimlari olarak gorebiliriz.  $P(\{T|p\}) = p$  ve  $P(\{H|p\}) = 1 - p$  oldugunu biliyoruz. O zaman

$$P(p|\{7 \text{ Tura}, 3 \text{ Yazı}\}) \propto p^7(1 - p)^3$$

Grafiklersek,



Boylece  $p$  için bir sonsal (posterior) dağılım elde ettik. Artık bu dağılımın yüzde 95 ağırlığının nerede olduğunu rahatca görebiliriz / hesaplayabiliriz. Dağılımın tepe noktasının  $p = 0.7$  civarında olduğu görülüyor. Bir dağılımla daha fazlasını yapmak da mümkün, mesela bu fonksiyonu  $p$ 'ye bağlı başka bir fonksiyona karşı entegre etmek mümkün, mesela beklentiyi bu şekilde hesaplayabiliriz.

Onsel dağılımın her noktaya eşit ağırlık veren bir örnek (uniform) seçilmiş olması, yani problemi çözmeye sıfır bilgidan başlamış olmamız, yöntemin bir zayıflığı olarak görülmemeli. Yöntemin kuvveti elimizdeki bilgiyle başlayıp onu net bir şekilde veri ve olurluk üzerinden sonsal tek dağılıma götürebilmesi. Başlangıç ve sonuç arasındaki bağlantı gayet net. Fazlası da var; ilgilendığımız alanı (domain) öğrendikçe, basta hiç bilmediğimiz onsel dağılımı daha net, bilgili bir şekilde seçebiliriz ve bu sonsal dağılımı da daha olması gereken modele daha yaklaştırabilir.

### Gaussian Kontrolü

Diyelim ki Gaussian dağılımına sahip olduğunu düşündüğümüz  $\{x_i\}$  verilerimiz var. Bu verilerin Gaussian dağılımına uyup uymadığını nasıl kontrol edeceğiz? Normal bir dağılımın her veri noktası için şöyle temsil edebiliriz,

$$y_i = \Phi\left(\frac{x_i - \mu}{\sigma}\right)$$

Burada  $\Phi$  standart Gaussian'ı temsil ediyor (detaylar için \*İstatistik Ders 1\*) ve CDF fonksiyonuna tekabül ediyor. CDF fonksiyonunun aynı zamanda ceyregi (quantile) hesapladığı söylenir, aslında CDF son derece detaylı bir olasılık değeri verir fakat evet, dolaylı yoldan noktanın hangi ceyrek içine düştüğü de görülecektir.

Şimdi bir numara yapalım, iki tarafa ters Gaussian formülünü uygulayalım, yani  $\Phi^{-1}$ .

$$\Phi^{-1}(y_i) = \Phi^{-1}\left(\Phi\left(\frac{x_i - \mu}{\sigma}\right)\right)$$

$$\Phi^{-1}(y_i) = \frac{x_i - \mu}{\sigma}$$

$$x_i = \Phi^{-1}(y_i)\sigma + \mu$$

Bu demektir ki elimizdeki verileri  $\Phi^{-1}(y_i)$  bazında grafiklersek, bu noktalar eğimi  $\sigma$ , başlangıcı (intercept)  $\mu$  olan bir düz çizgi olmalıdır. Eğer kabaca noktalar düz çizgi oluşturmuyorsa, verimizin Gaussian dağılıma sahip olmadığına karar verebiliriz.

Ustte tarif edilen grafik, olasılık grafiği (probability plot) olarak bilinir.

Ters Gaussian teorik fonksiyonunu burada vermeyeceğiz, Scipy `scipy.stats.invgauss` hesaplar için kullanılabilir. Fakat  $y_i$ 'nin kendisi nereden geliyor? Eğer  $y_i$ , CDF'in bir sonucu ise, pur veriye bakarak bir CDF değeri de hesaplayabilmemiz gerekir. Bunu yapmak için bir başka numara lazım.

1. Eldeki sayıları artan şekilde sıralayın
2. Her veri noktasına bir derece (rank) atayın (sıralama sonrası hangi seviyede olduğu yeterli, 1'den başlayarak).
3. Çeyrek değeri  $y_i$  bu sıra /  $n + 1$ ,  $n$  eldeki verinin büyüklüğü.

Bu teknik niye isliyor?  $x$ 'in CDF'i  $x_i < x$  şartına uyan  $x_i$ 'lerin oranı değil midir? Yani bir sıralama söz konusu ve üstteki teknik te bu sıralamayı biz elle yapmış olduk, ve bu sıralamadan gereken bilgiyi aldık.

### Moment Fonksiyonları

Olasılık matematiğinde "moment üreten işlevler" olarak adlandırılan, başlangıçta pek yararlı gibi gözükmesede bir takım matematiksel özellikleri olduğu için, ispatlarda oldukça işe yarayan bir kavram vardır.

Her rasgele değişkenin bir dağılımı olduğunu biliyoruz. Her rasgele değişkenin de ayrıca bir moment üreten fonksiyonu da vardır. Ayrıca, moment üreten fonksiyon ile rasgele değişken arasında bire-bir olarak bir ilişki mevcuttur. "Bu neye yarar?" diye sorulabilir; Cevap olarak, mesela cebirsel olarak türete türete bir moment'e geldiğimiz düşünelim, ve tekrar başka bir taraftan, başka bir formülden gene türete türete tekrar aynı moment işlevine geliyorsak, bu demektir ki, iki taraftan gelen rasgele değişkenler (ve tekabül eden dağılımları) birbirine eşittir. Bazı şartlarda moment üreten işlevler ile cebir yapmak, dağılım fonksiyonlarından daha rahat olmaktadır.

Her rasgele değişken için, moment üreten işlev şöyle bulunur.

X rasgele değişkeninin moment üreten operasyonu

$M(t) = E(e^{tX})$  olarak gösterilir

Ayriksal operasyonlar için

$$M(t) = \sum_x e^{tx} p(x)$$

Surekli islevler icin

$$M(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

Kuram

Gelelim yazımızın esas konusu olan kuramımıza.

Eğer  $X_1, X_2, \dots, X_n$  bağımsız rasgele değişken ise, ve her değişkenin  $M_i(t)$   $i = 1, 2, 3, \dots, n$  olarak, öz olarak aynı olan birer moment üreten işlevi var ise, o zaman,

$$Y = \sum_{i=1}^n a_i X_i$$

acilimi

$$M_y(t) = \prod_{i=1}^n M(a_i t)$$

olacaktır.

Ispat

$$M_y(t) = E(e^{tY}) = E(e^{t(a_1 X_1 + a_2 X_2 + \dots + a_n X_n)})$$

$$= E[\exp(ta_1 X_1 + ta_2 X_2 + \dots + ta_n X_n)]$$

$$= E[\exp(ta_1 X_1) + \exp(ta_2 X_2) + \dots + \exp(ta_n X_n)]$$

$$= E[\exp(ta_1 X_1)] + E[\exp(ta_2 X_2)] + \dots + E[\exp(ta_n X_n)]$$

Daha once belirttigimiz gibi

$$M_i(t) = E[\exp(tX_i)]$$

olduguna gore ve  $t$  yerine  $ta_i$  koyuldugunu dusunelim

$$M_y(t) = \prod_{i=1}^n M_y(a_i t)$$

olacaktır.

Bunu  $M_y(t) = (M_i(a_i t))^n$  şeklinde de gösterebiliriz.

### Orneklem Dağılımları (Sampling Distributions)

Diyelim ki elimizde (hakkında) öğrenmek istediğimiz bir sayısal obek (population) var. Bu obekteki her elemanı ayrı ayrı incelemek istemiyoruz, problem değil, nüfustan bir örneklem (sample) alırız. Eğer bu örneklem nüfusu yeterince iyi temsil ediyorsa, problem çıkmaz. Bu temsiliyeti garantilemenin iyi bir yolu örneklemi rasgele yapmaktır.

Şimdi, diyelim ki, bu örneklemi bir şekilde özetlemek istiyoruz yani örneklem verisi kullanılarak hesaplanmış temsili bir istatistik (descriptive statistic) elde edeceğiz.

Fakat örneklemimiz rasgele idi. Bu istatistikimiz (ki o da sonuçta bir rasgele değiskendir ve onun da bir dağılımı vardır), nasıl bir dağılıma sahiptir? Yani nüfus dağılımı (population distribution), ve örneklem dağılımının (sampling distribution) birbiriyle bağlantısıyla ilgileniyoruz.

#### Teori

Eğer  $X_1, \dots, X_n$  bir  $N(\mu, \sigma)$  dağılımında alınmış örneklem olsun. O zaman örneklem ortalamasının dağılımı  $N(\mu, \sigma/\sqrt{n})$ .

[TBD - İspat]

#### Teori

Eğer  $X_1, \dots, X_n$  bir  $N(\mu, \sigma)$  dağılımında alınmış örneklem olsun. O zaman şu büyüklük

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

$t_{n-1}$  dağılımına, yani  $n - 1$  serbestlik derecesindeki (degree of freedom) bir Student's t Dağılımıdır.

[TBD - İspat]

### Büyük Sayılar Kanunu

Olasılık kuramında önemli matematiksel bir denklem, büyük sayılar kanunudur. Bu kanun, tahmini olarak bildiğimiz günlük bir gerçeğin matematiksel ispatıdır da denebilir.

Yazı-tura atarken yazı çıkma ihtimalinin  $1/2$  olduğunu biliyoruz. Herhalde çoğumuz da bu yazı-tura işleminin "bir çok kere" tekrarlandığı durumda, toplam sonucun

aşağı yukarı "yarısının" yazı olacağını tahmin biliyoruz. Bu tahminin matematiksel olarak söylemi, büyük sayılar kanunudur. Yıllarca önce Öklid'in geometriyi ispat ederek yaptığı gibi, matematiğe eklediğimizi her yeni bilgi dağarcığını önce matematiksel olarak ispatlamamız gerekiyor.

Farzedelim ki her yazı-tura atışı bir deney olsun. Her ayrı deneyin sonucu  $X_1, X_2, \dots, X_n$  olarak rasgelen değişkenlerle tanımlanmış olsun. Bu değişkenler ya 1 ya da 0 değeri taşıyacak, Yazı=1, Tura=0 olmak üzere.

Buna göre, n tane deneyden sonra elimize gelmesi gereken yazı oranı şudur.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Büyük sayılar kanunu, n büyüdükçe  $\bar{X}_n$ 'in 1/2'ye yaklaştığını ispatlar.

Başlayalım.

$X_1, X_2, \dots, X_n$  bağımsız değişkenler olsun.

$$E(X_i) = \mu$$

$$\text{Var}(X_i) = \sigma$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

O zaman her  $\epsilon > 0$  için ve  $n \rightarrow \infty$ ,  $p(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$ .

Bu tanımlara göre, her rasgele değişkenin (deneyin) ortalaması aynı değerdir diyoruz. Bu zaten beklenir bir tanımdı, çünkü her rasgele değişkenin dağılımının aynı olduğunu kabul etmiştik. Her yazı tura aynı şartlar altında atılmazlar mı?

$\bar{X}_n$  de bir rasgele değişkendir, çünkü Büyük sayılar kanununu, matematiksel olarak,  $\bar{X}_n$  değişkeninin ortalamasını tekil olarak her  $X_i$  dağılımının (aynı olan) ortalaması arasında birkü onun da formülü başka rasgelen değişkenlere dayanıyor.

İspat devam etmek için, şapkalı  $X_n$  dağılımının beklentisini bulmamız gerekiyor.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

E dogrusal bir islec (linear operator) oldugu icin disaridan iceri dogru nufuz eder.

$$\begin{aligned} &= \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu \\ &= \mu \end{aligned}$$

$\bar{X}_n$  dağılımının standart sapmasını da bulalım.

Diger bir olasilik kuramina gore

$$Y = a + bX$$

$$\text{Var}(Y) = b^2 \text{Var}(X)$$

oldugunu biliyoruz. O zaman,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$$

Artık Çebişev kuramını kullanmaya hazırız.

$n \rightarrow \infty$ ,

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Cebisev'den

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2}$$

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$$

$\sigma^2/n\epsilon^2$ 'in sifira gitmesi normal cunku n sonsuza gidiyor.

Peki  $P(|\bar{X}_n - \mu| > \epsilon)$ 'nin sifira gittigini gosterdik mi?



$\sigma^2/n\epsilon^2$ 'nin sifira gittigini gosterdik.  $\sigma^2/n\epsilon^2$  de  $P(|\bar{X}_n - \mu| > \epsilon)$ 'den buyuk olduguna gore, demek ki o da sifira iner.

### Çebişev Eşitsizliği

Olasılık matematiğinde, büyük sayılar kuramı adında anılan ve olasılık matematiğinin belkemiğini oluşturan kuramı ispatlamak için, diğer bir kuram olan Çebişev eşitsizliğini de anlamamız gerekiyor. Çebişev eşitsizliği bir rasgele değişken, onun ortalaması (beklentisi) ve herhangi bir sabit sayı arasındaki üçlü arasında bir 'eşitsizlik' bağlantısı kurar, ve bu bağlantı diğer olasılık işlemlerimizde ispat verisi olarak işimize yarar.

Teori: Herhangi bir  $t$  değeri için,

$$P(|X - \mu| > t) \leq \frac{\sigma^2}{t^2}$$

İspata başlayalım. Entegral ile olasılık hesabı yapmak için bize bir  $x$  uzayı lazım.

$$R = x : |x - \mu| > t$$

Yani  $R$  uzayı,  $x$  ile ortalamasının farkının,  $t$ 'den büyük olduğu bütün sayıların kümesidir.

O zaman,

$$P(|X - \mu| > t) = \int_R f(x) dx$$

Dikkat edelim  $P(\cdot)$  içindeki formül, küme tanımı ile aynı. O yüzden  $P(\cdot)$  hesabı ortada daha olmayan, ama varolduğu kesin bir dağılım fonksiyonu tanımlamış da oluyor. Buna  $f(x)$  deriz.  $P(\cdot)$ 'in,  $f(x)$  fonksiyonunun  $R$  üzerinden entegral olduğunu olasılığa giriş dersinden bilmemiz lazım.

Eğer  $x \in R$  dersek o zaman

$$\frac{|x - \mu|^2}{t^2} \geq 1$$

$t$ 'nin denkleme bu şekilde nereden geldiği şaşkınlık yaratabilir. Daha önce tanımlanan şu ibareye dikkat edelim,  $x : |x - \mu| > t$  diye belirtmiştik. Bu ifadeyi değiştirerek, yukarıdaki denkleme gelebiliriz.

Devam edersek, elimizdeki 1'den büyük bir değer var. Bu değeri kullanarak, aşağıdaki tanımı yapmamız doğru olacaktır.

$$\int_R f(x) dx \leq \int_R \frac{(x - \mu)^2}{t^2} f(x) dx \leq \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

Ortadaki integral niye birinci integralden büyük? Çünkü ortadaki integraldeki  $F(x)dx$  ibaresinden önce gelen kısmın, her zaman 1'den büyük olacağını belirttiğimize göre, ikinci integralin birinciden büyük olması normaldir.

Evet...Üçüncü integral ispata oldukça yaklaştı aslında. Standart sapma işaretini hala ortada göremiyoruz, fakat son integraldeki ibare standart sapma değerini zaten içeriyor. Önce daha önceki olasılık matematiği bilgimize dayanarak, standart sapmanın tanımını yazıyoruz. Dikkat edelim, bu ibare şu anki ispatımız dahilinden değil, haricinden önceki bilgimize dayanarak geldi. Standart sapmanın tanımı şöyledir.

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

O zaman

$$\frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

yani

$$\int_{\mathbb{R}} f(x) dx \leq \frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

ki  $\int_{\mathbb{R}} f(x) dx$  zaten  $P(|X - \mu| > t)$  olarak tanımlanmıstı.

Kaynaklar

[1] [http://en.wikipedia.org/wiki/Confidence\\_interval](http://en.wikipedia.org/wiki/Confidence_interval)

[2] Janert, P., Data Analysis with Open Source Tools

[3] Introduction to Probability Models, Sheldon Ross, 8th Edition, sf. 273