

Bu notlar makine öğrenimi, veri madenciliği gibi konularda gerekli olasılık ve istatistik bilgisini paylaşmak için hazırlanıyor. Notlarda olasılık ve istatistik aynı anda anlatılacak, ve uygulamalara ağırlık verilecek.

### Orneklem Uzayı (Sample Space)

Orneklem uzayı  $\Omega$  bir deneyin mümkün tüm olasılıksal sonuçların (outcome) kümesidir. Eğer deneyimiz ardı ardına iki kere yazı (T) tura (H) atıp sonucu kaydetmek ise, bu deneyin mümkün tüm sonuçları şöyledir

$$\Omega = \{HH, HT, TH, TT\}$$

### Sonuçlar ve Olaylar (Outcomes and Events)

$\Omega$  içindeki her nokta bir sonuctur (outcome). Olaylar  $\Omega$ 'nin herhangi bir alt kümesidir ve sonuçlardan oluşurlar. Mesela üstteki yazı-tura deneyinde “iki atışın içinden ilk atışın her zaman H gelmesi olayı” böyle bir alt kümedir, bu olaya A diyelim,  $A = \{HH, HT\}$ .

Ya da bir deneyin sonucu  $\omega$  fiziksel bir ölçüm, diyelim ki sıcaklık ölçümü. Sıcaklık  $\pm$ , reel bir sayı olduğuna göre,  $\Omega = (-\infty, +\infty)$ , ve sıcaklık ölçümünün 10'dan büyük ama 23'ten küçük ya da eşit olma “olayı”  $A = (10, 23]$ . Koseli parantez kullanıldı çünkü sınır değerini dahil ediyoruz.

### Örnek

10 kere yazı-tura at.  $A =$  “en az bir tura gelme” olayı olsun.  $T_j$  ise  $j$ 'inci yazı-tura atışında yazı gelme olayı olsun.  $P(A)$  nedir?

Bunun hesabi için en kolayı, hiç tura gelmeme, yani tamamen yazı gelme olasılığını,  $A^c$ 'yi hesaplamak, ve onu 1'den çıkartmaktır.  $^c$  sembolü “tamamlayıcı (complement)” kelimesinden geliyor.

$$\begin{aligned} P(A) &= 1 - P(A^c) \\ &= 1 - P(\text{hepsi yazı}) \\ &= 1 - P(T_1)P(T_2)\dots P(T_{10}) \\ &= 1 - \left(\frac{1}{2}\right)^{10} \approx .999 \end{aligned}$$

### Rasgele Değişkenler (Random Variables)

Bir rasgele değişken  $X$  bir eslemedir, ki bu esleme  $X : \Omega \rightarrow \mathbb{R}$  her sonuç ile bir reel sayı arasındaki eslemedir.

Olasılık derslerinde bir noktadan sonra artık örneklem uzayından bahsedilmez, ama bu kavramın arkasında bir yerde her zaman devrede olduğunu hiç aklımızdan çıkartmayalım.

### Örnek

10 kere yazı-tura attık diyelim. VE yine diyelim ki  $X(\omega)$  rasgele değişkeni her

$\omega$  siralamasında (sequence) olan tura sayısı. İşte bir esleme. Mesela eğer  $\omega = \text{HHTHHTHHTT}$  ise  $X(\omega) = 6$ . Tura sayısı eslemesi  $\omega$  sonucunu 6 sayısına esledi.

Ornek

$\Omega = \{(x, y); x^2 + y^2 \leq 1\}$ , yani kume birim cember ve içindeki reel sayılar (unit disc). Diyelim ki bu kumeden rasgele seçim yapıyoruz. Tipik bir sonuç  $\omega = (x, y)$ 'dir. Tipik rasgele değişkenler ise  $X(\omega) = x$ ,  $Y(\omega) = y$ ,  $Z(\omega) = x + y$  olabilir. Görüldüğü gibi bir sonuç ile reel sayı arasında esleme var.  $X$  rasgele değişkeni bir sonucu  $x$ 'e eslemiş, yani  $(x, y)$  icinden sadece  $x$ 'i çekip çıkartmış. Benzer şekilde  $Y, Z$  değişkenleri var.

Toplamsal Dağılım Fonksiyonu (Cumulative Distribution Function -CDF-)

Tanım

$X$  rasgele değişkeninin CDF'i  $F_X : \mathbb{R} \rightarrow [0, 1]$  tanımı

$$F_X(x) = P(X \geq x)$$

Eğer  $X$  ayrışal ise, yani sayılabilir bir kume  $\{x_1, x_2, \dots\}$  icinden değerler alıyorsa olasılık fonksiyonu (probability function), ya da olasılık kütle fonksiyonu (probability mass function -PMF-)

$$f_X(x) = P(X = x)$$

Bazen  $f_X$ , ve  $F_X$  yerine sadece  $f$  ve  $F$  yazarız.

Tanım

Eğer  $X$  sürekli (continuous) ise, yani tüm  $x$ 'ler için  $f_X(x) > 0$ ,  $\int_{-\infty}^{+\infty} f(x)dx = 1$  olacak şekilde bir  $f_X$  mevcut ise, o zaman her  $a \leq b$  için

$$P(a < X < b) = \int_a^b f_X(x)dx$$

Bu durumda  $f_X$  olasılık yoğunluk fonksiyonudur (probability density function -PDF-).

$$F_X = \int_{-\infty}^x f_X(t)dt$$

Ayrıca  $F_X(x)$ 'in türevi alınabildiği her  $x$  noktasında  $f_X(x) = F'_X(x)$  demektir.

Dikkat! Eğer  $X$  sürekli ise o zaman  $P(X = x) = 0$  değerindedir.  $f(x)$  fonksiyonunu  $P(X = x)$  olarak görmek hatalıdır. Bu sadece ayrışal rasgele değişkenler için işler. Sürekli durumda olasılık hesabı için belli iki nokta arasında integral hesabı yapmamız gereklidir. Ek olarak PDF 1'den büyük olabilir, ama PMF olamaz. PDF'in 1'den büyük olabilmesi integrali bozmaz mı? Unutmayalım, integral hesabı yapıyoruz, noktasal değerlerin 1 olması tüm 1'lerin toplandığı anlamına gelmez. Bakınız *Entegralleri Nasıl Düşünelim* yazımız.

Tanım

$X$  rasgele degiskeninin CDF'i  $F$  olsun. Ters CDF (inverse cdf), ya da ceyrek fonksiyonu (quantile function)

$$F^{-1}(q) = \inf \left\{ x : F(x) \leq q \right\}$$

ki  $q \in [0, 1]$ . Eger  $F$  kesinlikle artan ve surekli bir fonksiyon ise  $F^{-1}(q)$  tekil bir  $x$  sayisi ortaya cikarir, ki  $F(x) = q$ .

Eger  $\inf$  kavramini bilmiyorsak simdilik onu minimum olarak dusunebiliriz.

$F^{-1}(1/4)$  birinci ceyrek

$F^{-1}(1/2)$  medyan (median, ya da ikinci ceyrek),

$F^{-1}(3/4)$  ucuncu ceyrek

olarak bilinir.

iki rasgele degisken  $X$  ve  $Y$  dagilimsal olarak birbirine esitligi, yani  $X \stackrel{d}{=} Y$  eger  $F_X(x) = F_Y(x)$ ,  $\forall x$ . Bu  $X, Y$  birbirine esit, birbirinin aynisi demek degildir. Bu degiskenler hakkindaki tum olasiliksal islemler, sonuclar ayni olacak demektir.

Uyari! “ $X$ ’in dagilimi  $F$ ’tir” beyanini  $X \sim F$  seklinde yazmak bir gelenek. Bu biraz kotu bir gelenek aslinda cunku  $\sim$  sembolu ayni zamanda yaklasiksallik kavramini belirtmek icin de kullaniliyor.

### Bernoulli Dagilimi

$X$ ’in bir yazi-tura atisini temsil ettigini dusunelim. O zaman  $P(X = 1) = p$ , ve  $P(X = 0) = 1 - p$  olacaktir, ki  $p \in [0, 1]$  olmak uzere. O zaman  $X$ ’in dagilimi Bernoulli deriz, ve  $X \sim \text{Bernoulli}(p)$  diye gosteririz. Olasilik fonksiyonu  $f(x) = p^x(1 - p)^{(1-x)}$ ,  $x \in \{0, 1\}$ .

Yani  $x$  ya 0, ya da 1. Parametre  $p$ , 0 ile 1 arasindaki herhangi bir reel sayi.

Uyari!

$X$  bir rasgele degisken;  $x$  bu degiskenin alabilecegi spesifik bir deger;  $p$  degeri ise bir **parametre**, yani sabit, onceden belirlenmis reel sayi. Tabii istatistiki problemlerde (olasilik problemlerinin tersi olarak dusunursek) cogunlukla o sabit parametre bilinmez, onun veriden hesaplanmasi, kestirilmesi gerekir. Her halukarda, cogu istatistiki modelde rasgele degiskenler vardir, ve onlardan ayri olarak parametreler vardir. Bu iki kavrami birbiriyle karistirmayalim.

### Birbicim (Uniform) Dagilim

$X$  birbicim,  $\text{Uniform}(a, b)$  olarak dagilmis deriz, ve bu  $X \sim \text{Uniform}(a, b)$  olarak yazilir eger

$$f(x) = \begin{cases} \frac{1}{b-a} & x \in [a, b] \text{ icin} \\ 0 & \text{digerleri} \end{cases}$$

ise ve  $a < b$  olacak sekilde. CDF hesabi olasilik egrisinin integralini temel alir,

birbirim dagilim bir  $a, b$  arasinda  $1/b - a$  yuksekliginde bir dikdortgen seklinde olacagi icin, bu dikdortgendeki herhangi bir  $x$  noktasinda CDF dagilimi, yani  $o\ x'in$  baslayip sol tarafin alaninin hesabi basit bir dikdortgensel alan hesabidir, yani  $x - a$  ile  $1/b - a$ 'nin carpimidir, o zaman

$$F(x) = \begin{cases} 0 & x < a \\ \frac{x-a}{b-a} & x \in [a, b] \\ 1 & x > b \end{cases}$$

Normal (Gaussian) Dagilim

$X \sim N(\mu, \sigma^2)$  ve PDF

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}, x \in \mathbb{R}$$

ki  $\mu \in \mathbb{R}$  ve  $\sigma > 0$  olacak sekilde.

Ilerride gorecegiz ki  $\mu$  bu dagilimin “ortasi”, ve  $\sigma$  onun etrafa ne kadar “yay-ildigi” (spread). Normal dagilim olasilik ve istatistikte cok onemli bir rol oynar. Dogadaki pek cok olay yaklasiksal olarak Normal dagilima sahiptir. Sonra gorecegimiz uzere, mesela bir rasgele degiskenin degerlerinin toplami her zaman Normal dagilima yaklasir (Merkezi Limit Teorisi -Central Limit Theorem-).

Eger  $\mu = 0$  ve  $\sigma = 1$  ise  $X$ 'in standart Normal dagilim oldugunu soyleriz. Gele-nege gore standart Normal dagilim rasgele degiskeni  $Z$  ile gosterilmelidir, PDF ve CDF  $\phi(z)$  ve  $\Phi(z)$  olarak gosterilir.

$\Phi(z)$ 'nin kapali form (closed-form) tanimi yoktur. Bu, matematikte “analitik bir forma sahip degil” demektir, formulu bulunamamaktadır, bunun sebebi ise Normal PDF'in entegralinin analitik olarak alinamiyor olusudur.

Bazi faydali puf noktaları

1. Eger  $X \sim N(\mu, \sigma^2)$  ise, o zaman  $Z = (X - \mu)/\sigma \sim N(0, 1)$ .
2. Eger  $Z \sim N(0, 1)$  ise, o zaman  $X = \mu + \sigma Z \sim N(\mu, \sigma^2)$
3. Eger  $X_i \sim N(\mu_i, \sigma_i^2)$ ,  $i = 1, 2, \dots$  ve her  $X_i$  digerlerinden bagimsiz ise, o zaman

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \mu_i, \sum_{i=1}^n \sigma_i^2\right)$$

Tekrar  $X \sim N(\mu, \sigma^2)$  alirsak ve 1. kuraldan devam edersek / temel alirsak su da dogru olacaktir.

$P(a < X < b) = ?$

$$= P\left(\frac{a - \mu}{\sigma} < \frac{X - \mu}{\sigma} < \frac{b - \mu}{\sigma}\right)$$

$$= P\left(\frac{a - \mu}{\sigma} < Z < \frac{b - \mu}{\sigma}\right) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$


İlk gecisi nasıl elde ettik? Bir olasılık ifadesi  $P(\cdot)$  içinde eşitliğin iki tarafına aynı anda aynı toplama, çıkarma operasyonlarını yapabiliriz.

Son ifadenin anlamı sudur. Eğer standart Normal'in CDF'ini hesaplayabiliyorsak, istediğimiz Normal olasılık hesabını yapabiliriz demektir, çünkü artık  $X$  içeren bir hesabın  $Z$ 'ye nasıl tercüme edildiğini görüyoruz.

Tüm istatistik yazılımları  $\Phi(z)$  ve  $\Phi(z)^{-1}$  hesabı için gerekli rutinlere sahiptir. Tüm istatistik kitaplarında  $\Phi(z)$ 'nin belli değerlerini taşıyan bir tablo vardır. Ders notlarımızın sonunda da benzer bir tabloyu bulabilirsiniz.

### Dağılımlar Hakkında

Doğadan yapılan çoğu ölçümlerin, sıklık grafiğini alınca sonucun aşağıda gibi çıkması ilginçtir.



Mesela, Türkiye'deki 2000 yetişkinin kilosunu ölçün. Grafiğini alın, kesinlikle yukarıdaki tepe şekli çıkacak. Ya da, 1000 kişinin boyunu ölçün, aynı tepe şekli. Keskin nişancının hedefe attığı kurşunların hedefe gelişini en iyi 12 en kötü 1 olmak üzere ölçün, sıklık grafiğini alın. Gene aynı tepe şekli!

Nasıl oluyor bu iş?

Açıklama için, normal dağılım eğrisinden bahsetmemiz gerekecek.

Not olarak düşelim: Sıklık grafiği,  $X$  sayısının ne kadar çıktığını sayıp,  $Y$  ekseninde bu sayıyı  $X$ 'e tekabül ederek kolon olarak göstermeye denir. Mesela, 60 kilo değeri 13 kere çıktı ise,  $X=60$ ,  $Y=13$  gibi bir kolon çizilecektir.

### Normal Dağılım Eğrisi

Normal dağılımın olasılık kavramı ile yakın bağları var. Bu konuda ünlü bir deney zar atma deneyidir. Mesela, elimizde tek bir zar olsun, ve bu zarı arka arkaya atalım. Sabrımız yeterse 1000 kere atalım. Sonuçta, sıklık grafiği eşit bir dağılım gösterecektir. (Zar tutmuyorsanız :) )

Bunun sebeplerini anlamak zor değil. Her zar atış olayı birbirinden bağımsız, ve her sayının üstte gelme ihtimali birbirine eşit olduğu için ( $1/6$ ), her sayıdan eşit miktarda gelecektir. Tabii bunun için deneyin birçok kere tekrarlanması gerekiyor.

Fakat, bir yerine 2 zar atalım. Hatta hatta, 4 zar atalım, ve bu sefer sıklık grafik hanesine yazmadan çıkan sayıları önce toplayalım. Bu çıkan toplamın sıklık

grafiğini alalım.

İşte bu sıklık grafiği göreceğiz ki, önceden bahsettiğimiz tepe grafiğine yaklaşıyor. Ne kadar çok zar atarsanız, bu benzerlik o kadar daha fazla olacaktır.

Bunun sebebi de aslında basit: 1..6 arası sayıların tek bir zardan gelme olasılığı aynı, evet. Fakat toplamlara gelince, mesela iki zarlı örnekte, 10 sayısının olasılığı 2 sayısından daha yüksek. Çünkü, 10 sayısını 5-5, 4-6 ya da 6-4 ile alabiliyoruz. 2 sayısı sadece 1-1 ile geliyor.

Buradan şu sonuç çıkabilir: Eğer doğada ölçtüğümüz bir kavramın oluşmasında birden fazla etken var ise, o ölçümlerin sıklığı her zaman tepe şekli ile olacaktır.

Fakat, daha da gizemli olan bir olay şudur; Sabit olan bir şeyi ölçtüğümüzde (yaptığımız hatalar sonucu) çıkan grafiğin bile tepe şekilli olması! Yani, doğru dürüst hata yapmak bile elimizde değil gibi gözüküyor... Bunun tabii ki olasılık açıklamaları olacaktır. İzlediğimiz matematikçilerden bu en son konuda net bir açıklama alamadık.

### Simulasyon


Eğer bu kavramları simulasyon ortamında göstermek istersek, Python ile bunu yapabiliriz.

İlk önce, Random.org sitesinden rasgele sayı üretip bilgiyarımıza kopyalacağız. Bahsettiğimiz site, kimsenin kullanmadığı radyo kanallarından atmosfer gürültüsü dinleyip, bu gürültüleri sayısal değere çevirerek rasgele sayı üretiyor.

Gerçek rasgele sayı üretmek pek kolay bir iş değil. Her ne kadar bilgisayarınızda rasgele sayı üreten birçok algoritma olsa bile, bu algoritmalar belli bir sayı üretiminden sonra kendini tekrar etmeye başlıyorlar. Gerçek rasgele sayılar için muhakkak dış bir kaynağa bağlanmak gerekiyor.

Gösterimiz için, rasgele sayıları üretip, bir dat dosyasına koyuyoruz. Python ile bu sayıları okuyup, ilk önce teker teker sayıların sıklık grafiğini, ondan sonra sayıları üçer üçer toplayıp, onların grafiğini alıp göstereceğiz. Aşağıda bu iki grafiği bulabilirsiniz.

```
A = loadtxt('rasgele.dat')
plt.hist(A, 50)
plt.savefig('dagilim_1.png')
```




```
A = loadtxt('rasgele.dat');
B = []
```

```
i = 1;
```

```
while (i < 998):
    toplam = 0
    s = A[i]
    toplam = toplam + s
    s = A[i+1]
    toplam = toplam + s
    s = A[i+2]
    toplam = toplam + s
    B.append(toplam/3)
    i = i + 3
```

```
plt.hist(B, 50);
plt.savefig('dagilim_2.png')
```



Ornek

$X \sim N(3,5)$  ise  $P(X > 1)$  nedir? Cevap:

$$P(X > 1) = 1 - P(X < 1) = 1 - P\left(Z < \frac{1-3}{\sqrt{5}}\right) = 1 - \Phi(-0.8944) = .81$$

Soru tam  $P(a < X < b)$ , sadece b oldugu icin yukaridaki form ortaya cikti.

Ornek

Simdi oyle bir q bul ki  $P(X < q) = .2$  olsun. Yani  $\Phi^{-1}(.2)$ 'yi bul. Yine  $X \sim N(3, 5)$ .

Cevap

Demek ki tablodan .2 degerine tekabul eden esik degerini bulup, ustteki formül uzerinden geriye tercume etmemiz gerekiyor. Normal tablosunda  $\Phi(-0.8416) = .2$ ,

$$.2 = P(X < q) = P(Z < \frac{q - \mu}{\sigma}) = \Phi(\frac{q - \mu}{\sigma})$$

O zaman

$$-0.8416 = \frac{q - \mu}{\sigma} = \frac{q - 3}{\sqrt{5}}$$

$$q = 3 - 0.8416\sqrt{5} = 1.1181$$

t (Student's t) ve Cauchy Dagilimi

$X$ ,  $\nu$  derece bagimsizlikta t dagilimina sahiptir, ki bu  $X \sim t_\nu$  diye yazilir eger

$$f(x) = \frac{\Gamma(\nu + 1/2)}{\sqrt{\nu\pi}\Gamma(\nu/2)} \left(1 + \frac{x^2}{\nu}\right)^{-(\nu+1)/2}$$

t dagilimi Normal dagilima benzer ama daha kuyrugu daha kalindir. Aslinda Normal dagilimi t dagiliminin  $\nu = \infty$  oldugu hale tekabul eder. Cauchy dagilimi da t'nin özel bir halidir,  $\nu = 1$  halidir. Bu durumda yogunluk fonksiyonu

$$f(x) = \frac{1}{\pi(1 + x^2)}$$

Bu formül hakikaten bir yogunluk mudur? Kontrol icin entegralini alalim,

$$\int_{-\infty}^{\infty} f(x) dx = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{1 + x^2}$$

Cogunlukla entegre edilen yerde "1 arti ya da eksi bir sey in karesi" turunde bir ifade gorulurse, yerine gecirme (substitution) islemi trigonometrik olarak yapilir.

$$x = \tan \theta, \theta = \arctan x$$

$$1 + x^2 = 1 + \tan^2 \theta = \sec^2 \theta$$

$$dx/d\theta = \sec^2 \theta$$

O zaman

$$= \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{dx}{1 + x^2} = \frac{1}{\pi} \int_{-\infty}^{\infty} \frac{1}{\sec^2 \theta} \sec^2 \theta d\theta = \frac{1}{\pi} \int_{-\infty}^{\infty} 1 d\theta =$$

$$= \frac{1}{\pi} \theta \Big|_{-\infty}^{\infty} = \frac{1}{\pi} [\arctan(\infty) - \arctan(-\infty)]$$



$$= \frac{1}{\pi} \left[ \frac{\pi}{2} - \left( -\frac{\pi}{2} \right) \right] = 1$$

$\chi^2$  Dagilimi

$X$ 'in  $p$  derece serbestlige sahip bir  $\chi^2$  dagilima sahip ise  $X \sim \chi_p^2$  olarak gosterilir, yogunluk

$$f(x) = \frac{1}{\Gamma(p/2)2^{p/2}} x^{(p/2)-1} e^{-x/2}, x > 0$$

Eger  $Z_1, \dots, Z_p$  bagimsiz standart Normal rasgele degiskenler ise,  $\sum_{i=1}^p Z_i^2 \sim \chi_p^2$  esitligi dogrudur.

İki Degiskenli Dagilimler

Tanim

Surekli ortamda  $(X, Y)$  rasgele degiskenleri icin yogunluk fonksiyonu  $f(x, y)$  tanimlanabilir eger i)  $f(x, y) > 0, \forall (x, y)$  ise, ve ii)  $\int_{-\infty}^{\infty} \int_{-\infty}^{\infty} f(x, y) dx dy = 1$  ise ve her kume  $A \subset \mathbb{R} \times \mathbb{R}$  icin  $P((X, Y) \in A) = \int \int_A f(x, y) dx dy$ . Hem ayriksal hem surekli durumda birlesik (joint) CDF  $F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$  diye gosterilir.

Bu tanimda  $A$  kumesi olarak tanimlanan kavram uygulamalarda bir olaya (event) tekabul eder. Mesela

Ornek

$(X, Y)$ 'in birim kare uzerinde birbicimli (uniform) olsun. O zaman

$$f(x, y) = \begin{cases} 1 & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \text{ ise} \\ 0 & \text{diger durumlarda} \end{cases}$$

$P(X < 1/2, Y < 1/2)$ 'yi bul.

Cevap

Burada verilen  $A = \{X < 1/2, Y < 1/2\}$  bir altkumedir ve bir olaydir. Olaylari boyle tanimlamamis miydik? Orneklem uzayinin bir altkumesi olay degil midir? O zaman  $f$ 'i verilen altkume uzerinden entegre edersek, sonuca ulasmis oluruz.

Ornek

Eger dagilim kare olmayan bir bolge uzerinden tanimliysa hesaplar biraz daha zorlasabilir.  $(X, Y)$  yogunlugu

$$f(x, y) = \begin{cases} cx^2y & \text{eger } x^2 \leq y \leq 1 \\ 0 & \text{digerleri} \end{cases}$$

Niye  $c$  bilinmiyor? Belki problemin modellemesi sirasinda bu bilinmez olarak ortaya cikmistir. Olabilir. Bu degeri hesaplayabiliriz, cunku  $f(x, y)$  yogunluk olmalı, ve yogunluk olmanin sarti  $f(x, y)$  entegre edilince sonucun 1 olmasi.

Once bir ek bilgi uretelim, eger  $x^2 \leq 1$  ise, o zaman  $-1 \leq x \leq 1$  demektir. Bu

lazim cunku integrale sinir degeri olarak verilecek.

$$\begin{aligned}
 1 &= \int \int f(x, y) dy dx = c \int_{-1}^1 \int_{x^2}^1 x^2 y \\
 &= c \int_{-1}^1 x^2 \int_{x^2}^1 y dy dx = \int_{-1}^1 x^2 \left( \frac{1}{2} - \frac{x^4}{2} \right) dx = 1 \\
 &= c \int_{-1}^1 x^2 \left( \frac{1 - x^4}{2} \right) dx = 1 \\
 &= \frac{c}{2} \int_{-1}^1 x^2 - x^6 dx = 1
 \end{aligned}$$

Devam edersek  $c = 21/4$  buluruz.

Simdi, diyelim ki bizden  $P(X \geq Y)$ 'yi hesaplamamiz isteniyor. Bu hangi A bolgesine tekabul eder? Elimizdekiler

$$-1 \leq x \leq 1, x^2 \leq y, y \leq 1$$


Simdi bunlara bir de  $y \leq x$  eklememiz lazim. Yani ortadaki esitsizlige bir oge daha eklenir.

$$-1 \leq x \leq 1$$

$$x^2 \leq y \leq x$$

$$y \leq 1$$

$x^2 \leq y$ 'yi hayal etmek icin  $x^2 = y$ 'yi dusunelim, bu bir parabol olarak cizilebilir, ve parabolun ustunde kalanlar otomatik olarak  $x^2 \leq y$  olur, bu temel irdelemelerden biri.



Ayni sekilde  $y \leq x$  icin  $y = x$ 'i dusunelim, ki bu 45 derece aciyla cizilmis duz bir çizgi. Cizginin altı  $y \leq x$  olur. Bu iki bolgenin kesisimi yukaridaki resimdeki golgeli kisim.

Ek bir bolge sarti  $0 \leq x \leq 1$ . Bu sart resimde bariz goruluyor, ama cebirsel olarak bakarsak  $y \geq x^2$  oldugunu biliyoruz, o zaman  $y \geq 0$  cunku  $x^2$  muhakkak bir pozitif sayi olmalı. Diger yandan  $x \geq y$  verilmiş, tum bunlari yanyana koyarsak  $x \geq 0$  sarti ortaya cikar.

Artık  $P(X \geq Y)$  hesabi için hazırız,

$$P(X \geq Y) = \frac{21}{4} \int_0^1 \int_{x^2}^x x^2 y dy dx = \frac{21}{4} \int_0^1 x^2 \left[ \int_{x^2}^x y dy \right] dx$$

$$= \frac{21}{4} \int_0^1 x^2 \frac{x^2 - x^4}{2} dx = \frac{3}{20}$$

“Hafizasız” Dağılım, Ustel (Exponential) Dağılım

Ustel dağılımın hafizasız olduğu söylenir. Bunun ne anlama geldiğini anlatmaya uğrasalım. Diyelim ki rasgele değişken  $X$  bir aletin omrunu temsil ediyor, yani bir  $p(x)$  fonksiyonuna bir zaman “sordugumuz” zaman bize dondurulen olasılık, o aletin  $x$  zamani kadar daha islemesinin olasılığı. Eğer  $p(2) = 0.2$  ise, aletin 2 yıl daha yasamasının olasılığı 0.2.

Bu hafizasizligi, olasilik matematigi ile nasil temsil ederiz?

$$P(X > s + t | X > t) = P(X > s), \forall s, t \geq 0$$

Yani oyle bir dagilim var ki elimizde,  $X > t$  bilgisi veriliyor, ama (kalan) zamani hala  $P(X > s)$  olasılığı veriyor. Yani  $t$  kadar zaman gectigi bilgisi hicbir seyi degistirmiyor. Ne kadar zaman gecmis olursa olsun, direk  $s$  ile gidip ayni olasilik hesabini yapıyoruz.

Sartsal (conditional) formülünü uygularsak üstteki soyle olur

$$\frac{P(X > s + t, X > t)}{P(X > t)} = P(X > s)$$

ya da

$$P(X > s + t, X > t) = P(X > s)P(X > t)$$

Bu son denklemin tatmin olması için  $X$  ne şekilde dağılmış olmalıdır? Üstteki denklem sadece  $X$  dağılım fonksiyonu ustel (exponential) olursa mümkündür, çünkü sadece o zaman

$$e^{-\lambda(s+t)} = e^{-\lambda s} e^{-\lambda t}$$

gibi bir ilişki kurulabilir.

Örnek

Diyelim ki bir bankadaki bekleme zamanı ortalama 10 dakika ve ustel olarak dağılmış. Bir müşterinin i) bu bankada 15 dakika beklemesinin ihtimali nedir? ii) Bu müşterinin 10 dakika bekledikten sonra toplam olarak 15 dakika (ya da daha fazla) beklemesinin olasılığı nedir?

Cevap

i) Eğer  $X$  müşterinin bankada beklediği zamanı temsil ediyorsa

$$P(X > 15) = e^{-15 \cdot 1/10} = e^{-3/2} \approx 0.223$$

ii) Sorunun bu kısmi musteri 10 dakika gecirdikten sonra 5 dakika daha gecirmesinin olasiligini soruyor. Fakat ustel dagilim “hafizasiz” oldugu icin kalan zamani alip yine direk ayni fonksiyona geciyoruz,

$$P(X > 5) = e^{-5 \cdot 1/10} = e^{-1/2} \approx 0.60$$

Bilesen (Marginal) Dagilimler

Surekli rasgele degiskenler icin bilesen yogunluk

$$f_X(x) = \int f(x, y) dy$$

ve

$$f_Y(y) = \int f(x, y) dx$$

Ustteki integraller gercek bir dagilim fonksiyonu  $f(x, y)$  verilince alt ve ust limit te tanımlamak zorundadir. Cunku bilesen yogunluk icin bir veya daha fazla degiskeni “integralle disari atmak (integrate out)” ettigimiz soylenir, eger ayrik-sal (discrete) ortamda olsaydik bu atilan degiskenin tum degerlerini goze alarak toplama yapan bir formül yazardik. Surekli ortamda integral kullaniyoruz, ama tum degerlerin uzerinden yine bir sekilde gecmemiz gerekiyor. Iste alt ve ust limitler bunu gerceklestiriyor. Bu alt ve ust limitler, atilan degiskenin “tum degerlerine” bakmasi gerektiği icin  $-\infty, +\infty$  olmalidir. Eger problem icinde degiskenin belli degerler arasinda oldugu belirtilmis ise (mesela alttaki ornekte  $x > 0$ ) o zaman entegral limitleri alt ve ust sinirini buna gore degistirebilir.

Ornek

$f_{X,Y}(x, y) = e^{-(x+y)}$ , olsun ki  $x, y \geq 0$ . O zaman  $f_X(x)$

$$f_X(x) = e^{-x} \int_0^{\infty} e^{-y} dy = e^{-x} \cdot 1 = e^{-x}$$

Ornek

$$f(x, y) = \begin{cases} x + y & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{diger} \end{cases}$$

$$f_Y(y) = \int_0^1 (x + y) dx = \int_0^1 x dx + \int_0^1 y dx = \frac{1}{2} + y$$

Tanim

İki rasgele degisken  $A, B$  bagimsizdir eger tum  $A, B$  degerleri icin

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

esitligi dogru ise. Bu durumda  $X \perp Y$  yazilir.

Teori

$X, Y$ ’nin birlesik PDF’i  $f_{X,Y}$  olsun. O zaman ve sadece  $f_{X,Y}(x, y) = f_X(x)f_Y(y)$  ise

$X \perp Y$  dogrudur.

Ornek

Diyelim ki  $X, Y$  bagimsiz, ve ikisinin de ayni yogunlugu var.

$$f(x) = \begin{cases} 2x & \text{eger } 0 \leq x \leq 1 \\ 0 & \text{digerleri} \end{cases}$$

$P(X + Y < 1)$ 'i hesaplayin.

Cevap

Bagimsizligi kullanarak birlesik dagilimi hesaplayabiliriz

$$f(x, y) = f_X(x)f_Y(y) = \begin{cases} 4xy & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{digerleri} \end{cases}$$

Simdi bu birlesik yogunluk uzerinden istedigimiz bolgeyi hesaplariz, bolgeyi tanımlayan  $X + Y \leq 1$  ifadesi.

$$P(X + Y \leq 1) = \iint_{x+y \leq 1} f(x, y) dy dx$$

Entegralin limiti ustteki hali sembolik, hesap icin bu yeterli degil, eger  $x + y \leq 1$  ise,  $y \leq 1 - x$  demektir, ve bolge  $y = 1 - x$  cizgisinin alti olarak kabul edilebilir.  $x, y$  zaten sifirdan buyuk olmalı, yani sola dogru yatık cizginin alti ve  $y, x$  eksenlerinin ustu kismini olusturan bir ucgen,

$$= \int_0^1 \int_0^{1-x} 4yx \, dy dx = 4 \int_0^1 x \left[ \int_0^{1-x} y \, dy \right] dx$$

Numaraya dikkat, hangi degisken uzerinden entegral aldigimiza bakarak, onun haricindekileri sabit kabul ederek bu “sabitleri” entegral disina atiyoruz, boylece isimizi kolaylastiriyoruz. Hesabi tamamlarsak,

$$4 \int_0^1 x \frac{(1-x)^2}{2} dx = \frac{1}{6}$$

Kosullu Dagilimler (Conditional Distributions)

Surekli rasgele degiskenler icin kosullu olasilik yogunluk fonksiyonlari

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$

Devam edelim, eger kosullu yogunluk uzerinden olay hesabi yapmak istersek, ve  $f_Y(y) > 0$  oldugunu farzederek,

$$P(X \in A | Y = y) = \int_A f_{X|Y}(x|y) dx$$

Ornek

(1) sonucunu aldigimiz ornege donelim,

$$f(x, y) = \begin{cases} x + y & \text{eger } 0 \leq x \leq 1, 0 \leq y \leq 1 \\ 0 & \text{diger} \end{cases}$$

$P(X < 1/4 | Y = 1/3)$  nedir?

Cevap

Ustteki olasilik hesabi icin  $f_{X|Y}$  fonksiyonuna ihtiyacimiz var. (1)'de gordugumu uzere,

$$f_Y(y) = \frac{1}{2} + y$$

Ana formulumuz neydi?

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x, y)}{f_Y(y)}$$
$$= \frac{x + y}{\frac{1}{2} + y}$$

$$P(X < 1/4 | Y = 1/3) = \int_0^{1/4} \frac{x + \frac{1}{3}}{\frac{1}{2} + \frac{1}{3}} dx = \frac{\frac{1}{32} + \frac{1}{3}}{\frac{1}{2} + \frac{1}{3}} = \frac{14}{32}$$

Cok Degiskenli (Multivariate) Dagilimler ve IID Orneklemler (Samples)

$X = (X_1, \dots, X_n)$  olsun, ki  $(X_1, \dots, X_n)$ 'lerin herbiri bir rasgele degisken, o zaman  $X$ 'e rasgele vektor (random vector) ismi verilir.  $f(x_1, \dots, x_n)$ 'in PDF'i temsil ettigini dusunelim. Bu PDF'i baz alarak aynen iki degiskenli (bivariate) orneklerde oldugu gibi, benzer tekniklerle bilesenleri, kosullu dagilimleri, vs. hesaplamak mumkundur.

Cok Degiskenli Normal

Tek degiskenli Normal dagilimin iki parametresi vardi,  $\mu, \sigma$ . Cok degiskenli formda  $\mu$  bir vektor,  $\sigma$  yerine ise  $\Sigma$  matrisi var. Once rasgele degiskeni tanımlayalım,

$$Z = \begin{bmatrix} Z_1 \\ \vdots \\ Z_k \end{bmatrix}$$

ki  $Z_1, \dots, Z_k \sim N(0, 1)$ .  $Z$ 'nin yogunlugu

$$f(z) = \prod_{i=1}^k f(z_i) = \frac{1}{(2\pi)^{k/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^k z_j^2 \right\}$$
$$= \frac{1}{(2\pi)^{k/2}} \exp \left\{ -\frac{1}{2} z^T z \right\}$$

Bu durumda  $Z$ 'nin *standart* çok degiskenli Normal dagilima sahip oldugu soylenir, ve  $Z \sim N(0, I)$  olarak gosterilir. Buradaki 0 degeri icinde k tane sifir olan bir vek-

tor olarak,  $I$  ise  $k \times k$  birim (identity) matrisi olarak anlasilmalidir.

Daha genel olarak bir vektor  $X$ 'in cok degiskenli Normal dagilimina sahip oldugunu soyleriz, ve bunu  $X \sim N(\mu, \Sigma)$  olarak gosteririz, eger dagilimin yogunlugu

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{k/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} (x - \mu)^T \Sigma^{-1} (x - \mu) \right\}$$

$\Sigma$  pozitif kesin (positive definite) bir matristir. Hatirlayalim, bir matris pozitif kesindir eger tum sifir olmayan  $x$  vektorleri icin  $x^T \Sigma x > 0$  ise.

Not: Karekok kavrami tekil sayilardan matrislere de aktarilabilir. Bir matris  $B$ 'nin  $A$ 'nin karekoku oldugu soylenir, eger  $B \cdot B = A$  ise.

Devam edersek, eger  $\Sigma$  pozitif kesin ise bir  $\Sigma^{1/2}$  matrisini oldugu gosterilebilir, ki bu matrise  $\Sigma$ 'nin karekoku ismi verilir, ve bu karekokun su ozellikleri vardir, (i)  $\Sigma^{1/2}$  simetriktir, (ii)  $\Sigma = \Sigma^{1/2} \Sigma^{1/2} = I$  ve  $\Sigma^{-1/2} = (\Sigma^{1/2})^{-1}$ .

Cok Boyutlu Gaussian'i Parcalamak (Partitioning)

Diyelim ki Normal bir vektor  $X$ 'i  $X = (X_1, X_2)$  olarak parcaladik. Bunu Gaussian'a etkileri ne olur? Ayni sekilde  $\mu = (\mu_1, \mu_2)$  olarak parcalayabiliriz.  $\Sigma$  ise

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

olarak parcalanabilir.  $a, b$ 'nin parcalarinin boyutlari  $p, q$  olsun,  $n = p + q$ .

Simdi birlesik Gaussian'i

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{(p+q)/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

Birlesik yogunlugu parcalar uzerinden belirtirsek, bu yogunlugu  $X_2$  icin bilesten yogunluga ve  $X_1$  icin bir kosullu yogunluga ayirabiliriz. Yani

$$f(x_1, x_2) = f(x_1|x_2)f(x_2)$$

tanimindaki parcalari elde etmeye calisacagiz. Ama bundan once boluntulenmis matrislere yakindan bakalim.

Bir boluntulenmis (partitioned) matrisin tersini almak icin, o matrisin parcalarinin tersini almak dogru degildir, yani

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} \neq \begin{bmatrix} E^{-1} & F^{-1} \\ G^{-1} & H^{-1} \end{bmatrix}$$

Tersini alma islemi icin bazi numaralar lazim. Ana numara boluntulenmis matrisi kosegen bir matris haline getirmek, cunku kosegen matrislerin tersi, kosegendeki elemanlari tersidir, yani ters alma operasyonu bu tur matrislerin "icine isler", o yuzden bir sekilde bir kosegen matris elde etmeye ugrasacagiz. Bunun icin boluntulenmis matrisimizi sagdan ve soldan bazi matrislerle carpacagiz. Ayrica

sunu da bilelim,

$$XYZ = W$$

durumunda  $Y$ 'nin tersini almak istersek, sag ve soldaki  $X, Z$  matrislerinin tersini almak gerekmez, niye?

$$X^{-1}XYZ = X^{-1}W$$

$$YZZ^{-1} = X^{-1}WZ^{-1}$$

$$Y = X^{-1}WZ^{-1}$$

Simdi iki tarafın da tersini alalım,

$$Y^{-1} = ZW^{-1}X$$

Tamam, baslayalım.

$$M = \begin{bmatrix} E & F \\ G & H \end{bmatrix}$$

matrisini kosegen yapacağız. Eger sadece alt sol koseyi sifirlayasaydik, bunu yapacak ozel bir matrisle soldan carpardik,

$$\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} = \begin{bmatrix} E & F \\ 0 & H \end{bmatrix}$$

Sadece ust sag koseyi sifirlamak isteseydik, sagdan carpardik

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix} \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} = \begin{bmatrix} E & 0 \\ G & H \end{bmatrix}$$

Hepsini biraraya koyalım,

$$\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} = \begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}$$

Bu carpimin dogrulugu carpim elle yapilarak kontrol edilebilir.

Ustte gordugumuz gibi

$$XYZ = W$$

ifadesindeki  $Y$ 'nin tersi

$$Y^{-1} = ZW^{-1}X$$

ile olur.

$$\underbrace{\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}}_X \underbrace{\begin{bmatrix} E & F \\ G & H \end{bmatrix}}_Y \underbrace{\begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix}}_Z = \underbrace{\begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}}_W$$



O zaman

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} = \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} \begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}^{-1} \begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}$$

Daha kısa olması esitligin sag tarafinda, ortadaki matris icin  $E - FH^{-1}G$  yerine  $M/H$  kullanalim (bu arada  $M/H$  lineer cebirde “ $M$ ’in  $H$ ’e gore Schur tamamlayicisi (complement)” olarak bilinir),

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} = \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} \begin{bmatrix} (M/H)^{-1} & 0 \\ 0 & H^{-1} \end{bmatrix} \begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}$$

Esitligin sag tarafindaki carpimi gerceklestirirsek,

$$= \begin{bmatrix} (M/H)^{-1} & -(M/H)^{-1}FH^{-1} \\ -H^{-1}G(M/H)^{-1} & H^{-1} + H^{-1}G(M/H)^{-1}FH^{-1} \end{bmatrix}$$

Bu final ifade boluntulenmis bir matrisin tersini o matrisin icindeki parcalar uzerinden temsil eden bir ifadedir.

Icinde bir kosesi sifir olan boluntulenmis matrislerde determinantlar soyle isler,

$$\det \left( \begin{bmatrix} E & 0 \\ G & H \end{bmatrix} \right) = \det \left( \begin{bmatrix} E & F \\ 0 & H \end{bmatrix} \right) = \det(E) \det(H)$$

Ayrica

$$\det(AB) = \det(A) \det(B)$$

O zaman (2)’nin determinantini alirsak,  $\det$  yerine  $||$  kullandik,

$$|M| = |M/H||H|$$

Bu ifade gayet dogal duruyor (bir raslanti herhalde, ya da Schur tamamlayicisi isareti ozellikle boyle secilmis),

Boluntulenmis bir matrisin devrigini almak icin her blogunun ayri ayri devrigi alinir, ve tum blokların yani boluntulenmis tamaminin bir daha devrigi alinir, yani

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^T = \begin{bmatrix} A^T & C^T \\ B^T & D^T \end{bmatrix}$$

Simdi cok degiskenli Normal icin bilesen ve kosullu yogunluk hesaplarına geelim. Gaussian formulunun  $\exp$  kismini alirsak,

$$\exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

(3)’teki acilimi kullanirsak, ve  $E = \Sigma_{11}$ ,  $F = \Sigma_{12}$ , .. olacak sekilde,

$$\exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} I & 0 \\ -\Sigma_{22}^{-1}\Sigma_{21} & I \end{bmatrix} \begin{bmatrix} (\Sigma/\Sigma_{22}) & 0 \\ 0 & \Sigma_{22}^{-1} \end{bmatrix} \begin{bmatrix} I & -\Sigma_{12}\Sigma_{22}^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

Acilimi tamamen yaparsak,

$$= \exp \left\{ -\frac{1}{2}(\mathbf{x}_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2))^T (\Sigma/\Sigma_{22})^{-1}(\mathbf{x}_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)) \right\} \cdot \exp \left\{ \frac{1}{2}(\mathbf{x}_2 - \mu_2)^T \Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2) \right\}$$

Not:  $\Sigma_{12}^T = \Sigma_{21}$ . Ustte birinci exp icinde sol bolumde devrigin icindeki ifadelerden, mesela  $\mathbf{x}_1^T, \mu_1^T$ 'den ve  $\Sigma_{21}$ 'li ifadeden devrik islemini cekip, buyuk paranteze alinince bu degisim oldu.

Simdi mesela 1. exp'ye dikkat edersek, ortada  $(\Sigma/\Sigma_{22})^{-1}$  var, ve bu ifadenin solunda ve saginda birbirinin devrigi olan ayni terimler duruyor. Ifadenin tamamı bir Normal dagilim. Ayni sey 2. exp icin gecerli.

Isin exp tarafini halletik. Simdi exp oncesindeki kesiri (4) kullanarak parcalayalım,

$$\frac{1}{(2\pi)^{(p+q)/2} \det(\Sigma)^{1/2}} = \frac{1}{(2\pi)^{(p+q)/2} \left( \det(\Sigma/\Sigma_{22}) \det(\Sigma_{22}) \right)^{1/2}} \\ = \left( \frac{1}{(2\pi)^{p/2} \det(\Sigma/\Sigma_{22})^{1/2}} \right) \left( \frac{1}{(2\pi)^{q/2} \det(\Sigma_{22})^{1/2}} \right)$$

Bu parcalarin her birini ayri bir exp onunde kullanabiliriz, ve ikinci exp ifadesinin

$$\frac{1}{(2\pi)^{q/2} \det(\Sigma_{22})^{1/2}} \exp \left\{ \frac{1}{2}(\mathbf{x}_2 - \mu_2)^T \Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2) \right\}$$

oldugunu goruyoruz. Bu ifade  $f(\mathbf{x}_2)$  bilesen yogunlugudur! O zaman geri kalanlar, yani diger kesir ve birinci exp hep beraber  $f(\mathbf{x}_1|\mathbf{x}_2)$  yogunlugu olmalidir. Yani,

$$\frac{1}{(2\pi)^{p/2} \det(\Sigma/\Sigma_{22})^{1/2}} \cdot \exp \left\{ -\frac{1}{2}(\mathbf{x}_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2))^T (\Sigma/\Sigma_{22})^{-1}(\mathbf{x}_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2)) \right\}$$

Buradan genel bir kural cikartabiliriz,

1)  $X_2$ 'nin bilesen yogunlugu  $X_2 \sim N(\mu_2, \Sigma_{22})$

2)  $X_2 = \mathbf{x}_2$  olmak uzere  $X_1$ 'in kosullu dagilimi

$$X_1|X_2 = \mathbf{x}_2 \sim N\left(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}_2 - \mu_2), \Sigma/\Sigma_{22}\right)$$

$\Sigma/\Sigma_{22}$  nedir? Hatirlarsak,  $M/H = E - FH^{-1}G$ , ve  $E = \Sigma_{11}, F = \Sigma_{12}, \dots$  o zaman

$$\Sigma/\Sigma_{22} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$$

Yani

$$X_1|X_2 = x_2 \sim N\left(\mu_1 + \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2), \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\right)$$

Hatirlama Numarasi

Normal Dagilimin formulu bazen hatirlayamayabiliriz. Peki daha basit bir formolden baslayarak onu turetebilir miyiz? Bu mumkun. Daha once  $e^{-x^2}$  *Nasil Entegre Edilir?* yazisinda

$$\int_{-\infty}^{+\infty} e^{-x^2} dx = \sqrt{\pi}$$

oldugunu gormustuk. Dikkat edersek bu integral bir formulun olasiliksal dagilim olup olmadigini kontrol etmek icin kullandigimiz integrale benziyor. Eger integral 1 cikarsa onun olasiliksal dagilim oldugunu biliyoruz. Ustteki sonuc  $\sqrt{\pi}$ , fakat iki tarafi  $\sqrt{\pi}$ 'ye bolerseniz, sag taraf 1 olur ve Boylece solda bir dagilim elde ederiz. Yani

$$\int_{-\infty}^{+\infty} \frac{1}{\sqrt{\pi}} e^{-x^2} dx = 1$$

formulunde integralin sagindaki kisim bir dagilimdir. Bu formulu donusturerek Gaussian'a erisebiliriz. Ustteki formulun orta noktası (mean) sifir, varyansi (variance), yani  $\sigma^2 = 1/2$  (bunu da ezberlemek lazim ama o kadar dert degil). O zaman  $\sigma = 1/\sqrt{2}$ .

Ilk amacimiz  $\sigma = 1$ 'e erismek olsun (cunku oradan herhangi bir  $\sigma$ 'ya atlayabiliriz), bunun icin  $x$ 'i  $\sqrt{2}$ 'e bolmek lazim, tabii ayni anda onun etkisini sifirlamak icin normalize eden sabiti dengelemek amaciyla  $\sqrt{2}$ 'ye bolmek lazim,

$$= \int_{-\infty}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-\left(\frac{x}{\sqrt{2}}\right)^2} dx$$

$\sigma = 1$ 'e erisince oradan herhangi bir  $\sigma$  icin,  $\sigma$  degiskenine bolelim, yine hem e ustune hem sabite bu eki yapalim,

$$= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\left(\frac{x}{\sqrt{2}\sigma}\right)^2} dx$$

Simdi herhangi bir ortalama  $\mu$  icin bu degiskeni formule sokalim, bunun icin  $\mu$ 'yu  $x$ 'den cikarmak yeterli

$$= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\left(\frac{x-\mu}{\sqrt{2}\sigma}\right)^2} dx$$

e üstündeki kare alma işlemini acarsak,

$$= \int_{-\infty}^{+\infty} \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx$$

Boylece integral içindeki kısım tek boyutlu Gaussian formuna erismiş oluyor.

Beklenti (Expectation)

Bu değer, dağılım  $f(x)$ 'in tek sayılık bir özetidir. Yani beklenti hesabına bir taraftan bir dağılım fonksiyonu girer, diğer taraftan tek bir sayı dışarı çıkar. Sürekli dağılım fonksiyonları için  $E(X)$

$$E(X) = \int xf(x)dx$$

ayrıksal durumda

$$E(X) = \sum_x xf(x)$$

olarak hesaplanır. Hesabın, her  $x$  değerini onun olasılığı ile çarpıp topladığına dikkat. Bu tür bir hesap doğal olarak tüm  $x$ 'lerin ortalamasını verecektir, ve dolaylı olarak dağılımın ortalamasını hesaplayacaktır. Ortalama  $\mu_x$  olarak ta gösterilebilir.

Notasyonel basitlik için üstteki toplam / entegral yerine

$$= \int x dF(x)$$

diyeceğiz, bu notasyonel bir kullanım sadece, unutmayalım, reel analizde  $\int x dF(x)$ 'in özel bir anlamı var (hoca tam diferansiyel  $dF$ 'den bahsediyor).

Beklentinin tanımının kapsamlı / eksiksiz olması için  $E(X)$ 'in “mevcudiyeti” için de bir şart tanımlamak gerekir, bu şart şöyle olsun,

$$\int_x |x|dF_X(x) < \infty$$

ise beklenti mevcut demektir. Tersî söz konusu ise beklenti mevcut değildir.

Örnek

$$X \sim \text{Unif}(-1, 3) \text{ olsun. } E(X) = \int x dF(x) = \int xf_X(x)dx = \frac{1}{4} \int_{-1}^3 xdx = 1.$$

Örnek

Cauchy dağılımının  $f_X(x) = \{\pi(1+x^2)\}^{-1}$  olduğunu söylemistik. Şimdi beklenti hesaplayalım. Parçalı entegral tekniği lazım,  $u = x$ ,  $dv = 1/(1+x^2)$  deriz, ve o zaman  $v = \tan^{-1}(x)$  olur, bkz *Ters Trigonometrik Formüller* yazımız. Demek ki

$$\int |x|dF(x) = \frac{2}{\pi} \int_0^{\infty} \frac{xdx}{1+x^2}$$

2 nereden çıktı? Çünkü  $|x|$  kullanıyoruz, o zaman sınır değerlerinde sadece sıfırın sagına bakıp sonucu ikiyle carpmak yeterli. Bir sabit olduğu için  $\pi$  ile beraber disari cikiyor. Simdi

$$\int u dv = uv - \int v du$$

uzerinden

$$= [x \tan^{-1}(x)]_0^{\infty} - \int_0^{\infty} \tan^{-1}(x) dx = \infty$$

Yani ustteki hesap sonsuzluga gider. O zaman ustteki tanimimize gore Cauchy dagiliminin beklentisi yoktur.

### Toplamların Moment'leri

Olasılık matematiğinde "moment üreten işlevler" olarak adlandırılan, başlangıçta pek yararlı gibi gözükmesede bir takım matematiksel özellikleri olduğu için, ispatlarda oldukça işe yarayan bir kavram vardır.

Her rasgele değişkenin bir dağılımı olduğunu biliyoruz. Her rasgele değişkenin de ayrıca bir moment üreten fonksiyonu da vardır. Ayrıca, moment üreten fonksiyon ile rasgele değişken arasında bire-bir olarak bir ilişki mevcuttur. "Bu neye yarar?" diye sorulabilir; Cevap olarak, mesela cebirsel olarak türete türete bir moment'e geldiğimiz düşünelim, ve tekrar başka bir taraftan, başka bir formülden gene türete türete tekrar aynı moment işlevine geliyorsak, bu demektir ki, iki taraftan gelen rasgele değişkenler (ve tekabül eden dağılımları) birbirine eşittir. Bazı şartlarda moment üreten işlevler ile cebir yapmak, dağılım fonksiyonlarından daha rahat olmaktadır.

Her rasgele değişken için, moment üreten işlev şöyle bulunur.

X rasgele degiskenin moment ureten operasyonu

$$M(t) = E(e^{tx}) \text{ olarak gosterilir}$$

Ayriksal operasyonlar icin

$$M(t) = \sum_x e^{tx} p(x)$$

Surekli islevler icin

$$M(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

Kuram

Gelelim yazımızın esas konusu olan kuramımıza.

Eğer  $X_1, X_2, \dots, X_n$  bağımsız rasgele değişken ise, ve her değişkenin  $M_i(t)$   $i = 1, 2, 3, \dots, n$

olarak, öz olarak aynı olan birer moment üreten işlevi var ise, o zaman,

$$Y = \sum_{i=1}^n a_i X_i$$

acilimi

$$M_y(t) = \prod_{i=1}^n M(a_i t)$$

olacaktır.

Ispat

$$\begin{aligned} M_y(t) &= E(e^{tY}) = E(e^{t(a_1 X_1 + a_2 X_2 + \dots + a_n X_n)}) \\ &= E[\exp(t a_1 X_1 + t a_2 X_2 + \dots + t a_n X_n)] \\ &= E[\exp(t a_1 X_1) \exp(t a_2 X_2) + \dots + \exp(t a_n X_n)] \\ &= E[\exp(t a_1 X_1)] + E[\exp(t a_2 X_2)] + \dots + E[\exp(t a_n X_n)] \end{aligned}$$

Daha önce belirttiğimiz gibi

$$M_i(t) = E[\exp(t X_i)]$$

olduğuna göre ve  $t$  yerine  $t a_i$  koyulduğunu düşünelim

$$M_y(t) = \prod_{i=1}^n M_y(a_i t)$$

olacaktır.

Bunu  $M_y(t) = (M_i(a_i t))^n$  şeklinde de gösterebiliriz. Ortalama (Mean) ve Medyan (Median)

**Özet İstatistikleri**

Genellikle istatistik kitapları hemen ortalama (mean), medyan (median) ve bağlantılı özet istatistiklerinden (summary statistics) bahsederek işe girerler. Bu istatistikleri dikkatle kullanmak gerekir, çünkü her türlü veri, her yerde geçerli değildir. Mesela ortalama sadece tek merkezi bir tepesi olan (unimodal) dağılımlar için geçerlidir. Eğer bu temel varsayım geçerli değilse, ortalama kullanarak yapılan hesaplar bizi yanlış yollara götürür. Ayrıca bir dağılımı simetrik olup olmadığı da ortalama ya da medyan kullanılıp kullanılmaması konusunda önemlidir. Eğer simetrik, tek tepeli bir dağılım var ise, ortalama ve medyan birbirine yakın olacaktır. Fakat veri başka türde bir dağılım ise, o zaman bu iki ölçüt birbirinden çok farklı olabilir.

Önce ortalama ve standart sapmayı (standart deviation) görelim.

$$m = \frac{1}{n} \sum_i x_i$$

Standart sapma veri noktaların "ortalamadan farkının ortalamasını" verir. Tabii bazen noktalar ortalamanın altında, bazen üstünde olacaktır, bizi bu negatiflik, pozitiflik ilgilendirmez, biz sadece farkla alakalıyız. O yüzden her sapmanın karesini alırız, bunları toplayıp nokta sayısına böleriz .

$$s^2 = \frac{1}{n} \sum_i (x_i - m)^2$$

Eğer  $m$  tanımını üstte yerine koyarsak,

$$\begin{aligned} &= \frac{1}{n} \sum_i x_i^2 + \frac{1}{n} \sum_i m^2 - \frac{2}{n} \sum_i x_i m \\ &= \frac{1}{n} \sum_i x_i^2 + \frac{m^2 n}{n} - \frac{2mn}{n} m \\ &= \frac{1}{n} \sum_i x_i^2 + m^2 - 2m^2 \\ &= \frac{1}{n} \sum_i x_i^2 - m^2 \end{aligned}$$

Bu ölçüye varyans (variance) denir ve teorik olarak ortalamadan daha önemli olduğu söylenebilir. Fakat dağılımın yayılma ölçüsü olarak biz bu ölçüyü olduğu gibi değil, onun karesini kullanacağız (ki standart sapma buna deniyor aslında). Niye? Çünkü o zaman veri noktalarının ve yayılma ölçüsünün birimleri birbiri ile aynı olacak. Eğer veri setimiz bir alışveriş sepetindeki malzemelerin lira cinsinden değerleri olsaydı, varyans bize sonucu "karekok lira" olarak verecekti ve bunun pek anlamı olmayacaktı.

#### Medyan ve Yüzdelikler (Percentile)


Üstteki hesaplar sayıları toplayıp, bölmek üzerinden yapıldı. Medyan ve diğer yüzdeliklerin hesabı (ki medyan 50. yüzdelige tekabül eder) için eldeki tüm değerleri "sıra dizmemiz" ve sonra 50. yüzdelik için ortadakinin bakmamız gerekiyor. Mesela eğer ilk 5. yüzdeligi arıyorsak ve elimizde 80 tane değer var ise, bastan 4. sayıya / vektör hücrelerine / öğeye bakmamız gerekiyor. Eğer 100 eleman var ise, 5. sayıya bakmamız gerekiyor, vs.

Bu siraya dizme işlemi kritik. Kiyasla ortalama hesabı hangi sırada olursa olsun, sayıları birbirine topluyor ve sonra bölüyor. Zaten ortalama ve sapmanın

istatistikte daha çok kullanilmasinin tarihi sebebi de aslinda bu; bilgisayar öncesi çağda sayıları sıralamak (sorting) zor bir işti. Bu sebeple hangi sırada olursa olsun, toplayıp, bölerek hesaplanabilecek özetler daha makbuldu. Fakat artık sıralama işlemi kolay, ve veri setleri her zaman tek tepeli, simetrik olmayabiliyor.

Örnek veri seti olarak unlu `dellstore2` tabanındaki satış miktarları kullanırsak,

```
data = np.loadtxt("dell.csv")
plt.hist(data, 40)
plt.savefig('05_02.png')
```



```
print np.mean(data)
213.948899167

print np.median(data)
214.06

print np.std(data)
125.118481954

print np.mean(data)+2*np.std(data)
464.185863074

print np.percentile(data, 95)
410.4115
```

Görüldüğü gibi üç nokta hesabi için ortalamadan iki sapma ötesini kullanırsak, 464.18, fakat 95. yüzdeliği kullanırsak 410.41 elde ediyoruz. Niye? Sebep ortalamanın kendisi hesaplanırken çok uç değerlerin toplama dahil edilmiş olması ve bu durum, ortalamanın kendisini daha büyük seviyeye doğru itiyor. Yüzdelik hesabi ise sadece sayıları sıralayıp belli bazı elemanları otomatik olarak üç nokta olarak addediyor.



## Box Whisker Grafikleri


Tek boyutlu bir verinin dağılımını görmek için Box ve Whisker grafikleri faydalı araçlardır; medyan (median), dağılımın genişliğini ve siradisi noktaları (outliers) açık şekilde gösterirler. Isim nereden geliyor? Box yani kutu, dağılımın ağırlığının nerede olduğunu gösterir, medyanın sağında ve solunda olmak üzere iki çeyreğin arasındaki kısımdır, kutu olarak resmedilir. Whiskers kedilerin bacaklarına verilen isimdir, zaten grafikte birazcık bacak gibi duruyorlar. Bu uzantılar medyan noktasından her iki yana kutunun iki kati kadar uzatılır sonra verideki "ondan az olan en büyük" noktaya kadar geri çekilir. Tüm bunların dışında kalan veri ise teker teker nokta olarak grafikte basılır. Bunlar siradisi (outlier) oldukları için daha az olmaları tahmin edilir.

BW grafikleri iki veriyi dağılımsal olarak karşılaştırmak için birebirdir. Mesela Larsen and Marx adlı araştırmacılar çok az veri içeren Quintus Curtius Snodgrass veri setinin değişik olduğunu ispatlamak için bir sürü hesap yapmışlardır, bir sürü matematiksel işleme girmişlerdir, fakat basit bir BW grafiği iki setin farklılığını hemen gösterir.

BW grafikleri iki veriyi dağılımsal olarak karşılaştırmak için birebirdir. Mesela Larsen and Marx adlı araştırmacılar çok az veri içeren Quintus Curtius Snodgrass veri setinin değişik olduğunu ispatlamak için bir sürü hesap yapmışlardır, bir sürü matematiksel işleme girmişlerdir, fakat basit bir BW grafiği iki setin farklılığını hemen gösterir.

## Python üzerinde basit bir BW grafiği

```
spread= rand(50) * 100
center = ones(25) * 50
flier_high = rand(10) * 100 + 100
flier_low = rand(10) * -100
data = concatenate((spread, center, flier_high, flier_low), 0)
plt.boxplot(data)
plt.savefig('05_03.png')
```



Bir diğer örnek Glass veri seti üzerinde

```

data = loadtxt("glass.data", delimiter=",")
head = data[data[:,10]==7]
tableware = data[data[:,10]==6]
containers = data[data[:,10]==5]

print head[:,1]


data =(containers[:,1], tableware[:,1], head[:,1])

plt.yticks([1, 2, 3], ['containers', 'tableware', 'head'])

plt.boxplot(data,0,'rs',0,0.75)
plt.savefig('05_04.png')

[ 1.51131  1.51838  1.52315  1.52247  1.52365  1.51613  1.51602  1.51623
 1.51719  1.51683  1.51545  1.51556  1.51727  1.51531  1.51609  1.51508
 1.51653  1.51514  1.51658  1.51617  1.51732  1.51645  1.51831  1.5164
 1.51623  1.51685  1.52065  1.51651  1.51711]

```



## Guven Araligi (Confidence Intervals)

Bu kavram istatistikte tartisilan konulardan biri. Bayes ve Frenkansçı (Frequentist) istatistik arasindaki felsefi farklardan biri burada ortaya cikiyor. Frekansci tanim soyledir:

”Bir parametre  $\theta$  icin  $1 - \alpha$  seviyesinde bir  $C_n = (a, b)$  guven araligi tanimlanabilir – bu aralik  $a = a(X_1, \dots, X_n)$  ve  $b = b(X_1, \dots, X_n)$  adli iki fonksiyon uzerinden tanimlanabilir. Bu fonksiyonlar veri uzerinde isleyen, *verinin* fonksiyonlaridir, ve sonucta

$$\mathbb{P}_{\theta}(\theta \in C_n) \geq 1 - \alpha, \quad \forall \theta \in \Theta$$

Yani  $(a, b)$  araligi  $1 - \alpha$  olasiliginda  $\theta$  'yi icine alir / hapseder.

Daha detayli olarak deney arka arkaya pek cok kez tekrarlandiginda parametrenin tahmininin  $1 - \alpha$  oraninda tanimlanan araliga dusecegi soylenir.  $1 - \alpha$  sayisina guven araliginin kapsamı (coverage) ismi de verilir. Genellikle insanlar yuzde 95 guven araligini kullanirlar, ve bu yuzdeye tekabul eden  $\alpha = 0.05$

rakami kullanilir.

Uzerine basarak belirtmek gerekir ki  $C_n$  rasgele (random) bir degerdir, ama  $\theta$  sabittir, cunku  $C_n$  verinin bir fonksiyonudur, ve veriden, yani bir orneklemden gelecegi icin o da rasgele olmalidir.

Eger  $\theta$  bir vektor ise o zaman bir aralik yerine bir guven kumesi kullanilir (mesela bir kure, ya da elips)."

Fakat frekansci yaklasimda aralik fonksiyonlari  $a, b$  ile guven araligi arasindaki baglanti net degildir. Hangi fonksiyon secimi hangi  $\alpha$ 'ya sebebiye vermektedir? Bu durum net oldugu durumlarda bile teorik olarak saglamligi suphelidir, ayrica hesabin sozel olarak ortaya konmasinda bazi eksikler vardır. "Deney arka arkaya pek cok kez tekrarlandiginda parametrenin tahmini,  $1 - \alpha$  guven araliga dusecektir" ibaresi mesela; "deney tekrari" her durumda gecerli olmayabilir. Meteoroloji "yarin yuzde 80 ihtimali ile yagmur yagacak" diyorsa, o hesap sartlarinin bir daha ortaya cikmasinin olasiligi cok dusuktur, Kaos Teorisi bize en azindan bunu soyluyor.

Wiki sayfasinda [1] tartismanin boyutlari gorulebilir.

Son onyillarda ortaya cikan yaklasim ise Bayes Teorisini devreye sokmak. Bir guven araligi tanimlamanin en saglam yolu bu hesabi bir dagilimi baz alarak yapmak. Eger sonuc olarak bir tekil sayi degil, bir dagilim elde edersek bu dagilim uzerinde guvenlik hesaplarini yapmak cok kolay hale gelir. Mesela sonuc (sonsal dagilim) bir Gaussian dagilim ise, bu dagilimin yuzde 95 agirliginin nerede oldugu, ve nasil hesaplandigi bellidir.

Bayes Teorisi

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Veri analizi baglaminda diyelim ki deneyler yaparak tahmini olarak hesaplamak (estimate) istedigimiz bir parametre var, bu bir protonun kutlesi ya da bir ameliyat sonrasi hayatta kalma orani olabilir. Bu durumlarda iki ayri "olaydan" bahsetmemiz gerekir, B olayi spesifik bazi olcumlerin elde edilmesi "olayidir", mesela olcum uc sayidan olusuyorsa, biz bir olcumde spesifik olarak  $\{0.2, 4, 5.4\}$  degerlerini elde etmisiz. Ikinci olay bilmedigimiz parametrenin belli bir degere sahip olmasi olacak. O zaman Bayes Teorisinin su sekilde tekrar yazabiliriz,

$$P(\text{parametre}|\text{veri}) \propto P(\text{data}|\text{parametre})P(\text{parametre})$$

$\propto$  isareti orantili olmak (proportional to) anlamina geliyor. Boleni attik cunku o bir sabit (tamamen veriye bagli, tahmini hesaplamak istedigimiz parametreye bagli degil). Tabii bu durumda sol ve sag taraf birbirine esit olmaz, o yuzden esitlik yerine orantili olmak isaretini kullandik. Bu cercevede "belli bir numerik sabit cercevesinde birbirine esit (equal within a numeric constant)" gibi cumleler

de gorulebilir.

Ornek

Diyelim ki bir bozuk para ile 10 kere yazi-tura attik, ve sonuc altta

T H H H H T T H H H

Bu veriye bakarak paranin hileli olup olmadigini anlamaya calisacagiz. Bayes ifadesini bu veriye gore yazalim,


$$P(p|\{T H H H H T T H H H\}) \propto P(\{T H H H H T T H H H|p\})P(p)\}$$

$P(p)$  ifadesi ne anlama gelir? Aslinda bu ifadeyi  $P([Dagilim] = p)$  olarak gormek daha iyi, artik  $p$  parametresini bir dagilimdan gelen bir tekil deger olarak gordugumuze gore, o dagilimin belli bir  $p$ 'ye esit oldugu zamani modelliyoruz burada. Her halukarda  $P(p)$  dagilimini, yani onsel (prior) olasiligi bilmiyoruz, hesaptan once her degerin mumkun oldugunu biliyoruz, o zaman bu onsel dagilimi duz (flat) olarak aliriz, yani  $P(p) = 1$ .

$P(\{T H H H H T T H H H|p\})$  ifadesi goz korkutucu olabilir, ama buradaki her ogenin bagimsiz ozdesce dagilmis (independent identically distributed) oldugunu gorursek, ama bu ifadeyi ayri ayri  $P(\{T|p\})$  ve  $P(\{H|p\})$  carpimlari olarak gorebiliriz.  $P(\{T|p\}) = p$  ve  $P(\{H|p\}) = 1 - p$  oldugunu biliyoruz. O zaman

$$P(p|\{7 Tura, 3 Yazı\}) \propto p^7(1 - p)^3$$

Grafiklersek,



Boylece  $p$  icin bir sonsal (posterior) dagilim elde ettik. Artik bu dagilimin yuzde 95 agirliginin nerede oldugunu rahatca gorebiliriz / hesaplayabiliriz. Dagilimin tepe noktasinin  $p = 0.7$  civarinda oldugu goruluyor. Bir dagilimla daha fazlasini yapmak ta mumkun, mesela bu fonksiyonu  $p$ 'ye bagli baska bir fonksiyona karsi entegre etmek mumkun, mesela beklentiye bu sekilde hesaplayabiliriz.

Onsel dagilimin her noktaya esit agirlik veren birornek (uniform) secilmis olmasi,

yani problemi cozmeye sifir bilgidenden baslamis olmamiz, yontemin bir zayifligi olarak gorulmemeli. Yontemin kuvveti elimizdeki bilgiyle baslayip onu net bir sekilde veri ve olurluk uzerinden sonsal tek dagilima goturebilmesi. Baslangic ve sonuc arasindaki baglanti gayet net. Fazlasi da var; ilgilendigimizalani (domain) ogrendikce, basta hic bilmedigimiz onsel dagilimi daha net, bilgili bir sekilde secebiliriz ve bu sonsal dagilimi da daha olmasi gereken modele daha yaklastirabilir.

## Gaussian Kontrolu

Diyelim ki Gaussian dagilimina sahip oldugunu dusundugumuz  $\{x_i\}$  verilerimiz var. Bu verilerin Gaussian dagilimina uyup uymadigini nasil kontrol edecegiz? Normal bir dagilimin her veri noktasini icin soyle temsil edebiliriz,

$$y_i = \Phi\left(\frac{x_i - \mu}{\sigma}\right)$$

Burada  $\Phi$  standart Gaussian'i temsil ediyor (detaylar icin \*Istatistik Ders 1\*) ve CDF fonksiyonuna tekabul ediyor. CDF fonksiyonunun ayni zamanda ceyregi (quantile) hesapladigi soylenir, aslinda CDF son derece detayli bir olasilik degeri verir fakat evet, dolayli yoldan noktanin hangi ceyrek icine dustugu de gorulecektir.

Simdi bir numara yapalim, iki tarafa ters Gaussian formuluunu uygulayalim, yani  $\Phi^{-1}$ .

$$\Phi^{-1}(y_i) = \Phi^{-1}\left(\Phi\left(\frac{x_i - \mu}{\sigma}\right)\right)$$

$$\Phi^{-1}(y_i) = \frac{x_i - \mu}{\sigma}$$

$$x_i = \Phi^{-1}(y_i)\sigma + \mu$$

Bu demektir ki elimizdeki verileri  $\Phi^{-1}(y_i)$  bazinda grafiklersek, bu noktalar egimi  $\sigma$ , baslangici (intercept)  $\mu$  olan bir duz çizgi olmalidir. Eger kabaca noktalar duz çizgi olusturmuyorsa, verimizin Gaussian dagilima sahip olmadigina karar verebiliriz.

Ustte tarif edilen grafik, olasilik grafigi (probability plot) olarak bilinir.

Ters Gaussian teorik fonksiyonunu burada vermeyecegiz, Scipy `scipy.stats.invgauss` hesaplar icin kullanilabilir. Fakat  $y_i$ 'nin kendisi nereden geliyor? Eger  $y_i$ , CDF'in bir sonucu ise, pur veriye bakarak bir CDF degeri de hesaplayabilmemiz gerekir. Bunu yapmak icin bir baska numara lazim.

1. Eldeki sayilari artan sekilde siralayin

2. Her veri noktasına bir derece (rank) atayın (siralama sonrası hangi seviyede olduğu yeterli, 1'den başlayarak).

3. Ceyrek değeri  $y_i$  bu sıra /  $n + 1$ ,  $n$  eldeki verinin büyüklüğü.

Bu teknik niye isliyor?  $x$ 'in CDF'i  $x_i < x$  şartına uyan  $x_i$ 'lerin oranı değil midir? Yani bir sıralama söz konusu ve üstteki teknik te bu sıralamayı biz elle yapmış olduk, ve bu sıralamadan gereken bilgiyi aldık.

### Moment Fonksiyonları

Olasılık matematiğinde "moment üreten işlevler" olarak adlandırılan, başlangıçta pek yararlı gibi gözükmesede bir takım matematiksel özellikleri olduğu için, ispatlarda oldukça işe yarayan bir kavram vardır.

Her rasgele değişkenin bir dağılımı olduğunu biliyoruz. Her rasgele değişkenin de ayrıca bir moment üreten fonksiyonu da vardır. Ayrıca, moment üreten fonksiyon ile rasgele değişken arasında bire-bir olarak bir ilişki mevcuttur. "Bu neye yarar?" diye sorulabilir; Cevap olarak, mesela cebirsel olarak türete türete bir moment'e geldiğimiz düşünelim, ve tekrar başka bir taraftan, başka bir formülden gene türete türete tekrar aynı moment işlevine geliyorsak, bu demektir ki, iki taraftan gelen rasgele değişkenler (ve tekabül eden dağılımları) birbirine eşittir. Bazı şartlarda moment üreten işlevler ile cebir yapmak, dağılım fonksiyonlarından daha rahat olmaktadır.

Her rasgele değişken için, moment üreten işlev şöyle bulunur.

$X$  rasgele değişkeninin moment üreten operasyonu

$M(t) = E(e^{tx})$  olarak gösterilir

Ayrık operasyonlar için

$$M(t) = \sum_x e^{tx} p(x)$$

Sürekli işlevler için

$$M(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

### Kuram

Gelelim yazımızın esas konusu olan kuramımıza.

Eğer  $X_1, X_2, \dots, X_n$  bağımsız rasgele değişken ise, ve her değişkenin  $M_i(t)$   $i = 1, 2, 3, \dots, n$  olarak, öz olarak aynı olan birer moment üreten işlevi var ise, o zaman,

$$Y = \sum_{i=1}^n aX_i$$

acilimi

$$M_y(t) = \prod_{i=1}^n M(a_i t)$$

olacaktır.

Ispat

$$\begin{aligned} M_y(t) &= E(e^{tY}) = E(e^{t(a_1 X_1 + a_2 X_2 + \dots + a_n X_n)}) \\ &= E[\exp(t a_1 X_1 + t a_2 X_2 + \dots + t a_n X_n)] \\ &= E[\exp(t a_1 X_1) \exp(t a_2 X_2) \dots \exp(t a_n X_n)] \\ &= E[\exp(t a_1 X_1)] E[\exp(t a_2 X_2)] \dots E[\exp(t a_n X_n)] \end{aligned}$$

Daha once belirttigimiz gibi

$$M_i(t) = E[\exp(t X_i)]$$

olduguna gore ve t yerine  $t a_i$  koyuldugunu dusunelim

$$M_y(t) = \prod_{i=1}^n M_y(a_i t)$$

olacaktır.

Bunu  $M_y(t) = (M_i(a_i t))^n$  seklinde de gosterebiliriz.

Orneklem Dagilimleri (Sampling Distributions)

Diyelim ki elimizde (hakkinda) ogrenmek istedigimiz bir sayisal obek (population) var. Bu obekteki her elemani ayri ayri incelemek istemiyoruz, problem degil, nufustan bir orneklem (sample) aliriz. Eger bu orneklem nufusu yeterince iyi temsil ediyorsa, problem cikmaz. Bu temsiliyeti garantilemenin iyi bir yolu orneklemi rasgele yapmaktır.

Simdi, diyelim ki, bu orneklemi bir sekilde ozetlemek istiyoruz yani orneklem verisi kullanilarak hesaplanmis temsili bir istatistik (descriptive statistic) elde edecegiz.

Fakat orneklemimiz rasgele idi. Bu istatistigimiz (ki o da sonucta bir rasgele degiskendir ve onun da bir dagilimi vardir), nasil bir dagilima sahiptir? Yani nufus dagilimi (population distribution), ve orneklem dagiliminin (sampling distribution) birbiriyle baglantisiyla ilgileniyoruz.

Teori

Eger  $X_1, \dots, X_n$  bir  $N(\mu, \sigma)$  dagiliminda alinmis orneklem olsun. O zaman orneklem ortalamasinin dagilimi  $N(\mu, \sigma/\sqrt{n})$ .

[TBD - Ispat]

Teori

Eğer  $X_1, \dots, X_n$  bir  $N(\mu, \sigma)$  dağılımında alınmış örneklem olsun. O zaman bu büyüklük

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

$t_{n-1}$  dağılımına, yani  $n - 1$  serbestlik derecesindeki (degree of freedom) bir Student's t Dağılımıdır.

[TBD - İspat]

### Hipotez Testleri (Hypothesis Testing)

Hipotez testi (bir veriye dayanarak) farzedilen bir parametreyi bir sabit degerle karsilastirmak, ya da iki parametreyi birbiriyile karsilastirmak icin kullanilir.

Bir hipotez testi, sonucta sadece iki cevap verebilecek bir sorudur; bu sonuclar "reddetmek" ya da "reddetmemek" olabilir. Dikkat: bu sonuclardan biri "kabul etmek" degil, bir istatistiki hipotezi kabul etmek mumkun degildir. Tek soyleye-bildigimiz "bir hipotezi reddetmek icin elimizde yeterli veri olmadigini" soyle-mektir. Ama reddedebiliyorsak, bu sonucta daha bir kesinlik vardir.

### Tek Orneklem t Testi (One-sample t test)

Bu test verinin Normal dagilimdan geldigini farzeder, tek orneklem durumunda elde  $x_1, \dots, x_n$  verisi vardir, ve bu veri  $N(\mu, \Sigma)$  dagilimindan gelmistir ve test etmek istedigimiz hipotez / karsilastirma  $\mu = \mu_0$ .

```
from scipy.stats import ttest_1samp, wilcoxon, ttest_ind
import pandas as pd
daily_intake = np.array([5260, 5470, 5640, 6180, 6390, 6515, 6805, 7515, 7515, 8230, 8770])
df = pd.DataFrame(daily_intake)
print df.describe()
```

```
count    11.000000
mean     6753.636364
std      1142.123222
min      5260.000000
25%      5910.000000
50%      6515.000000
75%      7515.000000
max      8770.000000
```

```
t_statistic, p_value = ttest_1samp(daily_intake, 7725)
print "one-sample t-test", p_value

one-sample t-test 0.0181372351761
```

Sonuc  $p\_value$  0.05'ten kucuk cikti yani yuzde 5 onemliligini (significance) baz aldik bu durumda veri hipotezden onemli derecede (significantly) uzakta. Demek ki ortalamanin 7725 oldugu hipotezini reddetmemiz gerekiyor.



Testi iki orneklemli kullanalim, gruplar 0/1 degerleri ile isaretlendi, ve test etmek istedigimiz iki grubun ortalamasinin (mean) ayni oldugu hipotezini test etmek. t-test bu arada varyansin ayni oldugunu farzeder.

```
energ = np.array([
    [9.21, 0],
    [7.53, 1],
    [7.48, 1],
    [8.08, 1],
    [8.09, 1],
    [10.15, 1],
    [8.40, 1],
    [10.88, 1],
    [6.13, 1],
    [7.90, 1],
    [11.51, 0],
    [12.79, 0],
    [7.05, 1],
    [11.85, 0],
    [9.97, 0],
    [7.48, 1],
    [8.79, 0],
    [9.69, 0],
    [9.68, 0],
    [7.58, 1],
    [9.19, 0],
    [8.11, 1]])
group1 = energ[energ[:, 1] == 0][:, 0]
group2 = energ[energ[:, 1] == 1][:, 0]
t_statistic, p_value = ttest_ind(group1, group2)
print "two-sample t-test", p_value

two-sample t-test 0.00079899821117
```

$p - \text{value} < 0.05$  yani iki grubun ortalamasi ayni degildir. Ayni oldugu hipotezi reddedildi.

### Eslemeli t-Test (Paired t-test)

Eslemeli testler ayni deneysel birimin olcumu alindigi zaman kullanilabilir, yani olcum alinan ayni grupta, deney sonrasi deneyin etki edip etmedigi test edilebilir. Bunun icin ayni olcum deney sonrasi bir daha alinir ve "farklarin ortalamasinin sifir oldugu" hipotezi test edilebilir. Altta bir grup hastanin deney oncesi ve sonrasi ne kadar yiyecek tukettigi listelenmis.

```
intake = np.array([
    [5260, 3910],
    [5470, 4220],
    [5640, 3885],
    [6180, 5160],
    [6390, 5645],
    [6515, 4680],
    [6805, 5265],
    [7515, 5975],
```

```
[7515, 6790],
[8230, 6900],
[8770, 7335],
])
pre = intake[:, 0]
post = intake[:, 1]
t_statistic, p_value = ttest_1samp(post - pre, 0)
print "paired t-test", p_value

paired t-test 3.05902094293e-07
```

### Wilcoxon isaretli-sirali testi (Wilcoxon signed-rank test)

t Testleri Normal dagilima gore sapmaları yakalamak acisinden, ozellikle buyuk orneklem var ise, oldukca saglamdir. Fakat bazen verinin Normal dagilimdan geldiği faraziyesini yapmak istemeyebiliriz. Bu durumda *dagilimdan bagimsiz metotlar* daha uygundur, bu tur metotlar icin verinin yerine cogunlukla onun sıra istatistiklerini (order statistics) kullanir.

Tek orneklemli Wilcoxon testi icin prosedür  $\mu_0$ 'i tum veriden cikartmak ve geri kalan (farkları) isaretine bakmadan numerik degerine gore siralamak, ve bu sıra degerini bir kenara yazmak. Daha sonra geri donup bu sefer cikartma islemi sonucunun isaretine bakmak, ve eksi isareti tasiyan sıra degerlerini toplamak, ayni islemi arti isareti icin yapmak, ve eksi toplami arti toplamindan cikartmak. Sonucta elimize bir istatistik  $W$  gelecek. Bu test istatistigi aslında  $1..n$  tane sayi icinden herhangi birini  $1/2$  olasiligiyla secmek, ve sonuclari toplamaya tekabul etmektedir. Ve bu sonuc yine  $0.05$  ile karsilastirilir.

```
z_statistic, p_value = wilcoxon(daily_intake - 7725)
print "one-sample wilcoxon-test", p_value

one-sample wilcoxon-test 0.0279991628713
```

Hipotezi yine reddettik.

Uste yaptigimiz eslemeli t-testi simdi Wilcoxon testi ile yapalim,

```
z_statistic, p_value = wilcoxon(post - pre)
print "paired wilcoxon-test", p_value

paired wilcoxon-test 0.00463608893545
```

### Binom Testi

Binom dagilimi belli sayida "deney" icinde her seferinde  $p$  olasiligi tasiyan iki kategorili bir olaydan *kac tane* olabilecegini modeller. Dagilim

$$P(K = k) = \binom{n}{k} p^k q^{n-k}$$

olarak belirtilir, ki  $q = 1 - p$  degeridir. Bu dagilimin  $n > 20$ , yani "yeterince buyuk" degerleri icin Normal (Gaussian) Dagilima yaklastigi / onun gibi oldugu

bilinmektedir. Bu yaklaşılan dağılım ortalaması  $np$  ve standart sapması  $\sqrt{npq}$  olan bir Normal dağılım olacaktır, yani  $N(np, \sqrt{npq})$ .

Devam edelim, madem elimizde bir normal dağılım var, bu normal dağılımı diğer her normal dağılım gibi standardize edebiliriz,

$$Z = \frac{K - np}{\sqrt{npq}} \sim N_{0,1}$$

Burada rasgele değişken  $K$ , yani her binom deneyi ardından ele geçecek başarı sayısı burada. Binom testi için test etmek istediğimiz şey budur. O zaman  $p$  yerine test ettiğimiz ana binom dağılımından gelen ana orani  $\hat{p}$  kullanırız, ki bu başarı / tüm deney sayısı olarak hesaplanır,  $K$  yeni deneydeki ele geçen başarı sayısıdır,  $n$  örneklemının büyüklüğüdür, bu sayıları yerine koyarak  $Z$  dağılımından bir güven rakamı (confidence) elde edebiliriz.

Bir örnek üzerinde görelim: diyelim ki elimizde bir Web sitesinin günlük ziyaret, tıklama sayılarını gösteren bir veri seti var (CVR ziyaretçilerin, sitedeki tıklayan müşteriye "cevirme" oranı, -conversion-)

```
import pandas as pd
from scipy import stats
a = pd.DataFrame({'tiklama': [20., 2., 40., 5., 10., 100.],
                  'ziyaret': [100., 10., 300., 400., 30., 800.]})
a['cvr'] = a['tiklama'] / a['ziyaret']
print a
```

	tiklama	ziyaret	cvr
0	20	100	0.200000
1	2	10	0.200000
2	40	300	0.133333
3	5	400	0.012500
4	10	30	0.333333
5	100	800	0.125000

Diyelim ki bu veri seti için cvr'in 0.16, yani yüzde 16 olduğunu önceden biliyoruz. Üstteki başarı oranı binom dağılımı ile modellenenebilir, ziyaretler "deneylerdir", yani örneklem büyüklüğünü gösterirler. Tıklama ise başarıdır,

```
p_hat = 0.16
btest = lambda x: (x['cvr']-p_hat) / np.sqrt( p_hat*(1-p_hat)/x['ziyaret'])
a['guven'] = a.apply(btest, axis=1)
a['guven'] = np.round(stats.zprob(a['guven'])*100, 2)
print a
```

	tiklama	ziyaret	cvr	guven
0	20	100	0.200000	86.24
1	2	10	0.200000	63.50
2	40	300	0.133333	10.39
3	5	400	0.012500	0.00
4	10	30	0.333333	99.52
5	100	800	0.125000	0.35

## Büyük Sayılar Kanunu

Olasılık kuramında önemli matematiksel bir denklem, büyük sayılar kanunudur. Bu kanun, tahmini olarak bildiğimiz günlük bir gerçeğin matematiksel ispatıdır da denebilir.

Yazı-tura atarken yazı çıkma ihtimalinin 1/2 olduğunu biliyoruz. Herhalde çoğumuz da bu yazı-tura işleminin "bir çok kere" tekrarlandığı durumda, toplam sonucun aşağı yukarı "yarısının" yazı olacağını tahmin biliyoruz. Bu tahminin matematiksel olarak söylemi, büyük sayılar kanunudur. Yıllarca önce Öklid'in geometriyi ispat ederek yaptığı gibi, matematiğe eklediğimizi her yeni bilgi dağarcığını önce matematiksel olarak ispatlamamız gerekiyor.

Farzedelim ki her yazı-tura atışı bir deney olsun. Her ayrı deneyin sonucu  $X_1, X_2, \dots, X_n$  olarak rasgelen değişkenlerle tanımlanmış olsun. Bu değişkenler ya 1 ya da 0 değeri taşıyacak, Yazı=1, Tura=0 olmak üzere.

Buna göre, n tane deneyden sonra elimize gelmesi gereken yazı oranı şudur.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

Büyük sayılar kanunu, n büyüdükçe  $\bar{X}_n$ 'in 1/2'ye yaklaştığını ispatlar.

Başlayalım.

$X_1, X_2, \dots, X_n$  bağımsız değişkenler olsun.

$$E(X_i) = \mu$$

$$\text{Var}(X_i) = \sigma$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

O zaman her  $\epsilon > 0$  için ve  $n \rightarrow \infty$ ,  $p(|\bar{X}_n - \mu|) \rightarrow 0$ .

Bu tanımlara göre, her rasgele değişkenin (deneyin) ortalaması aynı değerdir diyoruz. Bu zaten beklenir bir tanımdı, çünkü her rasgele değişkenin dağılımının aynı olduğunu kabul etmiştik. Her yazı tura aynı şartlar altında atılmazlar mı?

$\bar{X}_n$  de bir rasgele değişkendir, çünkü Büyük sayılar kanununu, matematiksel olarak,  $\bar{X}_n$  değişkeninin ortalamasını tekil olarak her  $X_i$  dağılımının (aynı olan) ortalaması arasında birkü onun da formülü başka rasgelen değişkenlere dayanıyor.

İspat devam etmek için, şapkalı  $X_n$  dağılımının beklentisini bulmamız gerekiyor.

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

E dogrusal bir islec (linear operator) oldugu icin disaridan iceri dogru nufuz eder.

$$= \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu$$

$$= \mu$$

$\bar{X}_n$  dagiliminin standart sapmasini da bulalım.

Diger bir olasilik kuramina gore

$$Y = a + bX$$

$$\text{Var}(Y) = b^2 \text{Var}(X)$$

oldugunu biliyoruz. O zaman,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} n\sigma^2 = \frac{\sigma^2}{n}$$

Artık Çebisev kuramini kullanmaya haziriz.

$$n \rightarrow \infty,$$

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Cebisev'den

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2}$$

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$$

$\sigma^2/n\epsilon^2$ 'in sifira gitmesi normal cunku n sonsuza gidiyor.

Peki  $P(|\bar{X}_n - \mu| > \epsilon)$ 'nin sifira gittigini gosterdik mi?

$\sigma^2/n\epsilon^2$ 'nin sifira gittigini gosterdik.  $\sigma^2/n\epsilon^2$  de  $P(|\bar{X}_n - \mu| > \epsilon)$ 'den buyuk olduguna gore, demek ki o da sifira iner.

Çebisev Eşitsizliđi

Olasilik matematiđinde, büyük sayilar kuramı adında anılan ve olasilik matematiđinin belkemiđini oluřturan kuramı ispatlamak için, diđer bir kuram olan Çebisev eşitsizliđini de anlamamız gerekiyor. Çebisev eşitsizliđi bir rasgele deđişken, onun ortalaması (beklentisi) ve herhangi bir sabit sayı arasındaki üçlü arasında bir 'eşitsizlik' bađlantısı kurar, ve bu bađlantı diđer olasilik işlemlerimizde ispat verisi olarak

işimize yarar.

Teori: Herhangi bir  $t$  değeri için,

$$P(|X - \mu| > t) \leq \frac{\sigma^2}{t^2}$$

İspata başlayalım. Entegral ile olasılık hesabı yapmak için bize bir  $x$  uzayı lazım.

$$R = x : |x - \mu| > t$$

Yani  $R$  uzayı,  $x$  ile ortalamasının farkının,  $t$ 'den büyük olduğu bütün sayıların kümesidir.

O zaman,

$$P(|X - \mu| > t) = \int_R f(x) dx$$

Dikkat edelim  $P(\cdot)$  içindeki formül, küme tanımı ile aynı. O yüzden  $P(\cdot)$  hesabı ortada daha olmayan, ama varolduğu kesin bir dağılım fonksiyonu tanımlamış da oluyor. Buna  $f(x)$  deriz.  $P(\cdot)$ 'in,  $f(x)$  fonksiyonunun  $R$  üzerinden entegral olduğunu olasılığa giriş dersinden bilmemiz lazım.

Eğer  $x \in R$  dersek o zaman

$$\frac{|x - \mu|^2}{t^2} \geq 1$$

$t$ 'nin denkleme bu şekilde nereden geldiği şaşkınlık yaratabilir. Daha önce tanımlanan şu ibareye dikkat edelim,  $x : |x - \mu| > t$  diye belirtmiştik. Bu ifadeyi değiştirerek, yukarıdaki denkleme gelebiliriz.

Devam edersek, elimizdeki 1'den büyük bir değer var. Bu değeri kullanarak, aşağıdaki tanımı yapmamız doğru olacaktır.

$$\int_R f(x) dx \leq \int_R \frac{(x - \mu)^2}{t^2} f(x) dx \leq \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

Ortadaki entegral niye birinci entegralden büyük? Çünkü ortadaki entegraldeki  $F(x) dx$  ibaresinden önce gelen kısmın, her zaman 1'den büyük olacağını belirttiğimize göre, ikinci entegralin birinciden büyük olması normaldir.

Evet...Üçüncü entegral ispata oldukça yaklaştı aslında. Standart sapma işaretini hala ortada göremiyoruz, fakat son entegraldeki ibare standart sapma değerini zaten içeriyor. Önce daha önceki olasılık natematığı bilgimize dayanarak, standart sapmanın tanımını yazıyoruz. Dikkat edelim, bu ibare şu anki ispatımız dahilinden değil, haricinden önceki bilgimize dayanarak geldi. Standart sapmanın tanımı şöyledir.

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

O zaman

$$\frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

yani

$$\int_{\mathbb{R}} f(x) dx \leq \frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

ki  $\int_{\mathbb{R}} f(x) dx$  zaten  $P(|X - \mu| > t)$  olarak tanımlanmıştır.

Kaynaklar

[1] [http://en.wikipedia.org/wiki/Confidence\\_interval](http://en.wikipedia.org/wiki/Confidence_interval)

[2] Janert, P., Data Analysis with Open Source Tools

[3] Introduction to Probability Models, Sheldon Ross, 8th Edition, sf. 273

<https://gist.github.com/mblondel/1761714>

Introductory Statistics with R

Introduction to Probability and Statistics Using R