

Ekler (Appendix)

Bayes Usulu Guven Araligi (Confidence Intervals)

Bayes ile bu hesabi yapmak icin bir dagilimi baz almak lazim. Eger sonuc olarak bir tekil sayi degil, bir dagilim elde edersek bu dagilim uzerinde guvenlik hesaplarini yapariz. Mesela sonuc, sonsal dagilim (posterior) bir Gaussian dagilim ise, bu dagilimin yuzde 95 agirliginin nerede oldugu, ve nasil hesaplandigi bellidir.

Bayes Teorisi

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Veri analizi baglaminda diyelim ki deneyler yaparak tahmini olarak hesaplamak (estimate) istedigimiz bir parametre var, bu bir protonun kutlesi ya da bir ameliyat sonrasi hayatta kalma orani olabilir. Bu durumlarda iki ayri "olaydan" bahsetmemiz gerekir, B olayi spesifik bazi olcumlerin elde edilmesi "olayidir", mesela olcum uc sayidan olusuyorsa, biz bir olcumde spesifik olarak {0.2, 4, 5.4} degerlerini elde etmisiz. Ikinci olay bilmedigimiz parametrenin belli bir degere sahip olmasi olacak. O zaman Bayes Teorisinin su sekilde tekrar yazabiliriz,

$$P(\text{parametre}|\text{veri}) \propto P(\text{data}|\text{parametre})P(\text{parametre})$$

\propto isareti orantili olmak (proportional to) anlamina geliyor. Boleni attik cunku o bir sabit (tamamen veriye bagli, tahmini hesaplamak istedigimiz parametreye bagli degil). Tabii bu durumda sol ve sag taraf birbirine esit olmaz, o yuzden esitlik yerine orantili olmak isaretini kullandik. Bu cercevede "belli bir numerik sabit cercevesinde birbirine esit (equal within a numeric constant)" gibi cumleler de gorulebilir.

Ornek

Diyelim ki bir bozuk para ile 10 kere yazi-tura attik, ve sonuc altta

T H H H H T T H H H

Bu veriye bakarak paranin hileli olup olmadigini anlamaya calisacagiz. Bayes ifadesini bu veriye gore yazalim,


$$P(p|\{T H H H H T T H H H\}) \propto P(\{T H H H H T T H H H|p\})P(p)$$

$P(p)$ ifadesi ne anlama gelir? Aslinda bu ifadeyi $P([Dagilim] = p)$ olarak gormek daha iyi, artik p parametresini bir dagilimdan gelen bir tekil deger olarak gordugumuze gore, o dagilimin belli bir p 'ye esit oldugu zamani modelliyoruz burada. Her halukarda $P(p)$ dagilimini, yani onsel (prior) olasiligi bilmiyoruz, hesaptan once her degerin mumkun oldugunu biliyoruz, o zaman bu onsel dagilimi duz (flat) olarak aliriz, yani $P(p) = 1$.

$P(\{T H H H H T T H H H|p\})$ ifadesi göz korkutucu olabilir, ama buradaki her oğenin bağımsız özdeşçe dağılmış (independent identically distributed) olduğunu görürsek, ama bu ifadeyi ayrı ayrı $P(\{T|p\})$ ve $P(\{H|p\})$ çarpımları olarak görebiliriz. $P(\{T|p\}) = p$ ve $P(\{H|p\}) = 1 - p$ olduğunu biliyoruz. O zaman

$$P(p|\{7 \text{ Tura}, 3 \text{ Yazı}\}) \propto p^7(1-p)^3$$

Grafiklersek,



Boylece p için bir sonsal dağılım elde ettik. Artık bu dağılımın yüzde 95 ağırlığının nerede olduğunu rahatça görebiliriz / hesaplayabiliriz. Dağılımın tepe noktasının $p = 0.7$ civarında olduğu görülüyor. Bir dağılımı daha fazlasını yapmak mümkün, mesela bu fonksiyonu p 'ye bağlı başka bir fonksiyona karşı entegre etmek mümkün, mesela beklentiği bu şekilde hesaplayabiliriz.

Onsel dağılımın her noktaya eşit ağırlık veren bir örnek (uniform) seçilmiş olması, yani problemi çözmeye sıfır bilgidan başlamış olmamız, yöntemin bir zayıflığı olarak görülmemeli. Yöntemin kuvveti elimizdeki bilgiyle başlayıp onu net bir şekilde veri ve olurluk üzerinden sonsal tek dağılıma götürebilmesi. Başlangıç ve sonuç arasındaki bağlantı gayet net. Fazlası da var; ilgilendığımız alanı (domain) öğrendikçe, basta hiç bilmediğimiz onsel dağılımı daha net, bilgili bir şekilde seçebiliriz ve bu sonsal dağılımı da daha olması gereken modele daha yaklaştırabilir.

Cok Boyutlu Gaussian'ı Parcalamak (Partitioning)

Diyelim ki Normal bir vektör X 'i $X = (X_1, X_2)$ olarak parcaladık. Bunu Gaussian'a etkileri ne olur? Aynı şekilde $\mu = (\mu_1, \mu_2)$ olarak parcalayabiliriz. Σ ise

$$\Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}$$

olarak parçalanabilir. a, b 'nin parçalarının boyutları p, q olsun, $n = p + q$.

Simdi birlesik Gaussian'i

$$f(x; \mu, \Sigma) = \frac{1}{(2\pi)^{(p+q)/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

Birlesik yogunlugu parcalar uzerinden belirtirsek, bu yogunlugu X_2 icin bilesen yogunluga ve X_1 icin bir kosullu yogunluga ayirabiliriz. Yani

$$f(x_1, x_2) = f(x_1|x_2)f(x_2)$$

tanimindaki parcalar elde etmeye calisacagiz. Ama bundan once boluntulenmis matrislere yakindan bakalim.

Bir boluntulenmis (partitioned) matrisin tersini almak icin, o matrisin parcalarinin tersini almak dogru degildir, yani

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} \neq \begin{bmatrix} E^{-1} & F^{-1} \\ G^{-1} & H^{-1} \end{bmatrix}$$

Tersini alma islemi icin bazi numaralar lazim. Ana numara boluntulenmis matrisi kosegen bir matris haline getirmek, cunku kosegen matrislerin tersi, kosegendeki elemanlari tersidir, yani ters alma operasyonu bu tur matrislerin "icine isler", o yuzden bir sekilde bir kosegen matris elde etmeye ugrasacagiz. Bunun icin boluntulenmis matrisimizi sagdan ve soldan bazi matrislerle carpacagiz. Ayrica sunu da bilelim,

$$XYZ = W$$

durumunda Y 'nin tersini almak istersek, sag ve soldaki X, Z matrislerinin tersini almak gerekmez, niye?

$$X^{-1}XYZ = X^{-1}W$$

$$YZZ^{-1} = X^{-1}WZ^{-1}$$

$$Y = X^{-1}WZ^{-1}$$

Simdi iki tarafin da tersini alalim,

$$Y^{-1} = ZW^{-1}X$$

Tamam, baslayalim.

$$M = \begin{bmatrix} E & F \\ G & H \end{bmatrix}$$

matrisini kosegen yapacagiz. Eger sadece alt sol koseyi sifirlayasaydik, bunu yapacak ozel bir matrisle soldan carpardik,

$$\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} = \begin{bmatrix} E & F \\ 0 & H \end{bmatrix}$$

Sadece ust sag koseyi sifirlamak isteseydik, sagdan carpardik

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix} \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} = \begin{bmatrix} E & 0 \\ G & H \end{bmatrix}$$

Hepsini biraraya koyelim,

$$\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} E & F \\ G & H \end{bmatrix} \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} = \begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix} \quad (2)$$

Bu carpimin dogrulugu carpim elle yapilarak kontrol edilebilir.

Ustte gordugumuz gibi

$$XYZ = W$$

ifadesindeki Y'nin tersi

$$Y^{-1} = ZW^{-1}X$$

ile olur.

$$\underbrace{\begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}}_X \underbrace{\begin{bmatrix} E & F \\ G & H \end{bmatrix}}_Y \underbrace{\begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix}}_Z = \underbrace{\begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}}_W$$

O zaman

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} = \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} \begin{bmatrix} E - FH^{-1}G & 0 \\ 0 & H \end{bmatrix}^{-1} \begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix}$$

Daha kısa olmasi esitligin sag tarafinda, ortadaki matris icin $E - FH^{-1}G$ yerine M/H kullanalim (bu arada M/H lineer cebirde “M’in H’e gore Schur tamamlayicisi (complement)” olarak bilinir),

$$\begin{bmatrix} E & F \\ G & H \end{bmatrix}^{-1} = \begin{bmatrix} I & 0 \\ -H^{-1}G & I \end{bmatrix} \begin{bmatrix} (M/H)^{-1} & 0 \\ 0 & H^{-1} \end{bmatrix} \begin{bmatrix} I & -FH^{-1} \\ 0 & I \end{bmatrix} \quad (3)$$

Esitligin sag tarafindaki carpimi gerceklestirirsek,

$$= \begin{bmatrix} (M/H)^{-1} & -(M/H)^{-1}FH^{-1} \\ -H^{-1}G(M/H)^{-1} & H^{-1} + H^{-1}G(M/H)^{-1}FH^{-1} \end{bmatrix}$$

Bu final ifade boluntulenmis bir matrisin tersini o matrisin icindeki parcalar uzerinden temsil eden bir ifadedir.

Icinde bir kosesi sifir olan boluntulenmis matrislerde determinantlar soyle isler,

$$\det \left(\begin{bmatrix} E & 0 \\ G & H \end{bmatrix} \right) = \det \left(\begin{bmatrix} E & F \\ 0 & H \end{bmatrix} \right) = \det(E) \det(H)$$

Ayrica

$$\det(AB) = \det(A) \det(B)$$

O zaman (2)'nin determinantini alırsak, \det yerine $||$ kullandık,

$$|M| = |M/H||H| \quad (4)$$

Bu ifade gayet dogal duruyor (bir raslanti herhalde, ya da Schur tamamlayicisi isareti ozellikle boyle secilmis),

Boluntulenmis bir matrisin devrigini almak icin her blogunun ayri ayri devrigi alinir, ve tum blokların yani boluntulenmis tamaminin bir daha devrigi alinir, yani

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^T = \begin{bmatrix} A^T & C^T \\ B^T & D^T \end{bmatrix}$$

Simdi cok degiskenli Normal icin bilesten ve kosullu yogunluk hesaplarına geelim. Gaussian formulunun exp kismini alırsak,

$$\exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}^{-1} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

(3)'teki acilimi kullanırsak, ve $E = \Sigma_{11}, F = \Sigma_{12}, \dots$ olacak sekilde,

$$\exp \left\{ -\frac{1}{2} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix}^T \begin{bmatrix} I & 0 \\ -\Sigma_{22}^{-1}\Sigma_{21} & I \end{bmatrix} \begin{bmatrix} (\Sigma/\Sigma_{22}) & 0 \\ 0 & \Sigma_{22}^{-1} \end{bmatrix} \begin{bmatrix} I & -\Sigma_{12}\Sigma_{22}^{-1} \\ 0 & I \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \right\}$$

Acilimi tamamen yaparsak,

$$= \exp \left\{ -\frac{1}{2} (x_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2))^T (\Sigma/\Sigma_{22})^{-1} (x_1 - \mu_1 - \Sigma_{12}\Sigma_{22}^{-1}(x_2 - \mu_2)) \right\} \cdot \exp \left\{ \frac{1}{2} (x_2 - \mu_2)^T \Sigma_{22}^{-1} (x_2 - \mu_2) \right\}$$

Not: $\Sigma_{12}^T = \Sigma_{21}$. Ustte birinci exp icinde sol bolumde devrigin icindeki ifadelerden, mesela x_1^T, μ_1^T 'den ve Σ_{21} 'li ifadeden devrik islemini cekip, buyuk paranteze alinca bu degisim oldu.

Simdi mesela 1. \exp 'ye dikkat edersek, ortada $(\Sigma/\Sigma_{22})^{-1}$ var, ve bu ifadenin solunda ve saginda birbirinin devrigi olan ayni terimler duruyor. Ifadenin tamami bir Normal dagilim. Ayni sey 2. \exp icin gecerli.

Isin exp tarafini halletik. Simdi exp oncesindeki kesiri (4) kullanarak parcalayalım,

$$\begin{aligned} \frac{1}{(2\pi)^{(p+q)/2} \det(\Sigma)^{1/2}} &= \frac{1}{(2\pi)^{(p+q)/2} \left(\det(\Sigma/\Sigma_{22}) \det(\Sigma_{22}) \right)^{1/2}} \\ &= \left(\frac{1}{(2\pi)^{p/2} \det(\Sigma/\Sigma_{22})^{1/2}} \right) \left(\frac{1}{(2\pi)^{q/2} \det(\Sigma_{22})^{1/2}} \right) \end{aligned}$$

Bu parçaların her birini ayrı bir exp onunde kullanabiliriz, ve ikinci exp ifadesinin

$$\frac{1}{(2\pi)^{q/2} \det(\Sigma_{22})^{1/2}} \exp \left\{ \frac{1}{2} (x_2 - \mu_2)^T \Sigma_{22}^{-1} (x_2 - \mu_2) \right\}$$

oldugunu goruyoruz. Bu ifade $f(x_2)$ bilesen yogunlugudur! O zaman geri kalanlar, yani diger kesir ve birinci exp hep beraber $f(x_1|x_2)$ yogunlugu olmalidir. Yani,

$$\frac{1}{(2\pi)^{p/2} \det(\Sigma/\Sigma_{22})^{1/2}} \exp \left\{ -\frac{1}{2} (x_1 - \mu_1 - \Sigma_{12} \Sigma_{22}^{-1} (x_2 - \mu_2))^T (\Sigma/\Sigma_{22})^{-1} (x_1 - \mu_1 - \Sigma_{12} \Sigma_{22}^{-1} (x_2 - \mu_2)) \right\}$$

Buradan genel bir kural cikartabiliriz,

1) X_2 'nin bilesen yogunlugu $X_2 \sim N(\mu_2, \Sigma_{22})$

2) $X_2 = x_2$ olmak uzere X_1 'in kosullu dagilimi

$$X_1|X_2 = x_2 \sim N \left(\mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (x_2 - \mu_2), \Sigma/\Sigma_{22} \right)$$

Σ/Σ_{22} nedir? Hatirlarsak, $M/H = E - FH^{-1}G$, ve $E = \Sigma_{11}$, $F = \Sigma_{12}$, .. o zaman

$$\Sigma/\Sigma_{22} = \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$$

Yani

$$X_1|X_2 = x_2 \sim N \left(\mu_1 + \Sigma_{12} \Sigma_{22}^{-1} (x_2 - \mu_2), \Sigma_{11} - \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \right)$$

Moment

Olasılık matematiğinde "moment üreten işlevler" olarak adlandırılan, başlangıçta pek yararlı gibi gözükmesede bir takım matematiksel özellikleri olduğu için, ispatlarda oldukça işe yarayan bir kavram vardır.

Her rasgele değişkenin bir dağılımı olduğunu biliyoruz. Her rasgele değişkenin de ayrıca bir moment üreten fonksiyonu da vardır. Ayrıca, moment üreten fonksiyon ile rasgele değişken arasında bire-bir olarak bir ilişki mevcuttur. "Bu neye yarar?" diye sorulabilir; Cevap olarak, mesela cebirsel olarak türete türete bir moment'e geldiğimiz düşünelim, ve tekrar başka bir taraftan, başka bir formülden gene türete türete tekrar aynı moment işlevine geliyorsak, bu demektir ki, iki taraftan gelen rasgele değişkenler (ve tekabül eden dağılımları) birbirine eşittir. Bazı şartlarda moment üreten işlevler ile cebir yapmak, dağılım fonksiyonlarından daha rahat olmaktadır.

Her rasgele değişken için, moment üreten işlev şöyle bulunur.

X rasgele degiskenin moment ureten operasyonu

$$M(t) = E(e^{tX}) \text{ olarak gosterilir}$$

Ayriksal operasyonlar icin

$$M(t) = \sum_x e^{tx} p(x)$$

Surekli islevler icin

$$M(t) = \int_{-\infty}^{\infty} e^{tx} f(x) dx$$

Kuram

Gelelim yazımızın esas konusu olan kuramımıza.

Eğer X_1, X_2, \dots, X_n bağımsız rasgele değişken ise, ve her değişkenin $M_i(t)$ $i = 1, 2, 3, \dots, n$ olarak, öz olarak aynı olan birer moment üreten işlevi var ise, o zaman,

$$Y = \sum_{i=1}^n a_i X_i$$

acilimi

$$M_y(t) = \prod_{i=1}^n M(a_i t)$$

olacaktır.

Ispat

$$M_y(t) = E(e^{tY}) = E(e^{t(a_1 X_1 + a_2 X_2 + \dots + a_n X_n)})$$

$$= E[\exp(t a_1 X_1 + t a_2 X_2 + \dots + t a_n X_n)]$$

$$= E[\exp(t a_1 X_1) + \exp(t a_2 X_2) + \dots + \exp(t a_n X_n)]$$

$$= E[\exp(t a_1 X_1)] + E[\exp(t a_2 X_2)] + \dots + E[\exp(t a_n X_n)]$$

Daha once belirttigimiz gibi

$$M_i(t) = E[\exp(t X_i)]$$

olduguna gore ve t yerine $t a_i$ koyuldugunu dusunelim

$$M_y(t) = \prod_{i=1}^n M_y(a_i t)$$

olacaktır.

Bunu $M_y(t) = (M_i(a_i t))^n$ şeklinde de gösterebiliriz.

Orneklem Dağılımları (Sampling Distributions)

Diyelim ki elimizde (hakkında) öğrenmek istediğimiz bir sayısal obek (population) var. Bu obekteki her elemanı ayrı ayrı incelemek istemiyoruz, problem değil, nüfustan bir örneklem (sample) alıriz. Eğer bu örneklem nüfusu yeterince iyi temsil ediyorsa, problem çıkmaz. Bu temsiliyeti garantilemenin iyi bir yolu örneklemi rasgele yapmaktır.

Şimdi, diyelim ki, bu örneklemi bir şekilde özetlemek istiyoruz yani örneklem verisi kullanılarak hesaplanmış temsili bir istatistik (descriptive statistic) elde edeceğiz.

Fakat örneklemimiz rasgele idi. Bu istatistikimiz (ki o da sonuçta bir rasgele değiskendir ve onun da bir dağılımı vardır), nasıl bir dağılıma sahiptir? Yani nüfus dağılımı (population distribution), ve örneklem dağılımının (sampling distribution) birbiriyle bağlantısıyla ilgileniyoruz.

Teori

Eğer X_1, \dots, X_n bir $N(\mu, \sigma)$ dağılımında alınmış örneklem olsun. O zaman örneklem ortalamasının dağılımı $N(\mu, \sigma/\sqrt{n})$.

[TBD - İspat]

Teori

Eğer X_1, \dots, X_n bir $N(\mu, \sigma)$ dağılımında alınmış örneklem olsun. O zaman şu büyüklük


$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}}$$

t_{n-1} dağılımına, yani $n - 1$ serbestlik derecesindeki (degree of freedom) bir Student's t Dağılımıdır.

[TBD - İspat]

z-Tablosu

Nasil okunur? Z-degeri -0.8994 icin z kolonundan asagi inilir, ve -0.8 bulunur, x.x9xx yani 9 icin .09 kolonuna gidilir ve bu kesismedeki deger okunur, .1867, yuvarlanarak .19 da kabul edilebilir.



z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
-3.4	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0003	.0002
-3.3	.0005	.0005	.0005	.0004	.0004	.0004	.0004	.0004	.0004	.0003
-3.2	.0007	.0007	.0006	.0006	.0006	.0006	.0006	.0005	.0005	.0005
-3.1	.0010	.0009	.0009	.0009	.0008	.0008	.0008	.0008	.0007	.0007
-3.0	.0013	.0013	.0013	.0012	.0012	.0011	.0011	.0011	.0010	.0010
-2.9	.0019	.0018	.0018	.0017	.0016	.0016	.0015	.0015	.0014	.0014
-2.8	.0026	.0025	.0024	.0023	.0023	.0022	.0021	.0021	.0020	.0019
-2.7	.0035	.0034	.0033	.0032	.0031	.0030	.0029	.0028	.0027	.0026
-2.6	.0047	.0045	.0044	.0043	.0041	.0040	.0039	.0038	.0037	.0036
-2.5	.0062	.0060	.0059	.0057	.0055	.0054	.0052	.0051	.0049	.0048
-2.4	.0082	.0080	.0078	.0075	.0073	.0071	.0069	.0068	.0066	.0064
-2.3	.0107	.0104	.0102	.0099	.0096	.0094	.0091	.0089	.0087	.0084
-2.2	.0139	.0136	.0132	.0129	.0125	.0122	.0119	.0116	.0113	.0110
-2.1	.0179	.0174	.0170	.0166	.0162	.0158	.0154	.0150	.0146	.0143
-2.0	.0228	.0222	.0217	.0212	.0207	.0202	.0197	.0192	.0188	.0183
-1.9	.0287	.0281	.0274	.0268	.0262	.0256	.0250	.0244	.0239	.0233
-1.8	.0359	.0351	.0344	.0336	.0329	.0322	.0314	.0307	.0301	.0294
-1.7	.0446	.0436	.0427	.0418	.0409	.0401	.0392	.0384	.0375	.0367
-1.6	.0548	.0537	.0526	.0516	.0505	.0495	.0485	.0475	.0465	.0455
-1.5	.0668	.0655	.0643	.0630	.0618	.0606	.0594	.0582	.0571	.0559

-1.4 .0808 .0793 .0778 .0764 .0749 .0735 .0721 .0708 .0694 .0681
-1.3 .0968 .0951 .0934 .0918 .0901 .0885 .0869 .0853 .0838 .0823
-1.2 .1151 .1131 .1112 .1093 .1075 .1056 .1038 .1020 .1003 .0985
-1.1 .1357 .1335 .1314 .1292 .1271 .1251 .1230 .1210 .1190 .1170
-1.0 .1587 .1562 .1539 .1515 .1492 .1469 .1446 .1423 .1401 .1379
-0.9 .1841 .1814 .1788 .1762 .1736 .1711 .1685 .1660 .1635 .1611
-0.8 .2119 .2090 .2061 .2033 .2005 .1977 .1949 .1922 .1894 .1867
-0.7 .2420 .2389 .2358 .2327 .2296 .2266 .2236 .2206 .2177 .2148
-0.6 .2743 .2709 .2676 .2643 .2611 .2578 .2546 .2514 .2483 .2451
-0.5 .3085 .3050 .3015 .2981 .2946 .2912 .2877 .2843 .2810 .2776
-0.4 .3446 .3409 .3372 .3336 .3300 .3264 .3228 .3192 .3156 .3121
-0.3 .3821 .3783 .3745 .3707 .3669 .3632 .3594 .3557 .3520 .3483
-0.2 .4207 .4168 .4129 .4090 .4052 .4013 .3974 .3936 .3897 .3859
-0.1 .4602 .4562 .4522 .4483 .4443 .4404 .4364 .4325 .4286 .4247
0.0 .5000 .4960 .4920 .4880 .4840 .4801 .4761 .4721 .4681 .4641

z	.00	.01	.02	.03	.04	.05	.06	.07	.08	.09
0.0	.5000	.5040	.5080	.5120	.5160	.5199	.5239	.5279	.5319	.5359
0.1	.5398	.5438	.5478	.5517	.5557	.5596	.5636	.5675	.5714	.5753
0.2	.5793	.5832	.5871	.5910	.5948	.5987	.6026	.6064	.6103	.6141
0.3	.6179	.6217	.6255	.6293	.6331	.6368	.6406	.6443	.6480	.6517
0.4	.6554	.6591	.6628	.6664	.6700	.6736	.6772	.6808	.6844	.6879
0.5	.6915	.6950	.6985	.7019	.7054	.7088	.7123	.7157	.7190	.7224
0.6	.7257	.7291	.7324	.7357	.7389	.7422	.7454	.7486	.7517	.7549
0.7	.7580	.7611	.7642	.7673	.7704	.7734	.7764	.7794	.7823	.7852
0.8	.7881	.7910	.7939	.7967	.7995	.8023	.8051	.8078	.8106	.8133
0.9	.8159	.8186	.8212	.8238	.8264	.8289	.8315	.8340	.8365	.8389
1.0	.8413	.8438	.8461	.8485	.8508	.8531	.8554	.8577	.8599	.8621
1.1	.8643	.8665	.8686	.8708	.8729	.8749	.8770	.8790	.8810	.8830
1.2	.8849	.8869	.8888	.8907	.8925	.8944	.8962	.8980	.8997	.9015
1.3	.9032	.9049	.9066	.9082	.9099	.9115	.9131	.9147	.9162	.9177
1.4	.9192	.9207	.9222	.9236	.9251	.9265	.9279	.9292	.9306	.9319
1.5	.9332	.9345	.9357	.9370	.9382	.9394	.9406	.9418	.9429	.9441
1.6	.9452	.9463	.9474	.9484	.9495	.9505	.9515	.9525	.9535	.9545
1.7	.9554	.9564	.9573	.9582	.9591	.9599	.9608	.9616	.9625	.9633
1.8	.9641	.9649	.9656	.9664	.9671	.9678	.9686	.9693	.9699	.9706
1.9	.9713	.9719	.9726	.9732	.9738	.9744	.9750	.9756	.9761	.9767
2.0	.9772	.9778	.9783	.9788	.9793	.9798	.9803	.9808	.9812	.9817
2.1	.9821	.9826	.9830	.9834	.9838	.9842	.9846	.9850	.9854	.9857
2.2	.9861	.9864	.9868	.9871	.9875	.9878	.9881	.9884	.9887	.9890
2.3	.9893	.9896	.9898	.9901	.9904	.9906	.9909	.9911	.9913	.9916
2.4	.9918	.9920	.9922	.9925	.9927	.9929	.9931	.9932	.9934	.9936
2.5	.9938	.9940	.9941	.9943	.9945	.9946	.9948	.9949	.9951	.9952
2.6	.9953	.9955	.9956	.9957	.9959	.9960	.9961	.9962	.9963	.9964
2.7	.9965	.9966	.9967	.9968	.9969	.9970	.9971	.9972	.9973	.9974
2.8	.9974	.9975	.9976	.9977	.9977	.9978	.9979	.9979	.9980	.9981

2.9 .9981 .9982 .9982 .9983 .9984 .9984 .9985 .9985 .9986 .9986
3.0 .9987 .9987 .9987 .9988 .9988 .9989 .9989 .9989 .9990 .9990
3.1 .9990 .9991 .9991 .9991 .9992 .9992 .9992 .9992 .9993 .9993
3.2 .9993 .9993 .9994 .9994 .9994 .9994 .9994 .9995 .9995 .9995
3.3 .9995 .9995 .9995 .9996 .9996 .9996 .9996 .9996 .9996 .9997
3.4 .9997 .9997 .9997 .9997 .9997 .9997 .9997 .9997 .9997 .9998