

MCMC, Degisim Nokta Hesabi, Gibbs Orneklemesi, Bayes Teorisi

Ingiltere’de 1851 ve 1962 yillari arasinda komur madenlerinde olan kazalarin sayisi yillik olarak kayitli . Acaba bu kazalarin ”oraninin” degisimine bakarak, degisimin oldugu seneyi bulabilir miyiz? Boyle bir degisim ani neyi gosterir? Belki madenlerle alakali regulasyonlarda, denetimlerde bir degisiklik olmustur, ve kaza orani azalmistir.

Bu hesabi yapabilmek icin ”degisim noktası” hesabi (change-point analysis), ve Bayes kurali ile Bayes formullerini hesaplamamizi saglayan Markov Chain Monte Carlo (MCMC) teknigine bakacagiz. Kazalarin sayisinin tumunu iki Poisson dagiliminin ortak dagilimi (joint distribution) uzerinden modelleyecegiz, ve bu dagilimlarin birinci Poisson’dan ikincisine gectigi ani hesaplamaya ugrasacagiz.

Once Bayes, dagilimlar konusuna bir bakalim:

Poisson dagilimi

$$p(y|\theta) = \frac{e^{-\theta} \theta^y}{y!}$$

Eldeki n tane veri noktası $y = y_0, y_1, \dots, y_n$ ’nin hep birlikte θ ile tanimli bir Poisson dagilimindan gelip gelmediginin ne kadar mumkun oldugu (likelihood) hesabi soyledir:

$$p(y|\theta) = \frac{e^{-n\theta} \theta^{\sum y_i}}{\prod y_i!}$$

Formulun bolunen kisimindeki tum y noktaları toplaniyor, bolen kisminde ise tum y degerleri teker teker faktoryel hesabi sonrasi birbiri ile carpiliyor.

Simdi yukaridaki θ degiskeni de noktasal bir deger yerine bir ”dagilima”, mesela θ Gamma dagilimina sahip olabilirdi: $\text{Gamma}(\alpha, \beta)$. Formulde α, β sabit degerlerdir (fonksiyon degiskeni degil). Gamma olasilik formulu soyledir:

$$p(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}$$

O zaman $p(y|\theta)$ formulu bulmak icin Bayes teorisini kullanmamiz gerekecekti. Bayes teorisi bilindigi gibi

$$p(\theta|y) = \frac{p(y|\theta)p(\theta)}{p(y)}$$

$$p(\theta|y) \propto p(y|\theta)p(\theta)$$

İkinci formüle dikkat, esitlik yerine orantili olma (proportional to) isaretini kullanıyor. Sebep: bolen kismindaki $p(y)$ 'yi kaldirdik, sonuc olarak soldaki $p(\theta|y)$ degeri artik bir dagilim degil – bu bir bakimdan onemli ama ornekleme amaci icin bir fark yaratmiyor, basitlestirme amaciyla bunu yaptik, Boylece $p(y)$ 'yi hesaplamamiz gerekmeyecek, ama ornekleme uzerinden diger tum hesaplar hala yapabiliriz. Tamam.

Simdi Bayes Teorisini Gamma oncul (apriori) ve Poisson mumkunlugu (likelihood) uzerinden kullanirsak,

$$p(\theta|y) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} \times \frac{e^{-n\theta} \theta^{\sum y}}{\prod y!}$$

Benzer terimleri yanyana getirelim:

$$p(\theta|y) = \frac{\beta^\alpha}{\Gamma(\alpha) \prod y!} \theta^{\alpha-1} \theta^{\sum y} e^{-\beta\theta} e^{-n\theta}$$

Simdi sol taraftaki bolumu atalim; yine usttekinde benzer numara, bu kisim gidince geri galan dagilim olamayacak, ama ona "oranli" baska bir formül olacak.

$$p(\theta|y) \propto \theta^{\alpha-1} \theta^{\sum y} e^{-\beta\theta} e^{-n\theta}$$

$$\propto \theta^{\alpha-1+\sum y} e^{-(\beta+n)\theta}$$

Bu dagilim nedir? Formülün sag tarafi Gamma dagiliminin formülüne benzemiyor mu? Evet, formülün sag tarafi $\text{Gamma}(\alpha + \sum y, \beta + n)$ dagilimi, yani ona orantili olan bir formül. Yani Bayes teorisi uzerinden sunu anlamis olduk; eger oncul dagilim Gamma ise, Poisson mumkunluk bizi tekrar Gamma sonuc dagilimine goturuyor. Gamma'dan baslayınca tekrar Gamma'ya ulasiyoruz. Bu bir rahatlik, bir kolaylik, bir matematiksel numara olarak kullanilabilir. Sonuc (posterior) dagilimlerin sekli, hesaplanma, cebirsel islemler acisinden onemli, eger temiz, kisa, oz olurlarsa hesap islerimiz kolaylasir.

Not: Hatta uzerinde calistigimiz problem sebebiyle eger Poisson mumkunluk olacagini biliyorsak, sadece bu sebeple bile oncul dagilimi, ustteki kolaylik bilindigi icin, ozellikle Gamma secebiliriz, cunku biliriz ki Gamma ile baslarsak elimize tekrar Gamma gececektir.

Simdi komur madeni verisine geelim. Bu madendeki kazalarin sayisinin Poisson dagilimindan geldigini one suruyoruz, ve kazalarin "iki turlu" oldugunu bildigimizden hareketle, birinci tur kazalarin ikinci tur kazalardan degisik Poisson parametresi kullandigini one surecegiz.

O zaman degisim anini, degisim senesini nasil hesaplariz?

Kazaların ilk k senede ortalama θ ile, ve k ve n arasındaki senelerde ortalama λ Poisson ile dağıldığını söyleyelim: Yani

$$Y_i = \text{Poisson}(\theta) \quad i = 1, \dots, k$$

$$Y_i = \text{Poisson}(\lambda) \quad i = k + 1, \dots, n$$

Burada Y_i sene i sırasında olan kazaların sayısını belirtiyor. Bayes kuralını hatırlarsak θ ve λ parametrelerine öncül dağılım atayacağız. Bu dağılım Gamma olacak. Yani $\theta \sim \text{Gamma}(a_1, b_1)$ ve $\lambda \sim \text{Gamma}(a_2, b_2)$.

Ayrıca k değerini de bilmiyoruz, k değeri yani "değişim noktası" Poisson dağılımların birinden ötekine geçtiği andır. Bu seneyi bulmaya çalışıyoruz. Şimdi tüm verinin, tüm seneleri kapsayacak şekilde modelini kurmaya başlayalım. k parametresinin aynen öteki parametreler gibi bir öncül dağılımı olacak (ki sonradan elimize k için de bir sonuç dağılımı geçecek), ama bu parametre elimizdeki 112 senenin herhangi birinde "esit olasılıkta" olabileceği için onun öncül dağılımı Gamma değil $k \sim \text{Unif}(1, 112)$ olacak. Yani ilk basta her senenin olasılığı birbiriyle eşit, her sene $\frac{1}{112}$ olasılık değeri taşıyor.

Bu modelin tamaminin mümkünlüğü nedir?

$$L(\theta, \lambda, k|y) = \frac{1}{112} \times \prod_{i=1}^k \frac{e^{-\theta} \theta^{y_i}}{y_i!} \times \prod_{i=k+1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!}$$

Eğer sonuç (posterior) geçisini yapınca yukarıda olduğu gibi Gamma dağılımlarını elde ederiz:

$$L(\theta, \lambda, k|y) \propto \theta^{a_1-1+\sum_{i=1}^k y_i} e^{-(b_1+k)\theta} \lambda^{a_2-1+\sum_{i=k+1}^n y_i} e^{-(b_2+n-k)\lambda}$$

$\frac{1}{112}$ 'yi bir sabit olduğu için formülden attık, bu durum orantili hali etkilemiyor. Üstteki formül içindeki Gamma dağılımlarını görebiliyoruz, hemen yerlerine koyalım:

$$L(\theta, \lambda, k|y) \propto \text{Gamma}(a_1 + \sum_{i=1}^k y_i, b_1 + k) \text{Gamma}(a_2 + \sum_{i=k+1}^n y_i, b_2 + n - k)$$

Gibbs örneklemeye gelelim. Bu örneklemeye göre sartsal dağılım (conditional distribution) formülü bulunmaya uğrılır, hangi değişkenlerin verili olduğuna göre, o değişkenler sabit kabul edilebilir, ve orantisal formülden atılabilir. Bu her değişken için teker teker yapılır.

Sorna hesap sırasında her sartsal dağılıma teker teker zar atılır, ve elde edilen değer, bu sefer diğer sartsal dağılımlara değer olarak geçilir. Bu işlem sonuca

erisilinceye kadar ozyineli (iterative) olarak tekrar edilir (mesela 1000 kere). O zaman,

$$\theta|Y_1, \dots, Y_n, k \sim \text{Gamma}(a_1 + \sum_{i=1}^k y_i, b_1 + k)$$

$$\lambda|Y_1, \dots, Y_n, k \sim \text{Gamma}(a_2 + \sum_{i=k+1}^n y_i, b_2 + n - k)$$

$$p(k|Y_1, \dots, Y_n) \propto \theta^{\sum_{i=1}^k y_i} e^{-k\theta} \lambda^{\sum_{i=k+1}^n y_i} e^{k\lambda}$$

En son formülde icinde k olan terimleri tuttuk, gerisini attik. Formül e terimleri birlestirilerek biraz daha basitlestirilebilir:

$$p(k|Y_1, \dots, Y_n) \propto \theta^{\sum_{i=1}^k y_i} \lambda^{\sum_{i=k+1}^n y_i} e^{(\lambda-\theta)k}$$

Bir basitlestirme daha soyle olabilir

$$K = \sum_{i=1}^k y_i$$

$$\lambda^{\sum_{i=k+1}^n y_i} = \lambda^{\sum_{i=1}^n y_i - \sum_{i=1}^k y_i}$$

Ustel islemlerde eksi isareti, ustel degisken ayrilınca bolum islemine donusur:

$$= \frac{\lambda^{\sum_{i=1}^n y_i}}{\lambda^{\sum_{i=1}^k y_i}}$$

$$= \frac{\lambda^{\sum_{i=1}^n y_i}}{\lambda^K}$$

$$p(k|Y_1, \dots, Y_n) \propto \theta^K \frac{\lambda^{\sum_{i=1}^n y_i}}{\lambda^K} e^{(\lambda-\theta)k}$$

$$= \left(\frac{\theta}{\lambda}\right)^K \lambda^{\sum_{i=1}^n y_i} e^{(\lambda-\theta)k}$$

$\lambda^{\sum_{i=1}^n y_i}$ terimi k'ye degil n'ye bagli oldugu icin o da final formulden atilabilir

$$p(k|Y_1, \dots, Y_n) \propto \left(\frac{\theta}{\lambda}\right)^K e^{(\lambda-\theta)k}$$

$p(k)$ için ortaya çıkan bu formüle bakarsak, elimizde verilen her k değeri için bir olasılık dondurecek bir formül var. Daha önceki Gamma örneğinde formüle bakarak elimizde hemen bir Gamma dağılımı olduğunu söyleyebilmistik. Bu kodlama sırasında isimize yarayacak bir şeydi, hesaplama için bir dağılıma "zar attırmamız" gerekiyor, ve Gamma örneğinde hemen Python Numpy kutuphanesindeki `random.gamma` çağrısına Gamma'dan gelen rasgele sayılar ürettirebiliriz. Üstteki formüle bakarsak, hangi dağılıma zar attıracağız?

Cevap şöyle: $p(k|..)$ pdf fonksiyonundaki k değişkeni 1, ..., 119 arasındaki tam sayı değerleri alabilir, o zaman ortada bir ayrışal (discrete) dağılım var demektir. Ve her k noktası için olabilecek olasılık değerini üstteki $p(k|..)$ formülüne hesaplatılabiliyorsak, ayrışal bir dağılımı her nokta için üstteki çağrı, ve bu sonuçları normalize ederek (vektörün her elemanını vektörün toplamına bölerek) bir dağılım sekline dönüştürebiliriz. Daha sonra bu "vektörel dağılım" üzerinden zar attırırız. Python kodundaki `w_choice` ya da R dilindeki `sample` çağrısı bu işi yapar.

Kodları işletince elimize $k = 41$ değeri geçecek, yani değişim anı $1851+41 = 1892$ senesidir (zar attırmaya göre sonuç bazen 40, bazen 42 de olabilir).

```
import math
import random

# samples indexes from a sequence of probability table
# based on those probabilities
def w_choice(lst):
    n = random.uniform(0, 1)
    for item, weight in enumerate(lst):
        if n < weight:
            break
        n = n - weight
    return item

#
# hyperparameters: a1, a2, b1, b2
#
def coal(n,x,init,a1,a2,b1,b2):
    nn=len(x)
    theta=init[0]
    lam=init[1]
    k = init[2]
    z=np.zeros((nn,))
    for i in range(n):
        ca = a1 + sum(x[0:k])
        theta = np.random.gamma(ca, 1/float(k + b1), 1)
        ca = a2 + sum(x[(k+1):nn])
        lam = np.random.gamma(ca, 1/float(nn-k + b2), 1)
        for j in range(nn):
            z[j]=math.exp((lam-theta)*(j+1)) * (theta/lam)**sum(x[0:j])
        # sample
        zz = z / sum(z)
        k = w_choice(zz)
```

```
print float(theta), float(lam), float(k)

data = np.loadtxt("coal.txt")
coal(1100, data, init=[1,1,30], a1=1,a2=1,b1=1,b2=1)

3.24001019426 0.799040503196 40.0
```

Kaynaklar:

Ioana A. Cosma and Ludger Evers, Markov Chain Monte Carlo Methods (Lecture)

Charles H. Franklin, Bayesian Models for Social Science Analysis (Lecture)