

Gaussian Olcumlerin Fuzyonu (Gaussian Sensor Fusion)

Tek boyutlu ortamda bir buyuklugu mesela bir lokasyon bilgisi x 'i, iki kere olcuyoruz, ve bu olcumu iki degisik algilayiciya yaptiriyoruz, ve yine diyelim ki iki degisik alet bir cismin oldugu uzakligini / yerini bize geri donduruyor. Devam edelim, bu bilgilerde belli olcude gurultu var; bu aletlerin hatali olcumu yuzunden olabilir, cevre sartlari sebebiyle olabilir, ornek olarak iki z_1, z_2 olcumu icin iki degisik belirsizlik (uncertainty) oldugunu farzedelim, bunlar σ_1, σ_2 . Soru su: bu iki olcumu kullanarak daha iyi bir x tahmini yapabilir miyiz?

Bunun icin iki olcumu bir sekilde birlestirmemiz gerekiyor. Her olcumu Gaussian / Normal dagilim olarak modelleyebiliriz, o zaman iki Gaussian dagilimi bir sekilde birlestirmemiz (fusion) lazim.

Olcumleri temsil etmek icin Gaussian bicilmis kaftan. Olcumdeki belirsizligi standart sapma (standart deviation) uzerinden rahatlikla temsil edebiliriz. Peki birlestirimi nasil yapalim?

Bu tur problemlerde maksimum olurluk (maximum likelihood) kullanilmasi gerektigini asagi yukari tahmin edebiliriz, cunku maksimum olurluk verinin olurlugunu (olasiligini yani) maksimize ederek bilinmeyen parametreleri tahmin etmeye ugrasir. Cogunlukla bu teknigi hep *tek* bir dagilim baglaminda goruruz, bazi bilinmeyen parametreleri olan tek bir dagilima degisik veri noktaları verilerek olasilik sonuclari carpilir, ve elde edilen formül maksimize edilmeye ugrasilirken ayni anda bilinmeyen parametrelerin optimal degerleri saptanmaya ugrasilir. Bizim bu problemimizde iki degisik dagilim olacak, maksimum olurluk illa tek bir dagilimla kullanilabilir diye bir kural yok.

Problemimizde iki olcumu, iki Gaussian ile temsil edebiliriz, ve bu iki Gaussian'a verilen iki olcum noktasini olurlugunu bu Gaussian'ların sonuclarini carparak hesaplayabiliriz. Peki bilinmeyen parametre nedir? Onu da *her iki Gaussian icin de ayni oldugunu farzettigimiz orta nokta* (mean) olarak alabiliriz, ve x olarak belirtiriz. Yani

$$L(x) = p(z_1|x, \sigma_1)p(z_2|x, \sigma_2)$$

$$L(x) \sim \exp \frac{-(z_1 - x)^2}{2\sigma_1^2} \times \exp \frac{-(z_2 - x)^2}{2\sigma_2^2}$$

1D Gaussian formülünü hatirlarsak,

$$p(z; x, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{(z - x)^2}{2\sigma^2} \right\}$$

Ders notlari [1]'de iki ustteki formülün nasil maksimize edilerek bir x_{MLE} formülüne erisildigini gorebiliriz.

Formül basındaki sabit kısmının $L(x)$ 'de kullanılmadığını görüyoruz, çünkü maksimizasyon açısından düşünürsek o kısım tekrar tekrar hesaplanmaya çalıştığımız değişkenler açısından bu sürekli tekrar bir fark yaratmaz.

Bu metod işler. Fakat biz alternatif olarak daha temiz olacak değişik bir yoldan gideceğiz. Elimizdeki her iki ölçümü iki farklı tek boyutlu Gaussian yerine 2 boyutlu tek bir Gaussian içine koyacağız, iki ölçümü tek bir 2 boyutlu vektör içinde belirteceğiz yani, ve tek bir olasılık hesabını $p(z; x, \Sigma)$ 'i baz alacağız. Belirsizlikler ne olacak? Ölçüm belirsizliklerini bu 2D Gaussian'ın kovaryansında capraza (diagonal) koyabiliriz, capraz dışındaki matris öğeleri sıfır yapılırsa iki ölçümün birbirinden bağımsızlığını temsil etmiş oluruz. Maksimizasyon? Tek bir ölçümün olurluğunu maksimize edeceğiz, bu tek bir ölçümün olasılığını hesaplamaktan ibarettir, ve bu hesap sırasında bilinmeyen değişkenleri içeren yeni bir formül ortaya çıkacaktır. Maksimize etmeye uğrasacağımız bu formül olur.

Çok boyutlu Gaussian'ı hatırlayalım (artık z, x birer vektör),

$$p(z; x, \Sigma) = \frac{1}{(2\pi)^{k/2} \det(\Sigma)^{1/2}} \exp \left\{ -\frac{1}{2}(z - x)^T \Sigma^{-1}(z - x) \right\}$$

Kısaca,

$$= \frac{1}{C} \exp \left\{ -\frac{1}{2}(z - x)^T \Sigma^{-1}(z - x) \right\}$$

Bir numara, \exp ve parantez içi negatif ibareden kurtulmak için $-\ln p$ alalım,

$$L = -\ln p(z) = \frac{1}{2}(z - x)^T \Sigma^{-1}(z - x)$$

Şimdi iki ölçümü, belirsizliği vektör / matris öğeleri olarak gösterelim,

$$= \frac{1}{2} \begin{bmatrix} z_1 - x \\ z_2 - x \end{bmatrix}^T \begin{bmatrix} \sigma_1^2 & 0 \\ 0 & \sigma_2^2 \end{bmatrix}^{-1} \begin{bmatrix} z_1 - x \\ z_2 - x \end{bmatrix}$$

Capraz matrisin tersini almak için caprazdaki öğelerin tersini almak yeterlidir,

$$\begin{aligned} &= \frac{1}{2} \begin{bmatrix} z_1 - x \\ z_2 - x \end{bmatrix}^T \begin{bmatrix} \sigma_1^{-2} & 0 \\ 0 & \sigma_2^{-2} \end{bmatrix} \begin{bmatrix} z_1 - x \\ z_2 - x \end{bmatrix} \\ &= \frac{1}{2} \begin{bmatrix} \sigma_1^{-2}(z_1 - x) & \sigma_2^{-2}(z_2 - x) \end{bmatrix} \begin{bmatrix} z_1 - x \\ z_2 - x \end{bmatrix} \\ &= \frac{1}{2} \sigma_1^{-2}(z_1 - x)^2 + \frac{1}{2} \sigma_2^{-2}(z_2 - x)^2 \end{aligned}$$

Maksimize etmek için, formül karesel olduğuna göre, bilinmeyen x değişkenine göre türev alıp sifıra eşitleyebiliriz,

$$\frac{dL}{dx} = \sigma_1^{-2}z_1 - \sigma_1^{-2}x + \sigma_2^{-2}z_2 - \sigma_2^{-2}x = 0$$

x üzerinden gruplarsak,

$$-x(\sigma_1^{-2} + \sigma_2^{-2}) + \sigma_1^{-2}z_1 + \sigma_2^{-2}z_2 = 0$$

Gruplanan kısmi eşitliğin sağına alalım,

$$\sigma_1^{-2}z_1 + \sigma_2^{-2}z_2 = x(\sigma_1^{-2} + \sigma_2^{-2})$$

$$\frac{\sigma_1^{-2}z_1 + \sigma_2^{-2}z_2}{\sigma_1^{-2} + \sigma_2^{-2}} = x_{MLE}$$

Gayet temiz bir şekilde sonuca eriştik.

Örnek

Elimizde belirsizlikleri $\sigma_1 = 10, \sigma_2 = 20$ olan iki algılayıcı var. Bu algılayıcılar aynı obje hakkında $z_1 = 130, z_2 = 170$ olarak iki ölçüm gönderiyorlar. Bu ölçümleri birleştirelim. Hatırlarsak 10^{-2} ile çarpmak 10^2 ile bölmek aynı şey.

$$x_{MLE} = \frac{130/10^2 + 170/20^2}{1/10^2 + 1/20^2} = 138.0$$

Sonuç belirsizliği daha az olan ölçüme daha yakın çıktı, bu akla yatkın bir sonuç.

Cok Boyutlu Gaussian Fuzyon

Peki ya elimizdeki ölçümlerin kendisi çok boyutlu ise? Yani z_1, z_2 birer vektör ise?

Yine maksimum olurluk üzerinden bir formül türetebiliriz. Bu durumda tek olasılık hesabı yetmez, iki ayrı dağılım olmalı,

$$p(z_1; x, \Sigma_1) = \frac{1}{C_1} \exp \left\{ -\frac{1}{2}(z_1 - x)^T \Sigma_1^{-1}(z_1 - x) \right\}$$

$$p(z_2; x, \Sigma_2) = \frac{1}{C_2} \exp \left\{ -\frac{1}{2}(z_2 - x)^T \Sigma_2^{-1}(z_2 - x) \right\}$$

Orta nokta x her iki formülde aynı cunku değişmeyen olan o ; aynı orta nokta için tahmin üretmeye uğraşıyoruz. Bu durum bildik maksimum olurluk hesaplarına

benziyor, fakat ilk basta belirttigimiz gibi farkli turden olasilik fonksiyonlarinin (bu sefer cok boyutlu) farkli veri noktaları uzerinden carpilmasi.

Devam edelim. Daha once ln olarak exp'yi yoketmistik. Bunun bir diger faydasi ln alinınca carpimların toplama donusmesidir,

$$L = p(z_1; \mathbf{x}, \Sigma_1)p(z_2; \mathbf{x}, \Sigma_2)$$

$$-\ln L = -\ln p(z_1; \mathbf{x}, \Sigma_1) - \ln p(z_2; \mathbf{x}, \Sigma_2)$$

$$\mathcal{L} = -\ln L = \frac{1}{2}(\mathbf{z}_1 - \mathbf{x})^T \Sigma_1^{-1}(\mathbf{z}_1 - \mathbf{x}) + \frac{1}{2}(\mathbf{z}_2 - \mathbf{x})^T \Sigma_2^{-1}(\mathbf{z}_2 - \mathbf{x})$$

Simdi esitligin sag tarafının \mathbf{x} 'e gore turevini alalım, vektor ve matris baglamında turev nasıl alınır? Herhangi bir M 'in simetrik olduğu durumlarda (ki kovaryans matrisleri her zaman simetriktir, cunku mesela iki degiskenli durumda x_1, x_2 kovaryansi -iliskisi- x_2, x_1 kovaryansından farkli olamaz),

$$\frac{\partial}{\partial \mathbf{x}}[\mathbf{x}^T M \mathbf{x}] = 2M\mathbf{x}$$

oldugunu biliyoruz [2]. O zaman turev sonucu soyle olur,

$$\frac{d\mathcal{L}}{d\mathbf{x}} = (\mathbf{z}_1 - \mathbf{x})^T \Sigma_1^{-1} + (\mathbf{z}_2 - \mathbf{x})^T \Sigma_2^{-1}$$

Sifira esitleyip cozelim,

$$(\mathbf{z}_1 - \mathbf{x})\Sigma_1^{-1} + (\mathbf{z}_2 - \mathbf{x})\Sigma_2^{-1} = 0$$

$$\mathbf{z}_1\Sigma_1^{-1} - \mathbf{x}\Sigma_1^{-1} + \mathbf{z}_2\Sigma_2^{-1} - \mathbf{x}\Sigma_2^{-1} = 0$$

Yine \mathbf{x} altında gruplayalım,

$$-\mathbf{x}(\Sigma_1^{-1} + \Sigma_2^{-1}) + \mathbf{z}_1\Sigma_1^{-1} + \mathbf{z}_2\Sigma_2^{-1} = 0$$

$$\mathbf{z}_1\Sigma_1^{-1} + \mathbf{z}_2\Sigma_2^{-1} = \mathbf{x}(\Sigma_1^{-1} + \Sigma_2^{-1})$$

Eger iki belirsizligin toplamını Σ_x^{-1} olarak ozetlersek, yani

$$\Sigma_x^{-1} = \Sigma_1^{-1} + \Sigma_2^{-1}$$

Not: Aslında Σ_x te diyebilirdik, fakat tersi alınmış matrislerin toplamı olduğunu temsil etmesi için “tersi alınmış bir sembol” kullandık. Tabii diğer yandan tersin tersini alınca ele geçecek Σ_x ’in de bir anlamı olduğu iddia edilebilir, bu Σ_x en olası x tahmininin yeni belirsizliğidir de bir bakıma.

Şimdi ana formüle donelim,

$$z_1 \Sigma_1^{-1} + z_2 \Sigma_2^{-1} = x \Sigma_x^{-1}$$

$$\Sigma_x (z_1 \Sigma_1^{-1} + z_2 \Sigma_2^{-1}) = x_{MLE}$$

Örnek

Elimizde iki tane iki boyutlu ölçüm var,

$$z_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, z_2 = \begin{bmatrix} 2 \\ -1 \end{bmatrix}$$

Ölçümler iki değişik algılayıcıdan geliyor, belirsizlikleri

$$\Sigma_1 = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}, \Sigma_2 = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix}$$

Nihai ölçüm nedir?

```
from mpl_toolkits.mplot3d import Axes3D
from matplotlib import cm
import matplotlib.mlab as mlab

x = np.arange(-10.0, 10.0, 0.1)
y = np.arange(-10.0, 10.0, 0.1)


X, Y = np.meshgrid(x, y)
Z1 = mlab.bivariate_normal(X, Y, sigmax=1.0, sigmay=4.0, mux=1., \
    muy=1., sigmaxy=0.0)
Z2 = mlab.bivariate_normal(X, Y, sigmax=4.0, sigmay=1.0, mux=2., \
    muy=-1., sigmaxy=0.0)

# iki yuzeyi ayni grafikte birlestirmek icin herhangi iki nokta arasinda
# daha fazla (maksimum) olani al, cunku nihai yuzey olarak onu gormek
# istiyoruz zaten
Z = np.maximum(Z1, Z2)

fig = plt.figure()

ax = Axes3D(fig)
ax.view_init(elev=50., azim=80)


ax.plot_surface(X, Y, Z, cmap=cm.jet)
plt.savefig('fusion_1.png')
```



İki ölçümü Gaussian olarak ekrana bastık, bu Gaussian'ların orta noktası z_1, z_2 , bu durumu maksimum olurluk için aynı olduğunu farz ettiğimiz x ile karıştır-mayalım; o x modelleme sırasında olduğunu farzettığımız ideal bir Gaussian idi. Üstte sadece veri noktalarını ekrana basıyoruz.

Üstten bakışla kontur (contour) olarak gösterirsek

```
CS = plt.contour(X, Y, Z1,rotation=70)
CS = plt.contour(X, Y, Z2,rotation=70)
plt.savefig('fusion_3.png')
```



Resimde önce ilk ölçüm, sonra onunla yanyana olacak ikinci ölçüm koyulmuş.

$$\Sigma_x^{-1} = \Sigma_1^{-1} + \Sigma_2^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 0.25 \end{bmatrix} + \begin{bmatrix} 0.25 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1.25 & 0 \\ 0 & 1.25 \end{bmatrix}$$

Tersini alalım

$$\Sigma_x = \begin{bmatrix} 0.8 & 0 \\ 0 & 0.8 \end{bmatrix}$$

$$\mathbf{x}_{MLE} = \Sigma_x(z_1 \Sigma_1^{-1} + z_2 \Sigma_2^{-1})$$

$$\mathbf{x}_{MLE} = \begin{bmatrix} 0.8 & 0 \\ 0 & 0.8 \end{bmatrix} \left(\begin{bmatrix} 1 & 0 \\ 0 & 0.25 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} + \begin{bmatrix} 0.25 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ -1 \end{bmatrix} \right) = \begin{bmatrix} 1.2 \\ -0.6 \end{bmatrix}$$


Sonuc grafiklenirse suna benzer (ki yeni belirsizlik Σ_x 'i de grafikte kullanalım),

```
Z3 = mlab.bivariate_normal(X, Y, sigmax=0.8, sigmay=0.8, mux=1.2, \
    muy=-0.6, sigmaxy=0.0)
```

```
fig = plt.figure()
```


```
ax = Axes3D(fig)
ax.view_init(elev=40., azimuth=80)
```

```
ax.plot_surface(X, Y, Z3, cmap=cm.jet)
plt.savefig('fusion_2.png')
```



Yeni tahminimiz boyle cikti. Çok daha emin oldugumuz bir noktada en olasi olcumu ortaya cikardik. Kontur olarak grafiklersek,

```
CS = plt.contour(X, Y, Z3)
plt.savefig('fusion_4.png')
```



[1] www.robots.ox.ac.uk/~az/lectures/est/lect34.pdf

[2] Hart, Duda, *Pattern Classification*