Paralel Rasgele Izdusumu

Rasgele yansitma teknigi $m \times b$ boyutunda bir matrisi $n \times k$ boyutunda ve her hucresinde $N(0,1)$ dagilimindan gelen bir sayi iceren matris ile carpmak sonunda elde edilir. Boylece ana veri matrisi "yansiltilmis" olur, boyut azaltmak icin cok kullanisli bir tekniktir, cunku elde edilen matrisin ana matris A'nin "menzilini" iyi temsil ettigi ispatlanmistir. Daha fazla detay icin *Rasgele Izdusumu ile SVD* yazisina bakabilirsiniz.

Esle/indirge ortaminda rasgele yansitma icin once *Matris Carpimi* adli yaziya da bakmak gerekebilir. Bu yazida iki matris arasindaki carpima "satir bakisi" bizim icin gerekli. Cunku carpimin solunda $m \times n$ boyutundaki matrisin verileri bize satir satir geliyor, yani her m satirdan sadece bir tanesine bakarak islem yapiyoruz. Faraziyemiz n'in de buyuk olabilmesine ragmen en azindan n tane veri noktasini tek bir makinada isleyebilecegimiz.

Satir bakisina donersek, bu carpim gorusune gore soldaki her satir icin, o satirdaki bir ogeyi sagda ona tekabul eden $n \times k$ boyutundaki matrisin satiriyla (yani her gelen satirin 5. ogesi sagdaki matrisin 5 satirin tamami ile) carpip, sonuc olan "carpilmis" satirlari birbiriyle topluyoruz. Bu Hadoop veri isleme mentalitesine uygun cunku her seferinde A'nin tek bir satirina bakiyoruz.

Sagdaki rasgele sayilar iceren matris kritik. Biz bu matrisi bellekte tut**ma**maya karar verdik, cunku n sayisi da buyuk olabilir, her ne kadar k kucuk olsa da (cogunlukla 100 civari) yine de bu kadar bellegi eger mumkun ise israf etmemek en iyisi.

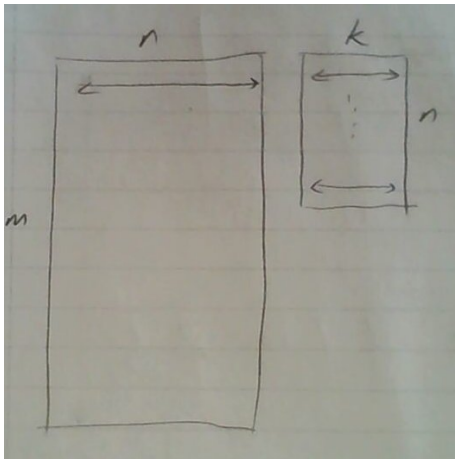

Eger bellekte tutmuyorsak rasgele matrisin degerlerini (sadece ilgilendigimiz oge icin, tum matrisi degil) her seferinde tekrar uretmek gerekir. Hiz acisindan performans cok kotu olmayacaktir, cunku rasgele sayi uretimi toplama, carpma, mod gibi direk matematiksel hesaplar ile yapilir.

Fakat burada onemli bir diger konu sudur: her A satiri icin *ayni* rasgele matris (ogelerini) ayni sekilde uretebilmeliyiz.

Bu problemin en basit cozumu rasgele sayi uretimi icin tohum (seed) kullan-

imidir. Eger tohum kullanilmazsa, Python `random` paketindeki uretici cagrilar gunun zamanina gore bir tohum kullanirlar, ve boylece her cagri degisik bir sayi uretmis olur (cunku komut isletildigi her seferinde gunun zamani degisiktir). Fakat rasgele sayi uretimini, "her seferinde ayni sekilde" yaptirmanin yolku vardir, bunun icin tohum disaridan set edilir ve boylece ayni tohumdan baslayan rasgele sayi uretim zinciri hep ayni olur. Rasgele sayi uretimi deterministik bir algoritmadir, zaten literaturde bu islem "yari rasgele sayi uretimi (pseudorandom number generation)" olarak gecer.

```
import random

# tohumsuz, bu kod her seferinde degisik sayi uretir
print random.gauss(0,1), random.gauss(0,1)
print random.gauss(0,1), random.gauss(0,1)
```

```
-0.49078710907 1.97156772689
-0.612135407803 -0.0159405924623
```

```
import random
# tohumlu
random.seed(100000)
print random.gauss(0,1), random.gauss(0,1)
random.seed(100000)
print random.gauss(0,1), random.gauss(0,1)
```

```
1.46560757321 0.974749135866
1.46560757321 0.974749135866
```

Ustteki kodda ayni tohumu verince arka arkaya uretilen iki (daha fazla da olabilirdi) "rasgele" sayinin hep ayni oldugunu goruyoruz.

Rasgele "matrise" donersek, eger bu matrisin her A veri satiri icin hucre degerlerinin ayni sekilde uretilmesini istiyorsak, tohum kullanmaliyiz. Tohum degeri ne olacak? Bu deger mesela $n \times k$ boyutundaki rasgele matris icin indis degerleri yanyana koyularak uretilebilir, mesela 111. satir ve 2. kolon icin 1112 tohum degeri kullanilir, ve bu tohumla tek bir rasgele sayi uretilir, (111,2) hucresine konulur ve sonraki indis icin yeni bir tohum kullanilir. Evet ust uste cakismalar olabilir tabii ki, mesela 11. satir 12. kolon da ustteki tohumla ayni sonucu getirir, ama bu tur nadir cakismalar o kadar onemli degil, sonucta rasgele sayilarla ugrasiyoruz, "yeterince raslantisal olmalari" kafi.

Altta bu veri matrisini satir satir carpip yansitilmis yeni bir matrisi ureten mrjob programini bulabilirsiniz.

```
from mrjob.job import MRJob
from mrjob.protocol import PickleProtocol, RawValueProtocol
import numpy as np, sys
import random

class MRProj(MRJob):
    INTERNAL_PROTOCOL = PickleProtocol
```

```
    OUTPUT_PROTOCOL = RawValueProtocol

    def __init__(self, *args, **kwargs):
        super(MRProj, self).__init__(*args, **kwargs)
        self.k = 3

    def mapper(self, key, line):
        line_vals = map(np.float,line.split())
        result = np.zeros(self.k)
        for j,val in enumerate(line_vals):
            for i in range(self.k):
                random.seed(int(j + i))
                result[i] += val*random.gauss(0,1)
        yield (None,",".join(map(str,result)))

if __name__ == '__main__':
    MRProj.run()
```

Tek bir esle cagrisi var, cunku carpim islemi oldukca basit, indirgeme islemine gerek yok.

Cikti icin yield ile yayinladigimiz (emit) satirlarda anahtar kullanmiyoruz, yani verinin paralel islenirken nasil yuk dagitimi yapildigina gore sonuc matrisinin sirasi ana matrisin satir sirasina uymayabilir. Fakat satir sirasi bizim icin cogunlukla onemli olmuyor (kolon sirasi onemli), cunku genelde, her satir, digerinden ayri / bagimsiz bir veri olcumunu temsil eder cogunlukla. Eger zamansal bir boyut var ise, bazi seyler arka arkaya islenmeliyse, o bilgi ayri bir kolon (mesela tarih, zaman damgasi -timestamp-) olarak veride bulunurdu.

```
! python mrproj.py A_matrix > /tmp/out

using configs in /home/burak/.mrjob.conf
creating tmp directory /tmp/mrproj.burak.20131203.094548.254606
writing to /tmp/mrproj.burak.20131203.094548.254606/step-0-mapper_part-00000
Counters from step 1:
  (no counters found)
Moving /tmp/mrproj.burak.20131203.094548.254606/step-0-mapper_part-00000 -> /tmp/mrpro
Streaming final output from /tmp/mrproj.burak.20131203.094548.254606/output
removing tmp directory /tmp/mrproj.burak.20131203.094548.254606
```

```
! head -10 /tmp/out

20.2369671373,13.9358970644,0.524561578258
19.8581349841,13.7724732852,5.23992858318
27.6790861925,18.8833585029,-1.56199395804
9.3255498646,7.52383094482,2.58977793605
27.3677257439,33.0438553532,18.4819155509
27.6790861925,18.8833585029,-1.56199395804
9.3255498646,7.52383094482,2.58977793605
27.3677257439,33.0438553532,18.4819155509
27.6790861925,18.8833585029,-1.56199395804
9.3255498646,7.52383094482,2.58977793605
```

Performans Iyilestirmeleri

Ustteki kod daha hizli olabilir. Diyelim ki n'in milyonlarda oldugu sartlari da hizli bir sekilde isleyebilmek istiyoruz. Fakat bu noktada kendimize su soruyu sormamiz gerekir: hangi sartlarda n milyonlari bulacaktir?

Buyuk bir ihtimalle bu durum eger bolca kategorik veri boyutu var ise ortaya cikar. Kategorik verileri bildigimiz gibi 1-in-n, ya da one-hot kodlama (encoding) ile temsil ediyoruz, bu demektir ki 1000 tane farkli deger icerebilen tek bir kolon, 1000 tane yeni kolon haline geliyor. Bazi boyutlarin (mesela web sayfa ismi, URL degeri) tasiyan veri setlerinde tekil (unique) degerlerin milyonlar hatta milyara varabilecegini dusunursek asiri yuksek n rakamlarinin nereden geldigini anlariz.

Ama bunun bize ek bir faydasi var: 1-in-n kodlamasi var ise, bu her satirda cok fazla sifir olacak demektir, ve icinde cok sifiri olan vektorleri / matrisleri seyrek matrisler ile cok rahat sekilde temsil edebiliriz.

```
from mrjob.job import MRJob
from mrjob.protocol import PickleProtocol, RawValueProtocol
import numpy as np, sys, itertools
from scipy import sparse
import random

class MRProj(MRJob):
    INTERNAL_PROTOCOL = PickleProtocol
    OUTPUT_PROTOCOL = RawValueProtocol

    def __init__(self, *args, **kwargs):
        super(MRProj, self).__init__(*args, **kwargs)
        self.k = 3

    def mapper(self, key, line):
        line_vals = map(np.float,line.split())
        line_sps = sparse.coo_matrix(line_vals,shape=(1,len(line_vals)))
        result = np.zeros(self.k)
        for xx,j,v in itertools.izip(line_sps.row, line_sps.col, line_sps.data):
            np.random.seed(j)
            result += v*np.random.randn(self.k)
        yield (None,",".join(map(str,result)))

if __name__ == '__main__':
    MRProj.run()
```

Ustteki kodda her satiri okur okumaz hemen onu bir seyrek matrise ceviriyoruz. Simdi en kritik numara: `itertools.izip` cagrisi ile bu seyrek matrisin *sadece sifir olmayan degerlerini ziyaret ediyoruz*. Eger 1000 tane kolon var ise, ama bu 1000 kolonun 20 tanesi dolu ise, bu 50 kat bir performans iyilestirmesi saglayacak demektir (bu arada seyrek verilerde yuzde 2 doluluk gayet normal bir rakamdir). Sadece dolu hucreleri ziyaret ediyoruz, ayrica `izip` bu dolu hucrelerin indis degerlerini de bize geri getiriyor, biz de bu degerleri `seed` icin onceden oldugu gibi kullaniyoruz. Bir diger ilerleme K tane rasgele sayiyi bir kerede uretiyoruz, ve tohum ayarlamasini bir kere, dis dongu basinda gerceklestiriyoruz.

Sonuclara bakalim:

```
!python mrprojs.py A_matrix > /tmp/out
!head -10 /tmp/out
```

```
using configs in /home/burak/.mrjob.conf
creating tmp directory /tmp/mrprojs.burak.20131203.094635.908870
writing to /tmp/mrprojs.burak.20131203.094635.908870/step-0-mapper_part-00000
Counters from step 1:
  (no counters found)
Moving /tmp/mrprojs.burak.20131203.094635.908870/step-0-mapper_part-00000 -> /tmp/mrpr
Streaming final output from /tmp/mrprojs.burak.20131203.094635.908870/output
removing tmp directory /tmp/mrprojs.burak.20131203.094635.908870
20.4375200961,1.09117093744,-9.27846872665
13.2830062024,-0.654868464606,-9.66445859893
26.4299520755,0.628144156713,-14.4142094864
9.52053667131,0.337287636006,-3.17826479151
34.6111912648,-0.763663777689,-2.06399979621
26.4299520755,0.628144156713,-14.4142094864
9.52053667131,0.337287636006,-3.17826479151
34.6111912648,-0.763663777689,-2.06399979621
26.4299520755,0.628144156713,-14.4142094864
9.52053667131,0.337287636006,-3.17826479151
```

Daha onceki sonuclar ile ayni (rasgelelik var ama `seed` degerleri degismedi, o sebeple ayni sonucu aldik, bu iyi).

Bir kontrol daha var, eger rasgelelik bazli yansitma iyi yapildiysa, A matrisini izdusumunu aldiktan daha once anlattigimiz teknik ile SVD hesabini cok rahat bir sekilde yapabilmeliyiz. Bunun icin izdusumunu `/tmp/Y` icine yazacagiz, ve ardindan daha onceki QR bazli teknikle SVD hesabini yapacagiz. Ardindan pur SVD ile A'yi isleyecegiz ve sonuc U matrisindeki en buyuk iki tekilsel (singular) degeri her iki teknikten alip ekranda grafikleyecegiz.

```
!python mrprojs.py A_matrix > /tmp/Y
```

```
using configs in /home/burak/.mrjob.conf
creating tmp directory /tmp/mrprojs.burak.20140104.064956.493025
writing to /tmp/mrprojs.burak.20140104.064956.493025/step-0-mapper_part-00000
Counters from step 1:
  (no counters found)
Moving /tmp/mrprojs.burak.20140104.064956.493025/step-0-mapper_part-00000 -> /tmp/mrpr
Streaming final output from /tmp/mrprojs.burak.20140104.064956.493025/output
removing tmp directory /tmp/mrprojs.burak.20140104.064956.493025
```

```
import numpy.linalg as lin

n = 4; k = 3
A = np.loadtxt('A_matrix')
Y = np.loadtxt("/tmp/Y",delimiter=',')

Q, xx = lin.qr(Y)
B = np.dot(Q.T,A)
```

```
Uhat, Sigma, V = lin.svd(B)
U = np.dot(Q, Uhat)

plt.plot(U[:,0],U[:,1],'r+')
plt.hold(True)

U, Sigma, V = lin.svd(A);
plt.plot(U[:,0],U[:,1],'bx')
plt.savefig('rnd_1.png')
```

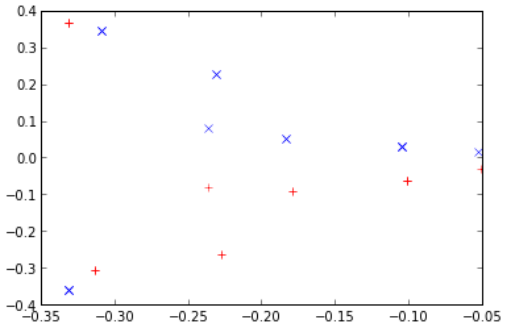

Sonuclar fena degil.