

Ders 6

Monte Carlo, Entegraller, MCMC

Fizik, biyoloji ve özellikle makina öğrenimi problemlerinde bazen çok boyutlu bir fonksiyon üzerinden integral almak gerekebiliyor. En basit örnek, mesela bir dağılımın başka bir fonksiyon ile çarpımının beklentisini (expectation) hesaplamak gerektiğinde, ki bu

$$E(f) = \int p(x)f(x)dx$$

entegralidir, $x \in \mathbb{R}^n$, $p(x)$ dağılım fonksiyonu, $f(x)$ herhangi bir başka fonksiyon olmak üzere, o zaman tüm x değerlerini göz önüne alarak (ayrık sal bağlamda ya teker teker geçerek, ya da analitik olarak) entegral hesabını yapmak gerekecekti.

Fakat $p(x)$ bir dağılım olduğuna göre, ve bizim göçtığımız her x için bir olasılık değeri varsa, bu işi tersine çevirerek, $p(x)$ 'teki olasılıklara göre belli (az) sayıda x üretirsek, ve sadece bu x 'leri entegral hesabında kullanırsak yaklaşık sal acidan gerçek entegral hesabına yaklaşımlı oluruz.

Bu mantıklı değil mi? Düşünürsek, mesela 10 değeri 0.4 olasılığında ise, 5 değeri 0.1 olasılığında ise, hem sayı, hem olasılığı ile çarpmak yerine “daha fazla 10 değeri üretmek” ve bu değeri f 'e geçmek, toplamak, sonra bölmek, vs. yaklaşık sal olarak aynı kâpiya çıkar. Yani

$$E_N = \frac{1}{N} \sum_{i=1}^N f(x^{(i)})$$

üstteki entegralin yaklaşık sal temsilidir, $x^{(i)}$ $p(x)$ olasılığına göre üretilen sayıları temsil ediyor. Üstteki bağlantının teorik olarak ispatı da var, bu ispatı burada vermeyeceğiz.

İşte Monte Carlo entegral hesabının artasında yatan numara budur.

MCMC

Demek ki Monte Carlo entegralinin işlemesi için $p(x)$ 'den örnekleme yapmak gerekiyor. Şimdi ikinci numaraya gelelim.

Bazen ne yazık ki $p(x)$ 'den örnekleme yapmak kolay olmuyor. Bu durumlar için $p(x)$ yerine onu yaklaşık sal olarak temsil eden bir $\pi(x)$ 'i elde etmekle uğraşıyoruz. Bu $\pi(x)$ ise bir Markov Zincirinin (Markov Chain -yine MC harfleri!-) duragan dağılımı olarak hayal ediliyor.

Markov Zinciri teorisinde bir geçiş matrisi, yani Markov Zincirinin kendisi verilir, ve duragan dağılımın hesaplanması istenir. MCMC problemlerinde ise, yani Monte Carlo entegrali için Markov Zinciri kullanıldığı durumlarda elimizde bir $\pi(x)$ dağılımı vardır ve bir Markov Zinciri oluşturmamız gerekir. Nihai dağılımı biliriz, ve bu dağılıma “giden” geçişleri üretiriz. Bu geçişleri öyle ayarlayabiliriz ki üretilen rasgele sayılar hedef dağılımından geliyormuş gibi olur.

Gecisleri üretmek için literatürde bir çok teknik vardır. Önemsel Örneklem (Importance Sampling), Örneklem ve Önemli Göre Tekrar Örneklem (Sampling Importance Resampling), Metropolis-Hastings, Gibbs Örneklemesi gibi teknikleri vardır, ve detayları değişik olsa da hepsi de MCMC kategorisine girer, ve yapmaya çalıştıkları $\pi(x)$ 'e giderken bir şekilde bir gecisleri, zinciri ortaya çıkartmak ve bu gecisleri entegral hesabında kullanmaktır.

Üstteki tekniklerden en yaygın kullanılanı Metropolis-Hastings algoritmasıdır.

Sunu vurgulamak önemli, gecisleri üretmek, “bir tür sanal Markov Matrisi” yaratmaktır aslında. Ve her MCMC algoritması bunu farklı şekillerde yapabilir; mesela MH daha basit başka bir dağılım ile ana dağılım arasında sürekli karşılaştırmalar yapar, belli aralıklarda gecis yapar, diğerlerinde yapmaz, ve bunun bir yan etkisi olarak ortaya bir Markov Zinciri çıkartmış / onu kullanmış olur. O gecislerin bir Markov Zinciri'ne eşdeğer olduğunun matematiksel olarak ispatı da vardır.

Not: Bu alandaki makalelerde bir dağılımın “belli bir carpımsal sabite kadar” bilindiği (known up to a multiplicative constant) söylenir. Bu söz aslında şu anlamı gelir. Mesela ayrık bir dağılımımız var, ama bu dağılımın kendisini, şu halini biliyoruz

[4.3 2. 8.4 8.7 1.8]

Bu bir dağılım değil, çünkü öğelerin toplamı 1 değil. Onu bir dağılım haline çevirmek için, tüm öğeleri toplamak ve bu vektördeki tüm sayıları bu toplam ile bölmek gerekir. Toplam 25.2, bölersek

[0.17063492 0.07936508 0.33333333 0.3452381 0.07142857]

İlk vektör “belli bir carpımsal sabite kadar” bilinen dağılım, carpımsal sabit 25.2. Esas dağılım ikinci vektör.

Peki niye bu sözü söyleyenler toplamı hesaplayıp gerçek dağılımı hesaplamıyorlar? Sebep performans. Bazen ayrık bir dağılım o kadar yüksek boyutlu, fazla öğe içeren bir halde oluyor ki, performans açısından bu basit toplam hesabını yapmak bile çok pahalı oluyor. İşte MCMC metodlarının bir güzel tarafı daha burada, dağılımın kendisi olmasa bile belli bir carpımsal sabite kadar bilinen versiyonları ile gayet rahat bir şekilde işliyorlar.

Kaynaklar

Algorithmic Machine Learning, Stephen Marsland