

Ozet Istatistikleri, Grafikleri

Beklenti (Expectation)

Bu deger, dagilim $f(x)$ 'in tek sayilik bir ozetidir. Yani beklenti hesabina bir taraftan bir dagilim fonksiyonu girer, diger taraftan tek bir sayi disari cikar.

Tanim

Surekli dagilim fonksiyonlari icin $E(X)$

$$E(X) = \int xf(x)dx$$

ayriksal dagilimlar icin

$$E(X) = \sum_x xf(x)$$

Hesabin, her x degerini onun olasiligi ile carpip topladigina dikkat. Bu tur bir hesap dogal olarak tum x 'lerin ortalamasini verecektir, ve dolayli olarak dagilimin ortalamasini hesaplayacaktır. Ortalama μ_x olarak ta gosterilebilir.

$E(X)$ 'in bir tanim olduguna dikkat, yani bu ifade tamamen bizim yarattigimiz, ortaya cikarttigimiz bir sey, matematigin baz kurallarindan gelerek turetilen bir kavram degil.

Notasyonel basitlik icin ustteki toplam / entegral yerine

$$= \int x dF(x)$$

diyecegiz, bu notasyonel bir kullanim sadece, unutmayalim, reel analizde $\int x dF(x)$ 'in ozel bir anlami var (hoca tam diferansiyel dF 'den bahsediyor).

Beklentinin taniminin kapsamli / eksiksiz olmasi icin $E(X)$ 'in "mevcudiyeti" icin de bir sart tanımlamak gerekir, bu sart soyle olsun,

$$\int_x |x|dF_X(x) < \infty$$

ise beklenti mevcut demektir. Tersi sozkonusu ise beklenti mevcut degildir.

Ornek

$X \sim \text{Unif}(-1, 3)$ olsun. $E(X) = \int x dF(x) = \int xf_X(x)dx = \frac{1}{4} \int_{-1}^3 xdx = 1$.

Ornek

Cauchy dagiliminin $f_X(x) = \{\pi(1+x^2)\}^{-1}$ oldugunu soylemistik. Simdi beklentiyi hesaplayalim. Parcali entegral teknigi lazim, $u = x$, $dv = 1/(1+x^2)$ deriz, ve o zaman $v = \tan^{-1}(x)$ olur, bkz *Ters Trigonometrik Formuller* yazimiz. Demek ki

$$\int |x|dF(x) = \frac{2}{\pi} \int_0^{\infty} \frac{x dx}{1+x^2}$$

2 nereden cikti? Cunku $|x|$ kullaniyoruz, o zaman sinir degerlerinde sadece sifirin sagina bakip sonucu ikiyle carpma yeterli. Bir sabit oldugu icin π ile beraber disari cikiyor. Simdi

$$\int u dv = uv - \int v du$$

uzerinden

$$= [x \tan^{-1}(x)]_0^{\infty} - \int_0^{\infty} \tan^{-1}(x) dx = \infty$$

Yani ustteki hesap sonsuzluga gider. O zaman ustteki tanimimiza gore Cauchy dagiliminin beklentisi yoktur.

Tanim

x_1, \dots, x_n verilerini iceren orneklemen (sample) ortalamasi

$$\bar{x} = \frac{1}{n} \sum x_i \quad (1)$$

Dikkat bu orneklemdeki verinin ortalamasi. Hicbir dagilim hakkında hicbir faraziye yapmadik. Ayrica tanim kullandik, yani bu ifadenin ne oldugu tamamen bize bagli.

Orneklem ortalamasi sadece tek merkezi bir tepesi olan (unimodal) dagilimlar icin gecerlidir. Eger bu temel varsayim gecerli degilse, ortalama kullanarak yapilan hesaplar bizi yanlis yollara goturur. Ayrica bir dagilimi simetrik olup olmadigi da ortalama ya da medyan kullanilip kullanilmamasi kararinda onemlidir. Eger simetrik, tek tepeli bir dagilim var ise, ortalama ve medyan birbirine yakin olacaktir. Fakat veri baska turde bir dagilim ise, o zaman bu iki olcut birbirinden cok farkli olabilir.

Tanim

Y rasgele degiskeninin varyansi (variance)

$$\text{Var}(Y) = E((Y - E(Y))^2)$$

Ifadede toplama ve bolme gibi islemler olmadigina dikkat; onun yerine kare ifadeleri üzerinde beklenti ifadesi var. Yani Y' 'nin beklentisini rasgele degiskenin kendisinden cikartip kareyi aliyoruz, ve bu islemin Y' 'den gelen tum zar atislari uzerinden beklentisi bize varyansi veriyor. Bir rasgele degisken gorunce onun yerine “dagilimdan uretilen sayi” dusunmek faydalidir, ki bu gercek dunya sartlarindan (ve buyuk miktarda olunca) veri noktalarini temsil eder.

Tanim

y_1, \dots, y_n orneklerinin varyansi (literaturde S^2 olarak gecebiliyor,

$$S^2 = \frac{1}{n} \sum (y_i - \bar{y})^2 \quad (2)$$

Standart sapma veri noktalarin “ortalamadan farkinin ortalamasini” verir. Tabii bazen noktalar ortalamanin altinda, bazen ustunde olacaktır, bizi bu negatiflik, pozitiflik ilgilendirmez, biz sadece farkla alakaliyiz. O yuzden her sapmanin karesini aliriz, bunlari toplayip nokta sayisina boleriz.

Ilginc bir cebirsel islem sudur ve bize verinin uzerinden tek bir kez gecerek (one pass) hem sayisal ortalamayi hem de sayisal varyansi hesaplamamizi saglar. Eger \bar{y} tanimini ustteki formule sokarsak,

$$\begin{aligned} &= \frac{1}{n} \sum_i y_i^2 + \frac{1}{n} \sum_i m^2 - \frac{2}{n} \sum_i y_i \bar{y} \\ &= \frac{1}{n} \sum_i y_i^2 + \frac{\bar{y}^2 n}{n} - \frac{2\bar{y}n}{n} \bar{y} \\ &= \frac{1}{n} \sum_i y_i^2 + \bar{y}^2 - 2\bar{y}^2 \\ &= \frac{1}{n} \sum_i y_i^2 - \bar{y}^2 \end{aligned}$$

Bu arada standard sapma varyansin karekokudur, ve biz karekok olan versiyon ile calismayi tercih ediyoruz. Niye? Cunku o zaman veri noktalarinin ve yayilma olcusunun birimleri birbiri ile ayni olacak. Eger veri setimiz bir alisveris sepetindeki malzemelerin lira cinsinden degerleri olsaydi, varyans bize sonucu “kare lira” olarak verecekti ve bunun pek anlami olmayacakti.

Kovaryans ve Korelasyon (Covariance and Correlation)

Verisel Kovaryans (Empirical Covariance)

Eger verinin kolonlari arasindaki iliskiyi gormek istersek, en hizli yontem matristeki her kolonun (degiskenin) ortalamasini kendisinden cikartmak, yani onu

“sifirda ortalamak” ve bu matrisin devrini alarak kendisi ile carpma. Bu islem her kolonu kendisi ve diger kolonlar ile noktasal carpimdan gecirecektir ve carpim, toplama sonucunu nihai matrise yazacaktır. Carpimlarin bildigimiz ozelligine gore, arti deger arti degerle carpilince arti, eksi ile eksi arti, eksi ile arti eksi verir, ve bu bilgi bize ilinti bulma hakkında guzel bir ipucu sunar. Pozitif sonucun pozitif korelasyon, negatif ise tersi sekilde ilinti oldugu sonucuna boylece kolayca erisebiliriz.

Tanim

$$S = \frac{1}{n}(X - E(X))^T(X - E(X))$$

Pandas ile `cov` cagrisi bu hesabi hizli bir sekilde yapar,

```
print df.cov()
```

| | Sepal Length | Sepal Width | Petal Length | Petal Width |
|--------------|--------------|-------------|--------------|-------------|
| Sepal Length | 0.685694 | -0.039268 | 1.273682 | 0.516904 |
| Sepal Width | -0.039268 | 0.188004 | -0.321713 | -0.117981 |
| Petal Length | 1.273682 | -0.321713 | 3.113179 | 1.296387 |
| Petal Width | 0.516904 | -0.117981 | 1.296387 | 0.582414 |


Eger kendimiz bu hesabi yapmak istersek,

```
means = df.mean()
n = df.shape[0]
df2 = df.apply(lambda x: x - means, axis=1)
print np.dot(df2.T, df2) / n
```

```
[[ 0.68112222 -0.03900667  1.26519111  0.51345778]
 [-0.03900667  0.18675067 -0.319568   -0.11719467]
 [ 1.26519111 -0.319568   3.09242489  1.28774489]
 [ 0.51345778 -0.11719467  1.28774489  0.57853156]]
```

Verisel kovaryansin sayisal gosterdigini grafiklemek istersek, yani iki veya daha fazla boyutun arasindaki iliskileri grafiklemek icin yontemlerden birisi verideki mumkun her ikili iliskiye grafiksel olarak gosterme. Pandas `scatter_matrix` bunu yapabilir. Iris veri seti uzerinde goelim, her boyut hem y-ekseni hem x-ekseninde verilmiş, iliskiye gormek icin ekseninde o boyutu bulup kesisme noktalarindaki grafige bakmak lazim.

```
import pandas as pd
df = pd.read_csv('iris.csv')
df = df.ix[:,0:4]
pd.scatter_matrix(df)
plt.savefig('stat_summary_01.png')
```



İliski olduğu zaman o ilişkiye tekabül eden grafikte “düz çizgiye benzer” bir görüntü olur, demek ki değişkenlerden biri artınca diğeri de artıyor (eger çizgi soldan sağa yukarı doğru gidiyorsa), azalınca diğeri de azalıyor demektir (eger çizgi aşağı doğru iniyorsa). Eger ilinti yok ise bol gürültülü, ya da yuvarlak kuryeye benzer bir şekil çıkar. Üstteki grafiğe göre yaprak genişliği (petal width) ile yaprak boyu (petal length) arasında bir ilişki var.

Tanım

X, Y rasgele değişkenlerin arasındaki kovaryans,

$$\text{Cov}(X, Y) = E((X - E(X))(Y - E(Y)))$$

Yani hem X hem Y’nin beklentilerinden ne kadar saptıklarını her veri ikilisi için, çıkartarak tespit ediyoruz, daha sonra bu farkları birbiriyle çarpıyoruz, ve beklentisini alıyoruz (yani tüm olasılık üzerinden ne olacağını hesaplıyoruz).

Ayrı ayrı X, Y değişkenleri yerine çok boyutlu X kullanırsak, ki boyutları m, n olsun yani m veri noktası ve n boyut (özellik, öge) var, tanımı şöyle ifade edebiliriz,

$$\Sigma = \text{Cov}(X) = E((X - E(X))^T(X - E(X)))$$

Medyan ve Yüzdelikler (Percentile)

Üstteki hesapların çoğu sayıları toplayıp, bölmek üzerinden yapıldı. Medyan ve diğer yüzdeliklerin hesabı (ki medyan 50. yüzdeliğe tekabül eder) için eldeki tüm değerleri “sıra dizmemiz” ve sonra 50. yüzdelik için ortadakine bakmamız gerekiyor. Mesela eğer ilk 5. yüzdeliği arıyorsak ve elimizde 80 tane değer var ise, bastan 4. sayıya / vektör hücrelerine / ögeye bakmamız gerekiyor. Eğer 100 eleman var ise, 5. sayıya bakmamız gerekiyor, vs.

Bu siraya dizme islemi kritik. Kiyasla ortalama hesabi hangi sirada olursa olsun, sayilari birbirine topluyor ve sonra boluyor. Zaten ortalama ve sapmanin istatistikte daha cok kullanilmasinin tarihi sebebi de aslinda bu; bilgisayar oncesi cagda sayilari siralamak (sorting) zor bir isti. Bu sebeple hangi sirada olursa olsun, toplayip, bolerek hesaplanabilecek ozetler daha makbuldu. Fakat artik siralama islemi kolay, ve veri setleri her zaman tek tepeli, simetrik olmayabiliyor. Ornek veri seti olarak unlu `dellstore2` tabanindaki satis miktarlari kullanirsak,

```
print np.mean(data)

213.948899167

print np.median(data)

214.06

print np.std(data)

125.118481954

print np.mean(data)+2*np.std(data)

464.185863074

print np.percentile(data, 95)

410.4115
```

Goruldugu gibi uc nokta hesabi icin ortalamadan iki sapma otesini kullanirsak, 464.18, fakat 95. yuzdeligi kullanirsak 410.41 elde ediyoruz. Niye? Sebebi ortalamann kendisi hesaplanirken cok uc degerlerin toplama dahil edilmesidir ve bu durum, ortalamann kendisini daha buyuk seviyeye dogru itiyor. Yuzdelik hesabi ise sadece sayilari siralayip belli bazi elemanlari otomatik olarak uc nokta olarak addediyor.

Box Whisker Grafikleri

Tek boyutlu bir verinin dagilimini gormek icin Box ve Whisker grafikleri faydali araclardir; medyan (median), dagilimin genisligini ve siradisi noktalar (outliers) acik sekilde gosterirler. Isim nereden geliyor? Box yani kutu, dagilimin agirliginin nerede oldugunu gosterir, medyanin sagindada ve solunda olmak uzere iki ceyregin arasindaki kismidir, kutu olarak resmedilir. Whiskers kedilerin biyiklarina verilen isimdir, zaten grafikte birazcik biyik gibi duruyorlar. Bu uzantilar medyan noktasindan her iki yana kutunun iki kati kadar uzatilir sonra verideki "ondan az olan en buyuk" noktaya kadar geri cekilir. Tum bunlari disinda kalan veri ise teker teker nokta olarak grafikte basilir. Bunlar siradisi (outlier) olduklari icin daha az olacaklari tahmin edilir.


BW grafikleri iki veriyi dagilimsal olarak karsilastirmak icin birebirdir. Mesela Larsen and Marx adli arastirmacilar cok az veri iceren Quintus Curtius Snodgrass

veri setinin degisik oldugunu ispatlamak icin bir suru hesap yapmislardir, bir suru matematiksel isleme girmislerdir, fakat basit bir BW grafigi iki setin farklilik-
ini hemen gosterir.

BW grafikleri iki veriyi dagilimsal olarak karsilastirmak icin birebirdir. Mesela Larsen and Marx adli arastirmacilar cok az veri iceren Quintus Curtius Snodgrass veri setinin degisik oldugunu ispatlamak icin bir suru hesap yapmislardir, bir suru matematiksel isleme girmislerdir, fakat basit bir BW grafigi iki setin farklilik-
ini hemen gosterir.

Python uzerinde basit bir BW grafigi

```
spread= rand(50) * 100
center = ones(25) * 50
flier_high = rand(10) * 100 + 100
flier_low = rand(10) * -100
data =concatenate((spread, center, flier_high, flier_low), 0)
plt.boxplot(data)
plt.savefig('05_03.png')
```



Bir diger ornek Glass veri seti uzerinde

```
data = loadtxt("glass.data",delimiter=",")
head = data[data[:,10]==7]
tableware = data[data[:,10]==6]
containers = data[data[:,10]==5]
```

```
print head[:,1]
```


```
data =(containers[:,1], tableware[:,1], head[:,1])
```

```
plt.yticks([1, 2, 3], ['containers', 'tableware', 'head'])
```

```
plt.boxplot(data,0,'rs',0,0.75)
plt.savefig('05_04.png')
```

```
[ 1.51131  1.51838  1.52315  1.52247  1.52365  1.51613  1.51602  1.51623
  1.51719  1.51683  1.51545  1.51556  1.51727  1.51531  1.51609  1.51508
```

```
1.51653 1.51514 1.51658 1.51617 1.51732 1.51645 1.51831 1.5164
1.51623 1.51685 1.52065 1.51651 1.51711]
```



Parametre Tahmin Ediciler (Estimators)

Maksimum Olurluk (maximum likelihood) kavramini kullanarak ilginç bazı sonuçlara erismek mümkün; bu sayede dağılım fonksiyonları ve veri arasında bazı sonuçlar elde edebiliriz. Maksimum olurluk nedir? MO ile verinin her noktası teker teker olasılık fonksiyonuna geçilir, ve elde edilen olasılık sonuçları birbiri ile carpılır. Cogunlukla formül içinde bilinmeyen bir(kaç) parametre vardır, ve bu carpım sonrası, içinde bu parametre(ler) olan yeni bir formül ortaya çıkar. Bu nihai formülün kısmi türevi alınıp sifıra esitlenince cebirsel bazı teknikler ile bilinmeyen parametre bulunabilir. Bu sonuç eldeki veri bağlamında en mümkün (olur) parametre değeridir. Öyle ya, mesela Gaussian $N(10,2)$ dağılımı var ise, 60,90 gibi değerlerin “olurluğu” düşüktür. Gaussin üzerinde örnek,

$$f(x; \mu, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x - \mu)^2 \right\}, x \in \mathbb{R}$$

Carpım sonrası

$$\begin{aligned} f(x_1, \dots, x_n; \mu, \sigma) &= \prod \frac{1}{\sigma\sqrt{2\pi}} \exp \left\{ -\frac{1}{2\sigma^2}(x_i - \mu)^2 \right\} \\ &= \frac{(2\pi)^{-n/2}}{\sigma^n} \exp \left\{ -\frac{\sum (x_i - \mu)^2}{2\sigma^2} \right\} \end{aligned}$$

Ustel kısım $-n/2$ nereden geldi? Çünkü bolen olan karekoku uste cikardik, böylece $-1/2$ oldu, n çünkü n tane veri noktası yuzunden formül n kere carpiliyor. Veri noktaları x_i içinde. Eğer log, yani \ln alırsak \exp 'den kurtuluruz, ve biliyoruz ki log olurluğu maksimize etmek normal olurluğu maksimize etmek ile aynı şeydir, çünkü \ln transformasyonu monoton bir transformasyondur. Ayrıca olurluk icbukeydir (concave) yani kesin tek bir maksimumu vardır.

$$\ln f = -\frac{1}{2}n \ln(2\pi) - n \ln \sigma - \frac{\sum (x_i - \mu)^2}{2\sigma^2}$$

Turevi alip sifira esitleyelim

$$\frac{\partial(\ln f)}{\partial \mu} = \frac{\sum (x_i - \mu)^2}{2\sigma^2} = 0$$

$$\hat{\mu} = \frac{\sum x_i}{n}$$

Bu sonuc (1)'deki formul, yani orneklem ortalamasi ile ayni! Fakat buradan hemen bir baglantiya ziplamadan once sunu hatirlayalim - orneklem ortalamasi formulunu *biz* tanımladik. “Tanım” diyerek bir ifade yazdik, ve budur dedik. Simdi sonradan, verinin dagiliminin Gaussian oldugunu farzederek, bu verinin mumkun kilabilecegi en optimal parametre degeri nedir diye hesap ederek ayni formule eristik, fakat bu bir anlamda bir guzel raslanti oldu.. Daha dogrusu bu aynilik Gaussian / Normal dagilimlarinin “normalligi” ile alakali muhakkak, fakat ornekleme ortalamasi hicbir dagilim faraziyesi yapmiyor, herhangi bir dagilimdan geldigi bilinen ya da bilinmeyen bir veri uzerinde kullanilabiliyor. Bunu unutmayalim. Istatistikte matematigin lakaytlasmasi (sloppy) kolaydir, o sebeple neyin tanım, neyin hangi faraziyeeye gore optimal, neyin nufus (population) neyin orneklem (sample) oldugunu hep hatirlamamiz lazim.

Devam edelim, maksimum olurluk ile $\hat{\sigma}$ hesaplayalim,

$$\frac{\partial(\ln f)}{\partial \sigma} = -\frac{n}{\sigma} + \frac{\sum (x_i - \mu)^2}{2\sigma^3} = 0$$

Cebirsel birkac duzenleme sonrasi ve μ yerine yeni hesapladigimiz $\hat{\mu}$ kullanarak,

$$\hat{\sigma}^2 = \frac{\sum (x_i - \hat{\mu})^2}{n}$$

Bu da orneklem varyansi ile ayni!

Büyük Sayılar Kanunu (Law of Large Numbers)

Olasılık kuramında önemli matematiksel bir denklem, büyük sayılar kanunudur. Bu kanun, orneklem (sample) ile rasgele degiskenler, yani matematiksel olasilik dagilimleri olan dunya arasinda bir baglanti gorevi gorur.

Kanun kabaca bildigimiz gunluk bir gercegin matematiksel ispatidir da denebilir. Yazı-tura atarken yazı çıkma ihtimalinin 1/2 olduğunu biliyoruz (cunku zar atisini bir dagilim gibi goruyoruz). Herhalde çoğumuz da bu yazı-tura işleminin “bir çok kere” tekrarlandığı durumda, toplam sonucun aşağı yukarı yarısının yazı olacağını tahmin biliyoruz.

Matematiksel olarak, farzedelim ki her yazı-tura atışı bir deney olsun. Her ayrı deneyin sonucu X_1, X_2, \dots, X_n olarak rasgelen değişkenlerle tanımlanmış olsun, bu değişkenlerin dağılımı aynı (çünkü aynı zar), ama birbirlerinden bağımsızlar (çünkü her deney diğerinden alakasız). Değişkenlerin sonucu 1 ya da 0 değeri taşıyacak, $Yazı=1, Tura=0$.

Buyuk Sayılar Kanunu tüm bu deney sonuçlarının, yani rasgele değişkenlerin ortalama alınır, yani $\bar{X} = X_1 + \dots + X_n$ ile, elde edilen sonucun X_i 'lerin (aynı olan) beklentisine yaklaşacağını söyler, yani n büyüdükçe \bar{X}_n 'in $1/2$ 'ye yaklaştığını ispatlar, yani $E[X_i] = 1/2$ değerine. Notasyonel olarak $E(X_i) = \mu$ olarak da gösterilebilir.

Formüsel olarak, herhangi bir $\epsilon > 0$ için,

$$\lim_{n \rightarrow \infty} P(|\bar{X} - \mu| \leq \epsilon) = 1$$

ya da

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| > \epsilon) = 0$$

ya da

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Burada ne söylendiğine dikkat edelim, X_i dağılımı *ne olursa olsun*, yani ister Binom, ister Gaussian olsun, *örneklem* üzerinden hesaplanan sayısal ortalamanın (empirical mean) formüsel olasılık beklentisine yaklaştığını söylüyoruz! X_i 'ler en absürt dağılımlar olabilirler, bu dağılımların fonksiyonu son derece cetrefil, tek tepeli (unimodal) bile olmayabilir, o formüller üzerinden beklenti için gereken integralin belki analitik çözümü bile mevcut olmayabilir! Ama yine de ortalama, o dağılımların beklentisine yaklaşacaktır. İstatistik ile olasılık teorisi arasındaki çok önemli bir bağlantı bu.

Sonuç sasirtici, fakat bir ek daha yapalım, sezgisel (intuite) olarak bakarsak aslında sonuç çok sasirtici olmayabilir. Niye? Diyelim ki genel veri $N(\mu, \sigma^2)$ şeklinde bir Normal dağılımdan geliyor ve örneklem de bu sebeple aynı dağılıma sahip. Bu durumda örneklemdeki veri noktalarının μ 'ya yakın değerler olmasını beklemek mantıklı olmaz mı? Çünkü bu dağılım "zar atınca" ya da bir genel nüfustan bir "örnek toplayınca" (ki bunu bir anlamda istatistiksel bir zar atışı olarak görebiliriz) onu μ, σ^2 'e göre atacaktır. Örneklemi zar atışı sonuçları olarak gördüğümüze göre elde edilen verilerin bu şekilde olacağı sasirtici olmamalı. Ve bu zar atışlarının ortalamasının, son derece basit bir aritmetik bir işlemle hesaplanıyor olsa bile, μ 'ye yaklaşması normal olmalı.

Bu arada, bu argumana tersten bakarsak Monte Carlo integralinin niye isledigine görebiliriz (bkz *Monte Carlo, Entegraller, MCMC* yazısı).

Ozellikle orneklem ile genel nufus (population) arasinda kurulan baglantiya dikkat edelim. Istatigin onemli bir bolumunun bu baglanti oldugu soylenebilir. Her orneklem, bilmedigimiz ama genel nufusu temsil eden bir dagilimla ayni dagilima sahip olan X_i 'dir dedik, ve bu ayniliktan ve bagimsizliktan yola cikarak bize genel nufus hakkında bir ipucu saglayan bir kanun gelistirdik (ve birazdan ispatlayacagiz).

Ispata baslayalim.

X_1, X_2, \dots, X_n bagimsiz degiskenler olsun.

$$E(X_i) = \mu$$

$$\text{Var}(X_i) = \sigma$$

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

\bar{X}_n de bir rasgele degisikendir, cunku \bar{X}_n degiskeni her X_i dagilimiyla alakali.

İspat devam etmek için, \bar{X}_n dagiliminin beklentisini bulmamiz gerekiyor.

$$E(\bar{X}_n) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

E dogrusal bir islec (linear operator) oldugu icin disaridan iceri dogru nufuz eder.

$$\begin{aligned} &= \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} n\mu \\ &= \mu \end{aligned}$$

Dikkat edelim, bu *ortalamanin* beklentisi, ortalamanin kendisinin hangi degere yaklasacagini hala gostermiyor. Eger oyle olsaydi isimiz bitmis olurdu :) Daha yapacak cok is var.

Simdi \bar{X}_n dagiliminin standart sapmasini da bulalim. Diger bir olasilik kuramina gore

$$Y = a + bX$$

$$\text{Var}(Y) = b^2 \text{Var}(X)$$

oldugunu biliyoruz. O zaman,

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i)$$

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{1}{n^2} n \sigma^2 = \frac{\sigma^2}{n} \quad (3)$$

Artık Çebişev kuramını kullanmaya hazırız. İspatlamaya çalıştığımız neydi? $n \rightarrow \infty$ iken,

$$P(|\bar{X}_n - \mu| > \epsilon) \rightarrow 0$$

Cebisev'den

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\epsilon^2}$$

$$P(|\bar{X}_n - \mu| > \epsilon) \leq \frac{\sigma^2}{n\epsilon^2} \rightarrow 0$$

$\sigma^2/n\epsilon^2$ 'in sifira gitmesi normal cunku n sonsuza gidiyor.

Peki $P(|\bar{X}_n - \mu| > \epsilon)$ 'nin sifira gittigini gosterdik mi?

$\sigma^2/n\epsilon^2$ 'nin sifira gittigini gosterdik. $\sigma^2/n\epsilon^2$ de $P(|\bar{X}_n - \mu| > \epsilon)$ 'den buyuk olduguna gore, demek ki o da sifira iner.

□

Buyuk Sayilar Kanunu orneklem ortalamasinin ve varyansinin X_i 'in beklentisi ve varyansi ile baglanti kurar. Merkezi Limit Teorisi bir adim daha atar, ve der ki " \bar{X} 'in dagilimi Gaussian dagilim olmalidir yani normal egrisi seklinde cikmalidir!". Teorinin detaylari bu bolumde bulunabilir.

Çebişev Eşitsizliği

Olasılık matematiğinde, büyük sayılar kuramı adında anılan ve olasılık matematiğinin belkemiğini oluşturan kuramı ispatlamak için, diğer bir kuram olan Çebişev eşitsizliğini de anlamamız gerekiyor. Çebişev eşitsizliği bir rasgele değişken, onun ortalaması (beklentisi) ve herhangi bir sabit sayı arasındaki üçlü arasında bir 'eşitsizlik' bağlantısı kurar, ve bu bağlantı diğer olasılık işlemlerimizde ispat verisi olarak işimize yarar.

Teori: Herhangi bir t değeri için,

$$P(|X - \mu| > t) \leq \frac{\sigma^2}{t^2}$$

İspata başlayalım. Entegral ile olasılık hesabı yapmak için bize bir x uzayı lazım.

$$\mathbb{R} = x : |x - \mu| > t$$

Yani \mathbb{R} uzayı, x ile ortalamasının farkının, t 'den büyük olduğu bütün sayıların kümesidir.

O zaman,

$$P(|X - \mu| > t) = \int_{\mathbb{R}} f(x) dx$$

Dikkat edelim $P(\cdot)$ içindeki formül, küme tanımı ile aynı. O yüzden $P(\cdot)$ hesabı ortada daha olmayan, ama varolduğu kesin bir dağılım fonksiyonu tanımlamış da oluyor. Buna $f(x)$ deriz. $P(\cdot)$ 'in, $f(x)$ fonksiyonunun \mathbb{R} üzerinden entegral olduğunu olasılığa giriş dersinden bilmemiz lazım.

Eğer $x \in \mathbb{R}$ dersek o zaman

$$\frac{|x - \mu|^2}{t^2} \geq 1$$

t 'nin denkleme bu şekilde nereden geldiği şaşkınlık yaratabilir. Daha önce tanımlanan şu ibareye dikkat edelim, $x : |x - \mu| > t$ diye belirtmiştik. Bu ifadeyi değiştirerek, yukarıdaki denkleme gelebiliriz.

Devam edersek, elimizdeki 1'den büyük bir değer var. Bu değeri kullanarak, aşağıdaki tanımı yapmamız doğru olacaktır.

$$\int_{\mathbb{R}} f(x) dx \leq \int_{\mathbb{R}} \frac{(x - \mu)^2}{t^2} f(x) dx \leq \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

Ortadaki entegral niye birinci entegralden büyük? Çünkü ortadaki entegraldeki $f(x)dx$ ibaresinden önce gelen kısmın, her zaman 1'den büyük olacağını belirttiğimize göre, ikinci entegralin birinciden büyük olması normaldir, çünkü birinci entegral $f(x)$ olasılık dağılımına bağlı, entegral ise bir alan hesabıdır ve olasılık dağılımlarının sonsuzlar arasındaki entegrali her zaman 1 çıkar, kaldı ki üstteki x 'in uzayını daha da daralttık.

Evet...Üçüncü entegral ispata oldukça yaklaştı aslında. Standart sapma işaretini hala ortada göremiyoruz, fakat son entegraldeki ibare standart sapma değerini

zaten içeriyor. Önce daha önceki olasılık matematiği bilgimize dayanarak, standart sapmanın tanımını yazıyoruz. Dikkat edelim, bu ibare şu anki ispatımız dahilinden değil, haricinden önceki bilgimize dayanarak geldi. Standart sapmanın tanımı şöyledir.

$$\sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx$$

O zaman

$$\frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

yani

$$\int_{\mathbb{R}} f(x) dx \leq \frac{\sigma^2}{t^2} = \int_{-\infty}^{\infty} \frac{(x - \mu)^2}{t^2} f(x) dx$$

ki $\int_{\mathbb{R}} f(x) dx$ zaten $P(|X - \mu| > t)$ olarak tanımlanmıstı.

□

Merkezi Limit Teorisi (Central Limit Theorem -CLT-)

Buyuk Sayilar Kanunu orneklem ortalamasinin gercek nufus beklentisine yaklasacagini ispatladi. Orneklem herhangi bir dagilimdan gelebiliyordu. CLT bu teoriyi bir adim ilerletiyor ve diyor ki kendisi de bir rasgele degisken olan orneklem ortalamasi \bar{X} Normal dagilima sahiptir! Daha detaylandirmal gerekirse,

Diyelim ki X_1, \dots, X_n orneklemi birbirinden bagimsiz, ayni dagilimli ve ortalamasi μ , standart sapmasi σ olan (ki o da ayni dagilima sahip) bir nufustan geliyorlar. Orneklem ortalamasi \bar{X} , ki bu rasgele degiskenin beklentisinin μ , ve (3)'e gore standart sapmasinin σ/\sqrt{n} oldugunu biliyoruz. Dikkat: \bar{X} 'in kendisinden degil, *beklentisinden* bahsediyoruz, BSK'deki ayni durum, yani ortalama dagiliminin ortalamasi. Teori der ki n buyudukce \bar{X} dagilimi (bu sefer kendisi) bir $N(\mu, \sigma/\sqrt{n})$ dagilimina yaklasir.

Bu ifade genelde standart normal olarak gostrilir, herhangi bir normal dagilimi standart normal'e donusturmeyi daha once gormustuk zaten, beklentiyi cikartip standart sapmaya boluyoruz, o zaman orneklem dagilimi \bar{X} ,

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

dagilimina yaklasir diyoruz, ki $Z = N(0, 1)$ dagilimidir, beklentisi sifir, standart sapmasi 1 degerindedir.

Bu teorinin ispatini simdilik vermeyecegiz.

Kaynaklar

[1] <http://mathworld.wolfram.com/MaximumLikelihood.html>

[2] Introduction to Probability and Statistics Using R